Magíster en Ciencia de Datos e Inteligencia Artificial · MCDI500 Programación para la Ciencia de Datos · Universidad Andrés Bello

# Evaluación Formativa 1 — Mapa conceptual (versión 2, ajustada según la retroalimentación docente)

**Proyecto:** Análisis reproducible del Inventario Público de Glaciares de Chile 2022 · Fases 1 y 2

**Grupo 3 — Integrantes**
Aníbal Reyes
Francisco Correa
Gustavo Aloy
Roberto Gaubert

**Docente:** Dr. Omar Salinas Silva
**Entrega:** Semana 1 · versión 2 del 11 de noviembre de 2026
**Repositorio:** https://github.com/fcorreasoto/proyecto-grupo3-mcdi500

**Reflexión técnica del grupo**

• **Qué aporta nuestro análisis frente a la DGA.** La DGA publica el inventario y sus totales. Nuestro aporte es un cálculo **reproducible de punta a punta** (dato verificado con SHA-256, pipeline versionado y probado) centrado en una relación que el inventario no entrega como análisis: **la concentración del hielo**.

• **Pregunta acotada.** ¿Qué tan concentrado está el volumen de hielo estimado en pocos glaciares y regiones, y cambia esa concentración según la clasificación del glaciar? La exploración ya la sustenta: el 1 % de los glaciares reúne el 93,8 % del volumen, y Magallanes y Aysén el 97,9 %.

• **El volumen se estimó a partir del área.** La columna F_ESP_MED declara el método de Chen y Ohmura (1990), y lo verificamos en los datos: ESP_MED = 28,5 · AREA^0,357 en los cinco tipos de glaciar ($R^2 \geq 0{,}998$), de modo que VOL ≈ 0,0285 · AREA^1,357 (× 0,6 en glaciares rocosos). Área y volumen **no son variables independientes**: su correlación la produce la fórmula, y la concentración del volumen amplifica la del área. Reportaremos ambas y declararemos este supuesto.

• **Licencia del conjunto.** La página de descarga de la DGA no declara una licencia (revisada el 11-11-2026). Lo tratamos como un dato público de un organismo del Estado, usado con fines académicos y citando la fuente con su enlace de descarga.

• **Cada herramienta interviene en etapas concretas** (bloque B del mapa): Python y el .venv configuran el entorno; src/utilidades.py verifica y carga el dato; pandas y NumPy miden; pandas y scikit-learn transforman; Matplotlib visualiza. JupyterLab y Git atraviesan todas las etapas.

• **Repositorio y colaboración.** Los notebooks viven en F1/ y F2/, y los datos, el código (src/) y la documentación quedan en la raíz. Los notebooks se versionan **ejecutados**, porque sus salidas son evidencia. Cada tarea va en una rama con Pull Request revisado por otro integrante, y los commits se reparten entre los cuatro.

**Referencias**

Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book
Chen, J., & Ohmura, A. (1990). Estimation of Alpine glacier water resources and their change since the 1870s. *IAHS Publication, 193*, 127–135.
Dirección General de Aguas. (2022). *Inventario público de glaciares de Chile 2022* [Conjunto de datos]. Ministerio de Obras Públicas. https://dga.mop.gob.cl/inventario-publico-glaciares/
Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B., Bussonnier, M., Frederic, J., Kelley, K., Hamrick, J., Grout, J., Corlay, S., Ivanov, P., Avila, D., Abdalla, S., Willing, C., & Jupyter Development Team. (2016). Jupyter Notebooks: A publishing format for reproducible computational workflows. En F. Loizides & B. Schmidt (Eds.), *Positioning and power in academic publishing* (pp. 87–90). IOS Press. https://doi.org/10.3233/978-1-61499-649-1-87

# Flujo de trabajo reproducible — Inventario Público de Glaciares de Chile 2022 · Grupo 3 (versión 2)

## A · Contexto problematizador y pregunta

**Situación**
Los glaciares son reservas estratégicas de agua dulce: 26.180 glaciares y 21.012 km² en Chile

→ se delimita →

**Problema y aporte**
La DGA publica el inventario y sus totales, pero no un cálculo reproducible de cuán concentrado está el hielo

→ se formula →

**Pregunta acotada**
¿Qué tan concentrado está el volumen de hielo estimado en pocos glaciares y regiones, y cambia esa concentración según la clasificación?

→ responde con →

**Dataset · DGA 2022**
26.180 glaciares × 45 variables
Licencia: no declarada → uso académico citando la fuente

**Supuesto verificado:** el volumen se estimó desde el área (Chen y Ohmura, 1990). ESP_MED = 28,5·A^0,357 ⇒ área y volumen **no** son variables independientes

## B · Ciclo de vida del dato y herramientas que intervienen en cada etapa

⇢ la exploración obliga a redefinir ⇢

**① Definición**
Problema, pregunta acotada, alcance y supuestos
[F1] ✔

→

**② Obtención**
CSV oficial en data/raw, inmutable y verificado (SHA-256)
[F1–F2] ✔

→

**③ Exploración**
Tipos, faltantes encubiertos, atípicos y categorías
[F1–F2] ✔

→

**④ Transformación**
Limpieza, imputación, codificación y escalamiento
[F2] ✔

→

**⑤ Análisis**
Concentración del volumen por glaciar, región y clasificación
[F3] ○

→

**⑥ Comunicación**
Tablas, figuras e informe en results/
[F4] ○

configura ↑ — **Python 3.14 + .venv**
requirements.txt con versiones exactas

verifica y carga ↑ — **src/utilidades.py**
rutas relativas, huella SHA-256 y carga

mide ↑ — **pandas · NumPy**
+ validar_dataset.py: perfil, IQR, ceros

transforma ↑ — **pandas · scikit-learn**
imputación comparada, one-hot, RobustScaler

agrega ↑ — **pandas (groupby)**
agregaciones y curvas de concentración

visualiza ↑ — **Matplotlib · seaborn**
figuras; en F2, gráficos de control

**Git local + GitHub** — versionan todas las etapas: una rama por tarea → Pull Request revisado por otro integrante

**JupyterLab** (kernel del .venv) — ejecuta y documenta todas las etapas; Restart & Run All antes de cada entrega

registra cada commit en ↓

se documenta en ↓

## D · Repositorio proyecto-grupo3-mcdi500

**Estructura**
F1/F1_Definicion.ipynb · ① ② ③
F2/F2_Procesamiento.ipynb · ② ③ ④
data/raw/ · dato original ②
data/processed/ · dato limpio ④
src/utilidades.py · funciones compartidas
docs/ · diccionario, bitácora, informe
results/ · tablas y figuras ⑥ ○
README.md · requirements.txt
.gitignore · validar_dataset.py

**Protocolo de colaboración**
- Notebooks versionados **ejecutados**: sus salidas son evidencia (sin nbstripout)
- Una rama por tarea → Pull Request revisado por otro integrante
- Commits repartidos entre los cuatro integrantes
- Prefijos docs · data · feat · fix · test
- Email de Git = email de la cuenta GitHub

## E · Documentación científica reproducible

**Notebook reproducible** (F1/, F2/): une razonamiento, cálculo y evidencia

**Celdas Markdown**
justifican el porqué de cada decisión

**Celdas de código**
llaman funciones de src/ (el qué)

**Salidas**
tablas y gráficos de control como evidencia

registran ↓

**Bitácora de decisiones** (docs/)
Ej.: «HMIN se imputa con HMEDIA − desnivel por comuna: 0 violaciones físicas frente a 31 con la mediana global»

→ sustenta →

**Informe + referencias APA 7**
DGA (2022) con enlace de descarga; Chen y Ohmura (1990) para el volumen; resultados → F4

**Leyenda:** ■ contexto · ■ etapa del ciclo · ■ herramienta (flecha verde: qué hace en esa etapa) · ■ repositorio · ■ documentación · ■ supuesto verificado · → da paso a · ⇢ retorno · [F1–F4] fase · ✔ implementado · ○ proyectado