MCDI500

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASES 1 Y 2

Análisis reproducible del Inventario Público de Glaciares de Chile 2022

Nombre integrante/s: Aníbal Reyes, Francisco Correa Soto, Gustavo Aloy y Roberto Gaubert (Grupo 3)

Curso: MCDI500 Programación para la Ciencia de Datos — Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello

Fecha: 15 de noviembre de 2026

Docente: Dr. Omar Salinas Silva

Repositorio: https://github.com/fcorreasoto/proyecto-grupo3-mcdi500

Índice

1. Introducción y contextualización....3
1.1 Contexto del proyecto....3
1.2 Situación que origina el análisis y presentación del problema....3
1.3 Propósito general y alcance del informe....3
1.4 Justificación técnica....4
1.5 Conexión con las fases F1–F4....4
2. Definición de la problemática y objetivos del proyecto....5
2.1 Formulación de la problemática....5
2.2 Preguntas centrales del análisis....5
2.3 Objetivos....5
2.4 Alcance del proyecto....5
2.5 Restricciones....6
2.6 Supuestos relevantes....6
2.7 Articulación con las fases....7
3. Aplicación de herramientas científicas....8
3.1 Ecosistema utilizado....8
3.2 Integración en el flujo de trabajo....8
3.3 Reproducibilidad técnica....9
3.4 Control de versiones....10
3.5 Documentación del proceso....12
3.6 Repositorio GitHub....13
4. Diseño de soluciones algorítmicas....14
4.1 Codificación funcional....14
4.2 Preprocesamiento y transformación del dataset....14
4.3 Validación técnica y verificación del código....17
5. Notebook F1_Definicion.ipynb (F1)....19
6. Notebook ejecutable de la Fase 2....19
7. Vinculación del mapa conceptual con el avance del proyecto....21
7.1 Justificación de la relación entre planificación e implementación....22
8. Síntesis del avance y próximos pasos....23
Bibliografía....24
Anexo A. Perfil de las 45 variables originales....26
Anexo B. Bitácora de decisiones de la Fase 2....28
Anexo C. Evaluación del dataset contra los criterios del curso....30

1. Introducción y contextualización

1.1 Contexto del proyecto

Chile concentra una de las mayores superficies glaciares del hemisferio sur fuera de la Antártica. Los glaciares son reservas estratégicas de agua dulce: en las zonas norte y central sostienen el caudal de los ríos durante los meses secos y los años de sequía, y en la Patagonia forman los Campos de Hielo Norte y Sur. La evidencia reciente muestra que los glaciares andinos pierden masa de forma sostenida (Dussaillant et al., 2019) y que la pérdida de hielo a escala global se aceleró durante el siglo XXI (Hugonnet et al., 2021). En ese escenario, saber dónde están los glaciares y cuánta agua almacenan es una condición previa para cualquier decisión de gestión hídrica.

La Dirección General de Aguas (DGA) publica el **Inventario Público de Glaciares de Chile 2022**, un catastro oficial que en su versión CSV contiene **26.180 glaciares y 45 variables**: ubicación administrativa e hidrográfica, clasificación, superficie, altitudes, pendiente, espesor medio y volumen estimado (Dirección General de Aguas [DGA], 2022). Es la única fuente de datos del proyecto.

1.2 Situación que origina el análisis y presentación del problema

El inventario existe, pero no es directamente analizable. El reconocimiento de F1 y la exploración de F2 mostraron varios problemas:

- **Columnas sin información:** dos columnas vacías (`CUBIERTO` y `OBSERVACIO`) y una con 97,24 % de faltantes (`CH_CASQ`).
- **Formatos que impiden el cálculo:** coordenadas leídas como texto por la coma decimal y fechas en tres formatos.
- **Texto inconsistente:** categorías con la codificación de caracteres rota y espacios dobles.
- **Faltantes encubiertos:** valores que no figuran como nulos pero lo son, como 33 altitudes mínimas registradas en 0 m en glaciares que no llegan al mar y 362 volúmenes en 0 por redondeo.
- **Magnitudes muy asimétricas:** la superficie media es 0,80 km², la mediana 0,036 km² y el máximo 772,5 km².

Si el procedimiento para leer, limpiar y resumir el archivo no es transparente, nadie puede verificar las cifras que se obtengan. La DGA publica el inventario y sus totales, pero no un cálculo reproducible de **cuán concentrado está el hielo**, que es el foco de este proyecto. El problema es, por tanto, doble: **medir esa concentración y su variación entre tipos de glaciar**, y hacerlo con un **flujo reproducible** que cualquier persona pueda ejecutar desde el repositorio y obtener el mismo resultado.

1.3 Propósito general y alcance del informe

Objetivo general. Medir, mediante un flujo reproducible en Python, cuán concentrados están el volumen estimado y la superficie de los glaciares de Chile en pocos glaciares y regiones, y cómo varía esa concentración según la clasificación del glaciar.

Alcance de este informe. Este avance documenta las Fases 1 y 2: la definición del problema y la configuración del entorno reproducible (F1) y la obtención, exploración, limpieza, transformación y validación del inventario (F2). Los resúmenes territoriales (F3) y las visualizaciones y la comunicación de

resultados (F4) se presentan como trabajo proyectado.

1.4 Justificación técnica

Con 26.180 registros, 45 variables y decisiones que dependen de cifras (cuántos faltantes, qué método de imputación deforma menos la distribución, qué escalador corresponde a los datos), el trabajo no puede hacerse de forma manual ni en una planilla sin perder trazabilidad. Programar el proceso en Python permite:

- encapsular cada paso en funciones reutilizables y probadas;
- justificar cada decisión con evidencia calculada en el mismo documento, gracias a los notebooks de Jupyter (Kluyver et al., 2016);
- versionar el proceso completo con Git, para reconstruir qué cambió, cuándo y quién lo hizo (Chacon & Straub, 2014);
- entregar a las fases siguientes un conjunto validado.

El equipo sigue las prácticas de computación científica de Wilson et al. (2017) y Sandve et al. (2013), la recomendación de mantener notebooks ejecutables de principio a fin (Pimentel et al., 2021) y la ruta de doce pasos propuesta en el curso (Salinas, 2026), con los criterios de la guía de desarrollo de la evaluación (Universidad Andrés Bello, 2026).

1.5 Conexión con las fases F1–F4

Tabla 1. Aporte de cada fase a la solución del problema.

Fase	Propósito	Producto	Estado
F1 · Definición	Delimitar problema, pregunta y objetivos; configurar y verificar el entorno; reconocer el inventario sin modificarlo	F1/F1_Definicion.ipynb, README, requirements.txt	Implementada
F2 · Preparación	Explorar, limpiar, imputar, transformar, escalar y validar el inventario	F2/F2_Procesamiento.ipynb, data/processed/, docs/bitacora_f2.md	Implementada
F3 · Análisis	Medir la concentración del volumen y la superficie por glaciar, región y clasificación	Notebook F3, tablas y curvas de concentración	Proyectada (semana 2)
F4 · Comunicación	Comunicar si la concentración cambia según la clasificación	Figuras, informe final y presentación	Proyectada (semana 3)

2. Definición de la problemática y objetivos del proyecto

2.1 Formulación de la problemática

El fenómeno analizado es la **concentración de la masa glaciar de Chile**: qué fracción del volumen de hielo estimado (`VOL_km3`) y de la superficie (`AREA_KM2`) reúnen unos pocos glaciares y regiones, y si esa concentración difiere entre los 5 tipos de glaciar (`CLASIFICA`), las 16 regiones (`REGION`) y las 4 macrozonas (`MZON_GLAC`). El problema técnico consiste en transformar el inventario original en un conjunto confiable en el que esas magnitudes puedan agregarse sin sesgos introducidos por errores de formato, faltantes encubiertos o inconsistencias, y sin alterar el archivo fuente. **El volumen no es una medición independiente:** el inventario lo estimó desde el área (sección 2.6), y el análisis lo declara como supuesto.

2.2 Preguntas centrales del análisis

Pregunta de investigación: ¿qué tan concentrado está el volumen de hielo estimado en pocos glaciares y regiones, y cambia esa concentración según la clasificación del glaciar? Se desagrega en:

- ¿Qué fracción del volumen y de la superficie reúnen el 1 % y el 10 % de los glaciares de mayor tamaño? La exploración anticipa un valor extremo: el 1 % reúne el 93,8 % del volumen.
- ¿Qué regiones y macrozonas concentran el volumen? Magallanes y Aysén reúnen el 97,9 %.
- ¿Cambia esa concentración entre glaciaretes y glaciares de montaña, rocosos, de valle y efluentes?
- Pregunta técnica de F2: ¿qué problemas de calidad presenta el inventario y cómo tratarlos sin perder ni inventar información?

2.3 Objetivos

Objetivo general. Medir, mediante un flujo reproducible en Python, cuán concentrados están el volumen estimado y la superficie de los glaciares de Chile en pocos glaciares y regiones, y cómo varía esa concentración según la clasificación del glaciar.

Tabla 2. Objetivos específicos, fase e indicador de cumplimiento.

Objetivo específico	Fase	Indicador verificable
OE1. Verificar la estructura, la calidad y el rol analítico de las 45 variables, y la relación entre área y volumen estimado.	F1–F2	Diccionario de 45 variables (F1 §7); 17 hallazgos de F2 §2, incluida la fórmula de Chen y Ohmura verificada
OE2. Documentar y ejecutar la limpieza y transformación del inventario sin modificar el archivo original.	F2	Datos en data/processed/, 17/17 validaciones, 21/21 pruebas y huella SHA-256 del archivo raw sin cambios
OE3. Calcular la concentración del volumen y de la superficie: participación del 1 % y del 10 % de glaciares mayores, por región y por clasificación.	F3	Tablas y curvas de concentración reproducibles
OE4. Comunicar con tablas y visualizaciones reproducibles si la concentración cambia según la clasificación.	F4	Figuras e informe final generados desde los notebooks

2.4 Alcance del proyecto

Se aborda: la concentración del volumen y de la superficie por glaciar, región y macrozona; su comparación

entre clasificaciones de glaciar; el equivalente en agua como magnitud complementaria; y la construcción de un pipeline reproducible que prepare el inventario para esos análisis.

No se aborda: la estimación de tendencias temporales de pérdida de hielo, los modelos predictivos, el cruce con datos climáticos externos, la validación en terreno de las mediciones de la DGA ni las relaciones entre área y volumen, porque una se calculó a partir de la otra.

2.5 Restricciones

A diferencia del alcance, que es una decisión del equipo, las restricciones son condiciones impuestas por los datos, el método y el plazo. F1 §7.2 evaluó el inventario contra los criterios del curso, con los mismos umbrales de `validar_dataset.py`: **cumple todos los requisitos obligatorios y deja dos avisos**, que se declaran aquí como restricciones (detalle en el Anexo C):

- **Variables sobre 60 % de faltantes.** `CUBIERTO` y `OBSERVACIO` (100 %) y `CH_CASQ` (97,24 %) no son recuperables como variables; F2 las descarta y conserva el contenido de `CH_CASQ` como bandera binaria.
- **Datos transversales.** El 90,8 % de los registros tiene año de inventario 2019 y el 8,7 % 2020; no hay mediciones repetidas del mismo glaciar, por lo que no es posible estimar tendencias.
- **El espesor y el volumen no son mediciones.** La columna `F_ESP_MED` declara el método de Chen y Ohmura (1990), y F2 §2.3 lo verificó en los datos: `ESP_MED = 28,5 · AREA^0,357` en los cinco tipos ($R^2 \geq 0{,}998$). Por lo tanto, `VOL ≈ 0,0285 · AREA^1,357`, con un factor de 0,6 en los glaciares rocosos (60 % de hielo).
- **Documentación y licencia de la fuente.** La fuente es oficial y verificable, y el conjunto se descarga desde https://dga.mop.gob.cl/inventario-publico-glaciares/. Sin embargo, esa página no declara una licencia (revisada el 11-11-2026) y la DGA no publica un diccionario de variables junto al CSV. El conjunto se usa como dato público de un organismo del Estado, con fines exclusivamente académicos y citando la fuente. El significado y las unidades de `ERROR`, `PERIMETRO`, `PENDIENTE` y los códigos `WGI_*` quedan por verificar.
- **Plazo y herramientas.** Una semana para las Fases 1 y 2, con las librerías del curso.

2.6 Supuestos relevantes

- El inventario oficial es la mejor estimación disponible de cada glaciar: no se corrigen valores medidos sin una regla física o una fórmula del propio inventario que lo respalde.
- Las unidades (km^2, km^3, m s. n. m.) son homogéneas entre regiones.
- Cada fila representa un glaciar distinto y `COD_GLA` es su identificador. Se comprobó: 26.180 códigos únicos, sin nulos. `OBJECTID` se repite en 102 filas.
- Una altitud mínima de 0 m solo es plausible en glaciares con frente en fiordo. En los demás casos se interpreta como un dato faltante.
- **Área y volumen no son variables independientes.** Como el volumen es una función del área, ambos se reportan juntos pero no se analiza su relación: la concentración del volumen amplifica la del área (exponente 1,357) y no aporta información física independiente.

- El inventario se interpreta como una fotografía del estado reciente de los glaciares, no como una serie de tiempo.

2.7 Articulación con las fases

OE1 se cumple entre F1 (estructura, tipos y diccionario) y F2 (diagnóstico cuantitativo). OE2 se cumple completamente en F2. OE3 y OE4 se desarrollarán en F3 y F4 a partir de `data/processed/glaciares_limpio.csv`, el archivo que entrega la Fase 2.

3. Aplicación de herramientas científicas

3.1 Ecosistema utilizado

Tabla 3. Herramientas del ecosistema científico y su función en el proyecto.

Herramienta	Versión	Función en el proyecto
Python	3.14.6 (.venv)	Lenguaje del análisis; se ejecuta dentro del entorno virtual del proyecto
pandas	3.1.1	Lectura, perfilado, limpieza, imputación, codificación one-hot y persistencia (McKinney, 2022; pandas development team, 2026)
NumPy	2.5.4	Logaritmos, seno y coseno de la orientación, selección vectorizada y semilla (Harris et al., 2020)
scikit-learn	1.9.1	StandardScaler, MinMaxScaler y RobustScaler para comparar el escalamiento (scikit-learn developers, 2026)
Matplotlib	3.11.2	Gráficos de control de la imputación, la transformación y el escalamiento en F2 (Hunter, 2007)
JupyterLab / ipykernel	4.6.6 / 7.4.0	Notebooks que integran narrativa, código y evidencia (Kluyver et al., 2016)
hashlib, pathlib, subprocess	Python 3.14	Huella SHA-256, rutas relativas y registro del commit (Python Software Foundation, 2026)
Git / GitHub	—	Historial de cambios, ramas y Pull Requests (Chacon & Straub, 2014)

`requirements.txt` también fija seaborn 0.13.2, que se usará en las visualizaciones de F4, para que el entorno no cambie entre fases.

3.2 Integración en el flujo de trabajo

Las funciones que usan varias fases viven en el **módulo src/utilidades.py**. F1 lo importa y lo prueba, y F2 lo reutiliza, de modo que ninguna función está copiada entre notebooks. Las librerías se usan dentro de funciones con un propósito declarado, no en celdas sueltas. Cada etapa recibe un DataFrame y devuelve uno nuevo, sin modificar la entrada, lo que permite verificar en el propio notebook la correspondencia entre entrada, procesamiento y salida. Jupyter, Git y las librerías operan como un solo flujo, con tres señales en los notebooks:

- la celda de verificación del entorno, que compara versiones con `requirements.txt`;
- las rutas relativas a la raíz del repositorio;
- el historial de Git y los Pull Requests, que registran cada cambio de los notebooks; en F2, además, una celda final registra la rama y el commit con que se generaron las salidas.

Tabla 4. Funciones principales del flujo programático.

Función	NB	Entrada → salida
localizar_raiz(inicio) · huella_sha256(ruta) · verificar_huella(ruta)	src/	Directorio → raíz del repositorio (FileNotFoundError); archivo → SHA-256; versión distinta → ProyectoError
cargar_inventario · leer_requirements · version_repositorio · identidad_git	src/	CSV → DataFrame sin alterar; requirements → versiones; Git → rama, commit, email válido
Bitacora (clase) · ProyectoError (excepción propia)	src/	Decisión + evidencia → registro sin duplicados → Markdown; error del proyecto distinguible del de las librerías
verificar_entorno(deps, requirements)	F1	Paquetes → versión instalada vs. declarada (OK / DIFIERE / NO INSTALADO)

Función	NB	Entrada → salida
construir_diccionario · evaluar_criterios(ficha)	F1	DataFrame → diccionario con rol analítico; ficha → requisitos OK / FALTA / AVISO
validar_fase1(raiz, config, dicc, df)	F1	Repositorio → estructura, artefactos, definición, coherencia, módulo y docs/ verificados
columnas_sin_informacion(df, umbral)	F2	DataFrame → columnas con > 60 % faltante o valor único
resumen_numerico(df, cols) · relacion_volumen(df)	F2	Asimetría, ceros e IQR; razón VOL/(AREA·ESP) y EQ/VOL por tipo
categorias_sospechosas(df, cols)	F2	Codificación rota, mayúsculas, espacios y variantes de categorías
normalizar_columnas · convertir_tipos · parsear_fecha_mixta	F2	Texto reparado; '-18,17' → −18,17; fecha en 3 formatos → fecha + año
reconstruir_volumen(df)	F2	Ceros de VOL/EQ → fórmula del inventario + banderas
imputar(df, col, metodo, grupo, referencia) · comparar_imputaciones	F2	Nulos → valor estimado + bandera; tabla comparativa de métodos
derivar_variables · codificar_ordinal · codificar_orientacion · codificar_one_hot	F2	Derivadas, códigos con orden declarado, seno/coseno, columnas binarias
escalar(df, cols, metodo) · comparar_escaladores	F2	Continuas → *_ESC; propiedades de cada escalador
ejecutar_validaciones · ejecutar_pruebas	F2	Conjuntos de salida → tabla OK/FALLA de 17 validaciones y 21 pruebas
aplanar(estructura) · profundidad(estructura) (recursivas)	F2	Metadatos anidados → pares clave-valor → docs/metadatos_proyecto.csv

3.3 Reproducibilidad técnica

Entorno virtual y dependencias

El proyecto usa un entorno virtual propio (`.venv`), excluido del control de versiones. Las dependencias se declaran con versión exacta en `requirements.txt`, generado con `pip freeze`. El proyecto requiere Python 3.12 o superior. Para reconstruir el entorno en otro equipo:

```
git clone https://github.com/fcorreasoto/proyecto-grupo3-mcdi500.git
cd proyecto-grupo3-mcdi500
python3 -m venv .venv
source .venv/bin/activate          # Windows: .venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

Verificación de la instalación y ejecución sin errores

- **Kernel y versiones.** F1 §5 comprueba que el kernel corre dentro del entorno virtual y compara siete librerías con `requirements.txt`: las siete aparecen como OK. Si falta una librería que los notebooks importan (NumPy, pandas, scikit-learn o Matplotlib), el notebook se detiene con un `assert`; las demás se reportan como aviso. F2 §0 repite la verificación del kernel y avisa si alguna versión difiere de la declarada.
- **Ejecución de inicio a fin.** Ambos notebooks se ejecutaron completos con `jupyter nbconvert --execute` (equivalente a Restart & Run All) dentro del `.venv` (Python 3.14.6), sin errores y con contadores de ejecución consecutivos: 1–15 en F1 y 1–27 en F2.
- **Rutas relativas.** `localizar_raiz` sube desde el directorio de ejecución hasta encontrar `data/raw/`; ningún notebook depende de una ruta personal.
- **Integridad y versión del dato.** F1 y F2 comparan la huella SHA-256 del CSV con la registrada en el README (`5691de5d…c283f1d`). F2 la vuelve a calcular tras validar y tras exportar.

- **Determinismo y semilla.** El pipeline no usa muestreo ni procesos aleatorios: reejecutar F2 regenera archivos procesados idénticos byte a byte. Aun así, `SEMILLA = 42` queda declarada en `src/utilidades.py` y fijada en ambos notebooks para los pasos aleatorios de las fases siguientes.
- **Robustez ante el orden de ejecución y la versión.** Cada etapa de F2 produce su propio DataFrame a partir de la anterior, por lo que re-ejecutar cualquier celda suelta da el mismo resultado; se verificó re-ejecutando una a una todas las celdas de código de F1 y F2. Ambos notebooks también se ejecutaron sin errores en un clon limpio del repositorio y en un entorno con Python 3.12 y pandas 2.2, donde F2 produjo archivos idénticos.
- **Verificación en un segundo equipo.** Un integrante distinto de quien configuró el entorno clona el repositorio, reconstruye el `.venv` desde `requirements.txt` y ejecuta ambos notebooks; el resultado se registra en la sección «Verificación en un segundo equipo» del README, con un commit de ese integrante.

3.4 Control de versiones

Git registra localmente la evolución del proyecto y GitHub aloja el repositorio remoto común (Chacon & Straub, 2014). La convención de mensajes, declarada en el mapa conceptual y en el README, usa un prefijo por tipo de cambio: `docs:`, `data:`, `feat:`, `fix:`, `test:`, `refactor:` y `chore:`.

El trabajo de este avance se organizó en ramas por tarea:

- `f1-ajustes` reúne la revisión de F1, el README y el borrador del informe, y se integró a `main` mediante el **Pull Request #1**.
- `f2-pipeline` reúne el pipeline de F2, los datos procesados y la actualización de la documentación, y se integró mediante el **Pull Request #2**.
- `fix-robustez-notebooks` corrige la re-ejecución de celdas sueltas y la compatibilidad con pandas 2, detectadas al probar los notebooks en otro entorno. Además, alinea F1 y F2 con el proyecto de ejemplo del curso (módulo `src/`, evaluación del dataset, recursividad, gráficos de control y reflexión técnica) y aplica el formato institucional a este informe.

Las ejecuciones de los notebooks se registran en commits propios, que citan el commit sobre el que se generaron las salidas.

Tabla 5. Historial de commits del avance (52 commits).

Commit	Autor	Fecha	Mensaje
0aa3b95	Francisco Correa	05-11-2026	Initial commit
ed4dffe	Francisco Correa	05-11-2026	add Inventario de Glaciares data
4dac4c9	Francisco Correa	05-11-2026	docs: crear estructura inicial del proyecto
818758c	Francisco Correa	05-11-2026	data: incorpora dataset base en raw y actualizacion del README
025a317	Roberto Gaubert	10-11-2026	docs:Arregle el repositoreo, cree 2 carpetas
1774b5e	Gustavo Aloy	10-11-2026	docs: agregue una nueva carpeta donde se encuentran los datos procesados
c9dcf71	Gustavo Aloy	10-11-2026	update: actualizamos los requerimientos del proyecto
b04b33b	Roberto Gaubert	10-11-2026	update: Se agrego notebook para F1
fe4df0d	Roberto Gaubert	10-11-2026	update:gitignore actualizado

Commit	Autor	Fecha	Mensaje
268cc89	Gustavo Aloy	10-11-2026	update: agregue Notebook F2
2a9446c	Francisco Correa	10-11-2026	docs: se agrego la formativa f1, mapa conceptual
bd6bab7	Francisco Correa	11-11-2026	chore: excluye material de clase y archivos de sistema en .gitignore
cc91431	Francisco Correa	11-11-2026	docs: reescribe README con estructura, entorno y ejecución reales
89fac2a	Francisco Correa	11-11-2026	docs: agrega borrador del informe técnico de la Sumativa 1
e5aa555	Francisco Correa	11-11-2026	feat: completa F1 con verificación de entorno, huella del dataset y vínculo con el mapa
1685df9	Francisco Correa	11-11-2026	docs: registra salidas de F1 ejecutadas sobre el commit e5aa555
b410c60	Francisco Correa	11-11-2026	Merge pull request #1 from fcorreasoto/f1-ajustes
83cb963	Francisco Correa	11-11-2026	refactor: renombra data/processd a data/processed y documenta sus archivos
20d98c7	Francisco Correa	11-11-2026	feat: implementa pipeline completo de F2 según los pasos 6 a 11 del curso
487525d	Francisco Correa	11-11-2026	data: agrega datos procesados y bitácora de decisiones de F2
4e61283	Francisco Correa	11-11-2026	docs: actualiza README con salidas y decisiones de F2
3f066ea	Francisco Correa	11-11-2026	docs: registra salidas de F2 ejecutadas sobre el commit 4e61283
a8a2959	Francisco Correa	11-11-2026	docs: actualiza el informe con el pipeline de F2 y la vinculación del mapa
d22431a	Francisco Correa	11-11-2026	Merge pull request #2 from fcorreasoto/f2-pipeline
6a039a5	Francisco Correa	11-11-2026	fix: hace que las celdas de F2 se puedan re-ejecutar y que corra con pandas 2
5e37ab6	Francisco Correa	11-11-2026	fix: F1 solo se detiene si faltan librerías que los notebooks importan
33d8363	Francisco Correa	11-11-2026	docs: agrega solución de problemas frecuentes al README
7fbfe00	Francisco Correa	11-11-2026	docs: registra salidas de F1 ejecutadas sobre el commit 33d8363
0151e82	Francisco Correa	11-11-2026	docs: registra salidas de F2 ejecutadas sobre el commit 7fbfe00
b632b1a	Francisco Correa	11-11-2026	docs: actualiza el informe con la verificación de robustez y el historial reciente
e8bda81	Francisco Correa	11-11-2026	docs: aplica la plantilla institucional al informe
a34877c	Francisco Correa	11-11-2026	chore: excluye .ipynb_checkpoints en .gitignore
0e86804	Francisco Correa	11-11-2026	feat: agrega módulo compartido src/utilidades.py
25df465	Francisco Correa	11-11-2026	chore: agrega validar_dataset.py, el validador de dataset del curso
9d5a973	Francisco Correa	11-11-2026	feat: alinea F1 con el ejemplo del curso
83ba9b0	Francisco Correa	11-11-2026	feat: alinea F2 con el ejemplo del curso
de37d27	Francisco Correa	11-11-2026	docs: actualiza README con el módulo src/, los artefactos de docs/ y la semilla
629eabc	Francisco Correa	11-11-2026	docs: registra salidas de F1 ejecutadas sobre el commit de37d27
ffc414e	Francisco Correa	11-11-2026	docs: registra salidas de F2 ejecutadas sobre el commit 629eabc
fa06f51	Francisco Correa	11-11-2026	docs: actualiza el informe con el módulo src/, la recursividad, los gráficos de control y la evaluación del dataset
8134481	Francisco Correa	11-11-2026	docs: actualiza el mapa conceptual según la retroalimentación de la Formativa 1
9b290f3	Francisco Correa	11-11-2026	feat: F2 verifica que el espesor y el volumen se estimaron desde el área
ea1642d	Francisco Correa	11-11-2026	feat: alinea F1 con el mapa conceptual v2
b83ca1b	Francisco Correa	11-11-2026	docs: actualiza README con la pregunta acotada, el supuesto del volumen y la licencia
0704059	Francisco Correa	11-11-2026	docs: registra salidas de F1 ejecutadas sobre el commit b83ca1b
d2895c7	Francisco Correa	11-11-2026	docs: registra salidas de F2 ejecutadas sobre el commit 0704059
fcc0311	Francisco Correa	11-11-2026	docs: alinea el informe con el mapa conceptual v2
6f24321	Francisco Correa	11-11-2026	Merge pull request #3 from fcorreasoto/fix-robustez-notebooks
cd4f1de	Francisco Correa	11-11-2026	fix: fix: elimina celda de identidad Git que fallaba en F1

Commit	Autor	Fecha	Mensaje
268492f	Francisco Correa	11-11-2026	Merge pull request #4 from fcorreasoto/fix-robustez-notebooks
a92efbe	Francisco Correa	11-11-2026	docs: quita de F1 las menciones a la celda de trazabilidad eliminada
04ff013	Francisco Correa	11-11-2026	docs: agrega al README la tabla de verificación en un segundo equipo

El historial muestra el avance progresivo: estructura y datos (5 de noviembre); requerimientos, notebooks iniciales y mapa (10 de noviembre); y revisión de F1, pipeline de F2 y documentación (11 de noviembre). Cada commit se hizo desde la cuenta de su autor. 42 de los 52 mensajes siguen la convención. Los que no la siguen (con prefijo `update:` o sin prefijo) son de la primera semana, antes de que la convención quedara declarada en el README; desde entonces todos la siguen, salvo los mensajes automáticos de merge de los Pull Requests.

El archivo `.gitignore` excluye el entorno virtual, las cachés de Python, las variables de entorno (`.env`), archivos de sistema y la carpeta `material/` con el material de clase, que no es de autoría del grupo. Los notebooks se versionan **con sus salidas**, porque son evidencia de ejecución.

3.5 Documentación del proceso

El proceso queda documentado en cuatro niveles coherentes entre sí:

- **Notebooks.** Cada bloque de código va precedido por una celda Markdown que explica qué se hace y por qué. Las funciones tienen docstrings y los comentarios explican las líneas cuya razón no es evidente.
- **Bitácora.** La clase `Bitacora` de F2 registra cada decisión en el momento en que se toma, con su cifra. Se exporta a `docs/bitacora_f2.md` (34 decisiones) y se reproduce en el Anexo B. Este informe usa exactamente las mismas cifras.
- **Artefactos de docs/ generados por los notebooks.** F1 exporta el diccionario de variables con su rol, la evaluación del dataset, la tabla de vinculación con el mapa y los metadatos de ejecución. F2 exporta la bitácora y los metadatos del pipeline. Al generarse desde las mismas estructuras del notebook, no pueden contradecirlo.
- **Repositorio.** El README describe el proyecto, la estructura, las dependencias, la ejecución, las decisiones y la solución de problemas frecuentes. `data/processed/README` describe cada archivo de salida.
- **Informe.** Recoge las decisiones (capítulo 4), los enfoques descartados (secciones 4.2 y 7.1) y la vinculación con el mapa (capítulo 7).

Flujo de datos. Entra `data/raw/Inventario_Publico_de_Glaciares_2022.csv` (26.180 × 45, 9,46 MB). F1 lo lee y lo describe sin modificarlo. F2 lo explora, lo limpia, lo transforma, lo valida y escribe:

- `data/processed/glaciares_limpio.csv` (26.180 × 48);
- `data/processed/glaciares_modelo.csv` (26.180 × 49);
- un perfil de calidad, la bitácora y los metadatos del pipeline.

3.6 Repositorio GitHub

```
proyecto-grupo3-mcdi500/
├── F1/F1_Definicion.ipynb          # Fase 1: definición, entorno y dataset
├── F2/F2_Procesamiento.ipynb       # Fase 2: pasos 6–11 del pipeline
├── src/utilidades.py              # Módulo compartido (importado por F1 y F2)
├── data/
│   ├── raw/                        # CSV original de la DGA (inmutable)
│   └── processed/                  # glaciares_limpio, glaciares_modelo, perfil
├── docs/
│   ├── validacion_dataset.md       # Salida de validar_dataset.py
│   ├── diccionario_variables.csv   # F1: 45 variables con su rol
│   ├── evaluacion_criterios_dataset.csv · vinculacion_mapa_conceptual.csv
│   ├── metadatos_fase1.json · metadatos_proyecto.csv
│   ├── bitacora_f2.md              # Bitácora exportada por F2
│   ├── f1/                         # Mapa conceptual (Formativa 1)
│   └── informe/                    # Este informe (.docx y .pdf)
├── validar_dataset.py              # Validador de dataset del curso
├── requirements.txt                # Dependencias con versión exacta
├── .gitignore
└── README.md                       # Descripción, instalación, ejecución
```

4. Diseño de soluciones algorítmicas

4.1 Codificación funcional

El código sigue cinco principios:

- **Una función por tarea**, con parámetros explícitos y docstring.
- **Ninguna función modifica su entrada:** cada una trabaja sobre `df.copy()` y devuelve un objeto nuevo, y cada etapa del notebook guarda su resultado en una variable propia.
- **Las entradas inválidas producen la excepción correcta** (`ValueError`, `KeyError`, `FileNotFoundError`) en lugar de un resultado silenciosamente erróneo.
- **Las estructuras de control recorren variables y métodos**, en lugar de repetir el mismo bloque.
- **Las constantes del dominio se declaran una sola vez:** órdenes, cortes, ángulos y factores.

Ejemplo: la función de imputación, que admite cuatro métodos y crea la bandera de trazabilidad:

```
def imputar(df, columna, metodo, grupo=None, referencia=None, minimo=0.0):
    if metodo not in METODOS_IMPUTACION:
        raise ValueError(f"Método desconocido: {metodo}")
    df = df.copy()                                    # nunca se modifica la entrada
    nulos = df[columna].isna()
    if metodo == "diferencia":                        # usa una variable observada
        desnivel = df[referencia] - df[columna]
        desnivel_grupo = desnivel.groupby(df[grupo]).transform("median")
        estimado = (df[referencia] - desnivel_grupo).clip(lower=minimo)
    ...                                               # media, mediana, mediana por grupo
    df.loc[nulos, columna] = estimado[nulos]
    df[f"{columna}_IMPUTADO"] = nulos.astype(int)   # bandera: qué filas se imputaron
    return df
```

Módulos y excepciones. Lo que usan varias fases está en `src/utilidades.py`, junto con una excepción propia, `ProyectoError`, que distingue «el dato o el repositorio no son los esperados» de los errores de pandas o scikit-learn. F1 prueba el módulo con 13 casos (4 normales, 5 límite y 4 excepciones) antes de que F2 lo use.

Orientación a objetos. Aparece donde agrupar estado y comportamiento tiene sentido: la clase `Bitacora` acumula las decisiones, valida que cada una tenga evidencia, no las duplica si una celda se re-ejecuta y las exporta.

Recursividad. F2 §7 usa dos funciones recursivas con un propósito real. `aplanar` convierte los metadatos anidados del pipeline (fuente, decisiones con sus parámetros y resultados, hasta 4 niveles) en pares clave-valor exportables, y `profundidad` mide su anidamiento. Un bucle no sirve, porque la profundidad es variable. El caso base es un valor simple o una lista; el caso recursivo, un subdiccionario. Ambas funciones tienen 8 pruebas, incluida una excepción `TypeError`.

4.2 Preprocesamiento y transformación del dataset

La regla aplicada fue **medir primero, decidir después y justificar con la medición** (Salinas, 2026). La Tabla 6 resume el diagnóstico de F2 §2.

Tabla 6. Diagnóstico previo del inventario (F2 §2).

Aspecto	Resultado medido
Dimensiones y duplicados	26.180 × 45; 0 filas duplicadas; COD_GLA único; OBJECTID repetido en 102 filas
Faltantes > 60 %	CUBIERTO y OBSERVACIO 100 %; CH_CASQ 97,24 % (solo 723 glaciares con código)
Valor único	Id (0), DATUM (WGS 84), HUSO (19 SUR), F_ESP_MED (CHEN & OHMURA 1990)
Redundancia	WGI_1 corresponde uno a uno con las 5 clases de CLASIFICA
Asimetría y atípicos	AREA_KM2: asimetría 43,1; media 0,803 vs. mediana 0,036 km²; 14,37 % fuera del IQR. VOL_km3: asimetría 54,0
Fórmula del volumen	VOL/(AREA·ESP/1000) = 1,00 y EQ/VOL = 0,85 en todos los tipos, salvo los rocosos: 0,60 (60 % de hielo) y 0,917
Espesor y área	ESP_MED = a · AREA^b con a = 28,46–28,50 y b = 0,3567–0,3570 en los 5 tipos ($R^2 \geq 0,9985$): fórmula de Chen y Ohmura (1990)
Faltantes encubiertos	362 VOL_km3 = 0 (glaciaretes de 0,001–0,002 km²: redondeo); 668 EQ_AGUAKM3 = 0; 69 HMIN = 0, de ellos 36 en fiordo (plausible) y 33 en tierra o lago
Coherencia física	1 glaciar (CL108116007@, Ñuble) con HMEDIA 2.228 m < HMIN 2.849 m
Categorías	FUENTE_DIG: 'FOTOGRAMETR ├ìA' (codificación) y 'LiDAR ANDINA' (mayúsculas); espacios dobles en NOM_CUEN y NOMBRE
Tipos	LATITUD/LONGITUD como texto con coma decimal; FUEN_FECHA: 26.167 DD/MM/AAAA, 12 solo año, 1 MM/DD/AAAA

Limpieza: decisiones y justificación

Tabla 7. Decisiones de limpieza, alternativas y justificación.

Hallazgo	Decisión	Justificación
CUBIERTO, OBSERVACIO (100 % vacías)	Descartar	Supera el umbral del curso (> 60 %): no hay valores desde los cuales imputar
Id, DATUM, HUSO, F_ESP_MED (valor único)	Descartar; valores en la bitácora	No aportan variación; se conservan como metadato, sin perder información
WGI_1 ≡ CLASIFICA; OBJECTID no único	Descartar	WGI_1 es redundante; OBJECTID no identifica filas. COD_GLA es la clave y se excluye del análisis
CH_CASQ (97,24 % faltante)	Descartar como categoría; crear EN_CAMPO_HIELO (0/1)	El faltante significa «no pertenece a un campo de hielo»: el contenido útil es binario (723 glaciares)
Codificación, mayúsculas y espacios	Normalizar el texto	139 valores corregidos (FUENTE_DIG 6, NOM_CUEN 128, NOMBRE 5); evita contar una misma categoría dos veces en F3
Coordenadas, fechas y códigos con tipo incorrecto	Casting	26.180 coordenadas a float sin pérdida; 26.168 fechas completas y FUEN_ANIO para las 26.180 (1955–2022); 8 columnas de código a texto, porque no son cantidades
362 VOL_km3 = 0 y 668 EQ_AGUAKM3 = 0	Recalcular con la fórmula del inventario + bandera	Es redondeo a 5 decimales (máximo recalculado: $5{,}9 \cdot 10^{-6}$ km³). La fórmula usa datos observados del mismo glaciar; el volumen total cambia en +0,0013 km³
Atípicos de área y volumen	Conservar	Son glaciares reales (por ejemplo, los efluentes de los Campos de Hielo); eliminarlos sesgaría la respuesta

Imputación: comparación de métodos

Se marcaron como faltantes los 33 `HMIN = 0` con frente en tierra o lago (0,13 %) y el `HMEDIA` incoherente. Antes de imputar se compararon las alternativas con tres criterios: el cambio porcentual en la desviación estándar, que mide cuánto reduce la variabilidad cada método; las violaciones de la restricción física `HMIN ≤ HMEDIA`; y la superficie de hielo que se perdería al eliminar filas.

Tabla 8. Comparación de métodos de imputación de HMIN (33 faltantes).

Método	Filas	Desv. estándar	Cambio (%)	Violaciones	Área perdida (km²)
Eliminar filas	26.146	1.260,28	0,0000	0	967,51
Media global	26.179	1.259,48	−0,0630	33	0
Mediana global	26.179	1.259,56	−0,0568	31	0
Mediana por comuna	26.179	1.260,08	−0,0155	14	0
HMEDIA − desnivel mediano por comuna (elegido)	26.179	1.260,24	−0,0029	0	0

Eliminar filas no altera la dispersión, pero descarta glaciares que suman 967,5 km² de hielo. La media y la mediana globales asignan a glaciares patagónicos de baja altitud valores típicos de los Andes centrales: 33 y 31 de ellos quedan por encima de su propia altitud media, lo que es físicamente imposible. La mediana por comuna reduce el problema a 14 casos. El método por diferencia usa la `HMEDIA` observada de cada glaciar: es el único sin violaciones y el que menos modifica la desviación estándar (−0,003 %). La regla de elección se declaró en el código antes de aplicarla, y la bandera `HMIN_IMPUTADO` registra las 33 filas imputadas.

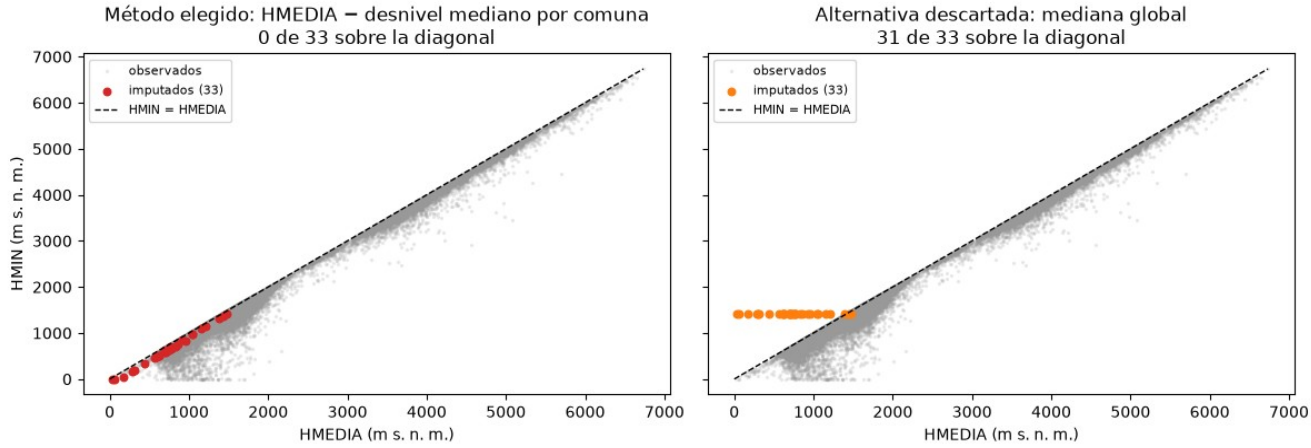


Figura 1. Gráfico de control de la imputación de HMIN (F2 §3.5). Los 33 valores imputados deben quedar bajo la diagonal HMIN = HMEDIA. El método elegido no deja ninguno sobre ella; la mediana global deja 31.

Para el `HMEDIA` del glaciar de Ñuble, la restricción física define el método: el punto medio entre `HMIN` y `HMAX` (2.893 m) respeta `HMIN ≤ HMEDIA ≤ HMAX` por construcción. La mediana global (1.525 m), en cambio, quedaría bajo su `HMIN` de 2.849 m.

Transformación según el tipo de variable

Tabla 9. Tratamiento por rol analítico.

Rol	Variables	Tratamiento y justificación
Numérica continua	AREA_KM2, VOL_km3	log10 → LOG_AREA, LOG_VOL: la asimetría baja de 43,1 a 0,61 (área) y de 54,0 a 0,69 (volumen). Sin el recálculo de los ceros, el log daría −∞
Derivadas	RANGO_ALT, CLASE_TAMANO, FRENTE_AGUA	Desnivel HMAX − HMIN; clases con cortes del dominio (0,01 · 0,1 · 1 · 10 km²); bandera de frente en lago o fiordo
Ordinal	MZON_GLAC, CLASE_TAMANO	Orden declarado NORTE → CENTRO → SUR → AUSTRAL. El alfabético pondría AUSTRAL < CENTRO < NORTE < SUR
Cíclica	ORIENTA	Seno y coseno del ángulo: N (0°) y NW (315°) quedan vecinas; las 3 laderas PLANO quedan en (0, 0)

Rol	Variables	Tratamiento y justificación
Nominal	CLASIFICA, FRENTE_TER, REGION	One-hot: 5 + 3 + 16 columnas binarias
Alta cardinalidad	FUENTE_DIG (19)	Categorías con menos de 1 % de los registros → OTRAS (160 glaciares); quedan 8 categorías → one-hot
Binaria	EN_CAMPO_HIELO, FRENTE_AGUA, banderas	Codificación 0/1
Numérica discreta	INVE_FECHA	Se mantiene numérica: el orden y la distancia entre años tienen significado
Identificador	COD_GLA	Único y sin nulos; se conserva como clave y se excluye del análisis

Escalamiento: comparación de los tres escaladores

Aplicados al área sin logaritmo, los tres escaladores dejan el 99,0 % de los glaciares en el 1 % inferior del rango: **el problema es la asimetría, no el escalador**. Por eso primero se aplica log10 y después se escala. Sobre las seis variables continuas del modelo (`LOG_AREA`, `LOG_VOL`, `HMEDIA`, `RANGO_ALT`, `PENDIENTE`, `ESP_MED`):

Tabla 10. Propiedades de cada escalador (ejemplo: LOG_AREA).

Escalador	Garantiza	Mediana · RIC de LOG_AREA	Riesgo con estos datos
StandardScaler	Media 0, desviación 1	−0,120 · 1,377	La media se desplaza por los valores extremos
MinMaxScaler	Rango [0, 1]	0,264 · 0,194	Depende de dos valores extremos (mínimo y máximo)
RobustScaler (elegido)	Mediana 0, RIC 1	0,000 · 1,000	Las cifras no quedan «redondas»

F2 incluye además dos gráficos de control: el histograma del área antes y después del logaritmo, y los boxplots de las mismas variables con cada escalador. RobustScaler es el único que deja la mediana en 0 y el RIC en 1 sin que los extremos deformen al resto. Se elige **RobustScaler** por coherencia con el resto del pipeline: la misma evidencia que llevó a conservar los atípicos legítimos y a imputar con medianas lleva a descartar la media para centrar.

Resultado e impacto

El pipeline entrega dos conjuntos con las **26.180 filas**; ningún glaciar se elimina:

- **glaciares_limpio.csv (26.180 × 48):** 36 variables originales limpias en sus unidades físicas, la bandera de campo de hielo, el año de la fuente, cuatro banderas de imputación o recálculo y seis variables derivadas. Es la entrada de F3 y F4.
- **glaciares_modelo.csv (26.180 × 49):** matriz 100 % numérica con 2 ordinales, 2 cíclicas, 6 banderas, 6 continuas escaladas y 32 columnas one-hot, más la clave `COD_GLA`.

Las estadísticas de superficie no cambian. Las de volumen cambian en 0,0013 km³ por el recálculo de los ceros, y las de `HMIN` en −0,003 % de desviación estándar.

4.3 Validación técnica y verificación del código

La validación tiene dos partes, ambas ejecutadas en el notebook con sus salidas conservadas como evidencia (F2 §6):

- **Dataset resultante:** 17 comprobaciones, cada una de una **propiedad específica**. `ejecutar_validaciones` las corre todas y reporta OK o FALLA sin detenerse en la primera;

luego un `assert` exige que todas pasen.

- **Funciones del pipeline:** 21 pruebas sobre un mini inventario sintético de cuatro glaciares que reproduce los problemas reales del dataset.
- **Módulo y recursividad:** las 13 pruebas de `src/utilidades.py` en F1 y las 8 de las funciones recursivas en F2. En total, el proyecto ejecuta 42 pruebas de funciones en casos normales, límite y excepciones.

Tabla 11. Validaciones del dataset resultante: 17/17 OK.

Validación	Resultado
Se conservan las 26.180 filas en ambos conjuntos	OK
COD_GLA único, sin nulos y alineado entre conjuntos	OK
Sin filas duplicadas	OK
Sin nulos en las columnas de análisis (limpio) ni en la matriz del modelo	OK (2)
Matriz del modelo 100 % numérica, salvo la clave	OK
Cada grupo one-hot (tipo, frente, región, fuente) suma 1 por fila	OK (4)
Ordinales dentro del rango declarado	OK
RobustScaler: mediana 0 y RIC 1 en las 6 variables	OK
Área, volumen y equivalente en agua positivos	OK
Coherencia altitudinal HMIN ≤ HMEDIA ≤ HMAX en todos los glaciares	OK
Coordenadas dentro del territorio de Chile (−56° a −17°; −76° a −66°)	OK
Banderas coinciden con lo registrado (33 HMIN, 1 HMEDIA, 362 VOL)	OK
data/raw no fue modificado (SHA-256)	OK

Tabla 12. Pruebas de las funciones: 21/21 OK.

Tipo	Pruebas
Casos normales (7)	Conversión de coma decimal; reparación de codificación; fechas en 3 formatos; reconstrucción del volumen con bandera; imputación por diferencia respeta HMIN ≤ HMEDIA; ordinal respeta el orden declarado; la función no modifica su entrada
Casos límite (5)	Imputar una columna sin nulos no cambia nada; one-hot con una sola categoría; RobustScaler sobre una columna constante (RIC = 0); orientación PLANO → (0, 0); funciones sobre un conjunto vacío
Excepciones (9)	Método de imputación desconocido; mediana por grupo sin grupo; escalar con nulos; escalador desconocido; categoría ordinal no declarada; logaritmo de volumen 0; columna inexistente; decisión sin evidencia en la bitácora; ruta sin data/raw → ValueError, KeyError o FileNotFoundError, según corresponda

Los archivos exportados se vuelven a leer y se comprueba que conservan la forma, las columnas y los tipos. En F1, `verificar_f1` comprueba las dimensiones y la unicidad de `COD_GLA`, y `validar_fase1` comprueba la estructura del repositorio, los artefactos del entorno, la definición del problema, la coherencia del diccionario, el módulo importable y los artefactos de `docs/`.

5. Notebook F1_Definicion.ipynb (F1)

`F1/F1_Definicion.ipynb` contiene exclusivamente el alcance de la Fase 1: **no limpia, no imputa y no transforma**. Su última verificación lo deja explícito: «F1 finalizada: no se modificó ni exportó el inventario».

Tabla 13. Estructura del notebook F1.

§	Contenido	Evidencia
1–3	Diccionario PROYECTO: problemática, pregunta, objetivos, alcance, restricciones y supuestos	Fuente única para el notebook, el README y el informe
4	Repositorio, módulo compartido y verificación del dataset (pasos 2 y 3)	src/utilidades.py importado; semilla 42; huella SHA-256 = referencia
4.1	Pruebas del módulo	13/13 OK: 4 normales, 5 límite, 4 excepciones
5	Verificación del entorno reproducible (paso 1)	Tabla de herramientas; kernel en .venv; 7 librerías vs. requirements.txt: 7 OK
6	Reconocimiento inicial: dimensiones, tipos inferidos y roles analíticos	26.180 × 45; 16 variables prioritarias presentes
7	Diccionario de las 45 variables (paso 4) y señales de calidad	Diccionario con assert de completitud; ceros y variantes de categorías; decisiones pendientes para F2
7.2	Ficha del conjunto y evaluación contra los criterios del curso	Rol analítico por variable; obligatorios OK y 2 avisos
8	Correspondencia con las fases y vinculación con el mapa conceptual	Tabla con los 6 tipos de elemento verificada con assert y exportada
9	Persistencia y validación de la fase	4 artefactos en docs/; validar_fase1 [OK]
10	Reflexión técnica	Hallazgos, dificultades y decisiones abiertas

6. Notebook ejecutable de la Fase 2

`F2/F2_Procesamiento.ipynb` sigue los pasos 6 a 11 del curso. Importa el módulo `src/utilidades.py` y fija la semilla. Cada etapa abre con una celda narrativa que explica su lógica y cierra con resultados intermedios verificables, registrados en la bitácora.

Tabla 14. Estructura del notebook F2.

§	Etapa	Resultado intermedio verificable
0–1	Entorno, bitácora y obtención	Versiones y kernel; huella SHA-256 = referencia; `original` inmutable
2	Exploración y medición (paso 6)	Perfil, columnas sin información, asimetría, ceros, IQR, fórmula del volumen, categorías y fechas; 17 hallazgos
3	Limpieza e imputación (paso 7)	45 → 37 columnas; 139 textos corregidos; casting; 362 + 668 recálculos; 5 métodos comparados para HMIN; gráfico de control
4	Transformación por tipo (paso 8)	Derivadas, ordinales, seno/coseno y 32 columnas one-hot; histograma antes y después del log
5	Escalamiento (paso 9)	Comparación de los tres escaladores con boxplots; RobustScaler
6	Validación y pruebas (paso 10)	17/17 validaciones y 21/21 pruebas OK
7	Recursividad	aplanar y profundidad: 4 niveles → 31 pares clave-valor; 8 pruebas OK
8	Persistencia y bitácora (paso 11)	2 CSV releídos y verificados; bitácora de 34 decisiones; metadatos en docs/

§	Etapa	Resultado intermedio verificable
9–10	Trazabilidad y reflexión técnica	Rama y commit de la ejecución; hallazgos, dificultades y decisiones abiertas

7. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual de la Formativa 1 se actualizó a una **versión 2** según la retroalimentación docente. La pregunta se acotó a la concentración del volumen; se agregó el supuesto verificado de que el volumen se estimó desde el área; se declaró la licencia; cada herramienta quedó conectada con la etapa en que interviene; y la letra quedó en 11,5 pt reales. El mapa organiza el proyecto en cinco bloques: A, contexto y pregunta; B, ciclo de vida del dato con las herramientas de cada etapa; C, herramientas transversales; D, repositorio y protocolo de colaboración; y E, documentación científica reproducible. La Tabla 15, generada por F1 §8 y exportada a `docs/vinculacion_mapa_conceptual.csv`, contrasta cada elemento con su implementación y cubre los seis tipos de elemento: herramientas, procesos, flujo reproducible, decisiones técnicas, organización del repositorio y estructura del notebook.

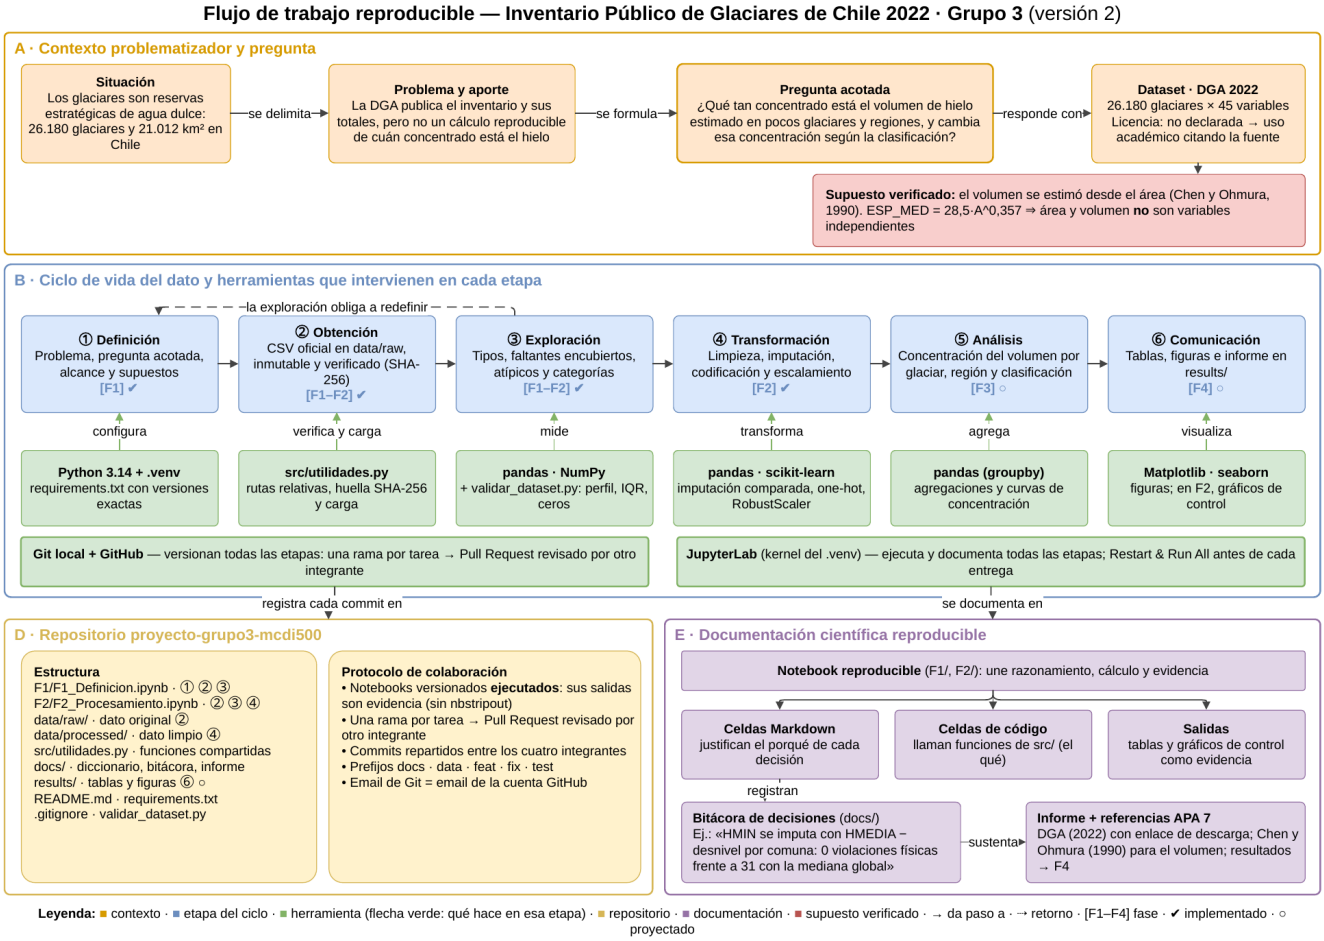


Figura 2. Mapa conceptual v2 del flujo de trabajo reproducible (Formativa 1, ajustado según la retroalimentación docente). El original en A3 está en docs/f1/mcdi500_s1_grupo3.pdf.

Tabla 15. Correspondencia entre el mapa conceptual y el avance.

Elemento del mapa	Tipo	Estado	Evidencia
A · Situación, problema y aporte frente a la DGA	Proceso	Implementado	§1–3: PROYECTO['problematica']; README
A · Pregunta acotada: concentración del volumen y su variación por clasificación	Proceso	Implementado	§2: PROYECTO['pregunta']

Elemento del mapa	Tipo	Estado	Evidencia
A · Dataset DGA 2022 con licencia declarada	Flujo reproducible	Implementado	§7.2: FICHA y evaluación del dataset
A · Supuesto verificado: el volumen se estimó desde el área	Decisión técnica	Implementado	F2 §2.3: ESP_MED = 28,5·A^0,357; §1 supuestos
B① Definición	Proceso	Implementado	§1–3
B② Obtención: CSV en data/raw verificado con SHA-256	Flujo reproducible	Implementado	§4: verificar_huella
B③ Exploración: faltantes encubiertos, atípicos y categorías	Proceso	Implementado	§6–7 (descriptiva); F2 §2
B④ Transformación → data/processed	Proceso	Implementado en F2	F2 §3–8; data/processed/
B⑤ Análisis de concentración · B⑥ Comunicación	Proceso	Proyectado (F3–F4)	—
C · Python + .venv + requirements.txt → ① configura	Herramienta	Implementado	§5: kernel y versiones verificadas
C · src/utilidades.py → ② verifica y carga	Herramienta	Implementado	§4: módulo importado y probado (13 casos)
C · pandas · NumPy + validar_dataset.py → ③ mide	Herramienta	Implementado	§6–7; F2 §2; docs/validacion_dataset.md
C · pandas · scikit-learn → ④ transforma	Herramienta	Implementado en F2	F2 §3–5
C · pandas (groupby) → ⑤ agrega	Herramienta	Proyectado (F3)	—
C · Matplotlib · seaborn → ⑥ visualiza	Herramienta	Parcial: gráficos de control en F2; figuras en F4	F2 §3.5, §4, §5
C · Git + GitHub y JupyterLab (transversales)	Herramienta	Implementado	Historial de Git; Pull Requests #1 a #4
D · Estructura: F1/, F2/, data/, src/, docs/ en la raíz	Organización del repositorio	Implementado	§9: validar_fase1
D · results/ (tablas y figuras)	Organización del repositorio	Proyectado (F4)	—
D · Protocolo: notebooks ejecutados, rama + PR, commits por integrante	Decisión técnica	Implementado	Historial de Git y README
E · Notebook: Markdown + código + salidas	Estructura del notebook	Implementado	Narrativa antes de cada bloque en F1 y F2
E · Bitácora de decisiones con cifras	Documentación	Implementado	docs/bitacora_f2.md
E · Informe + referencias APA 7 (DGA con enlace)	Documentación	Implementado	docs/informe/; §7.2

7.1 Justificación de la relación entre planificación e implementación

Lo implementado corresponde a las etapas que el mapa asignó a F1 y F2 (①–④) y a las herramientas que intervienen en ellas. Las decisiones proyectadas se materializaron, entre ellas eliminar `CUBIERTO`, convertir las coordenadas, el módulo `src/`, la convención de commits y el trabajo en ramas con Pull Request. Respecto de la primera versión del mapa hay cuatro cambios, y cada uno responde a evidencia o a la retroalimentación:

- **notebooks/ → F1/ y F2/.** El entregable exige carpetas por fase.
- **nbstripout → no se usa en la entrega.** La rúbrica evalúa las salidas como evidencia de ejecución.
- **El volumen se reconstruye en lugar de imputarse.** El mapa no anticipaba los ceros de

volumen; la exploración mostró que son redondeo y que el inventario usa una fórmula reproducible.

- **La pregunta se acotó a la concentración del volumen**, y su interpretación incorpora el supuesto verificado de que el volumen se estimó desde el área (Chen y Ohmura, 1990).

Lo proyectado sigue siendo pertinente. El análisis de concentración (⑤) y la comunicación (⑥) son el objeto de F3 y F4, y parten de `glaciares_limpio.csv`. `src/` crecerá cuando F3 reutilice las funciones de imputación, codificación y escalamiento de F2, y `results/` se creará cuando existan tablas y figuras que comunicar.

8. Síntesis del avance y próximos pasos

El avance entrega:

- un entorno reproducible con versiones verificadas;
- un repositorio organizado por fase y trabajado en ramas, con un módulo compartido (`src/utilidades.py`) que evita duplicar funciones;
- un pipeline que convierte el inventario original en dos conjuntos validados (17/17 validaciones y 42 pruebas de funciones), con gráficos de control y metadatos exportados mediante recursividad, sin eliminar ningún glaciar y sin modificar el archivo fuente.

Los hallazgos más relevantes del proceso fueron:

- los **faltantes encubiertos**: volúmenes y altitudes en 0 que no figuraban como nulos;
- la **fórmula diferenciada del volumen** en los glaciares rocosos;
- la **asimetría extrema** de las magnitudes, que condicionó de forma coherente la imputación y el escalamiento.

Próximos pasos. En F3 se medirá la concentración del volumen y de la superficie (participación de los glaciares mayores y curvas de concentración por región, macrozona y clasificación), declarando que el volumen deriva del área. Las funciones de F2 que se reutilicen se trasladarán a `src/`. En F4 se comunicará si la concentración cambia según la clasificación.

Bibliografía

Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book/es/v2

Chen, J., & Ohmura, A. (1990). Estimation of Alpine glacier water resources and their change since the 1870s. *IAHS Publication, 193*, 127–135.

Dirección General de Aguas. (2022). *Inventario público de glaciares de Chile 2022* [Conjunto de datos]. Ministerio de Obras Públicas. https://dga.mop.gob.cl/inventario-publico-glaciares/

Dussaillant, I., Berthier, E., Brun, F., Masiokas, M., Hugonnet, R., Favier, V., Rabatel, A., Pitte, P., & Ruiz, L. (2019). Two decades of glacier mass loss along the Andes. *Nature Geoscience, 12*(10), 802–808. https://doi.org/10.1038/s41561-019-0432-5

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hugonnet, R., McNabb, R., Berthier, E., Menounos, B., Nuth, C., Girod, L., Farinotti, D., Huss, M., Dussaillant, I., Brun, F., & Kääb, A. (2021). Accelerated global glacier mass loss in the early twenty-first century. *Nature, 592*(7856), 726–731. https://doi.org/10.1038/s41586-021-03436-z

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B., Bussonnier, M., Frederic, J., Kelley, K., Hamrick, J., Grout, J., Corlay, S., Ivanov, P., Avila, D., Abdalla, S., Willing, C., & Jupyter Development Team. (2016). Jupyter Notebooks: A publishing format for reproducible computational workflows. En F. Loizides & B. Schmidt (Eds.), *Positioning and power in academic publishing: Players, agents and agendas* (pp. 87–90). IOS Press. https://doi.org/10.3233/978-1-61499-649-1-87

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3.ª ed.). O'Reilly Media. https://wesmckinney.com/book/

pandas development team. (2026). *pandas: User guide* (Versión 3.1) [Documentación de software]. https://pandas.pydata.org/docs/user_guide/index.html

Pimentel, J. F., Murta, L., Braganholo, V., & Freire, J. (2021). Understanding and improving the quality and reproducibility of Jupyter notebooks. *Empirical Software Engineering, 26*(4), Artículo 65. https://doi.org/10.1007/s10664-021-09961-9

Python Software Foundation. (2026). *hashlib — Secure hashes and message digests* [Documentación de software]. https://docs.python.org/3/library/hashlib.html

Salinas, O. (2026). *Programación para la ciencia de datos: Semana 1* [Diapositivas de clase, MCDI500]. Universidad Andrés Bello.

Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLOS Computational Biology, 9*(10), Artículo e1003285. https://doi.org/10.1371/journal.pcbi.1003285

scikit-learn developers. (2026). *Preprocessing data* (Versión 1.9) [Documentación de software]. https://scikit-learn.org/stable/modules/preprocessing.html

Universidad Andrés Bello. (2026). *Guía de desarrollo: Evaluación Sumativa 1 (Fases 1 y 2)* [Documento de apoyo, MCDI500].

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology, 13*(6), Artículo e1005510. https://doi.org/10.1371/journal.pcbi.1005510

Anexo A. Perfil de las 45 variables originales

Tipo leído por pandas 3.1.1, rol analítico asignado en el diccionario de F1 (§7), valores únicos y porcentaje de faltantes sobre 26.180 registros.

Variable	Tipo	Rol analítico	Únicos	% faltante
OBJECTID	int64	Identificador técnico	26.078	0,00
Id	int64	Identificador auxiliar (constante)	1	0,00
COD_GLA	str	Identificador principal	26.180	0,00
NOMBRE	str	Descriptiva	431	0,00
CLASIFICA	str	Categórica principal	5	0,00
AREA_KM2	float64	Numérica principal	2.323	0,00
REGION	str	Categórica principal	16	0,00
PROVINCIA	str	Categórica	40	0,00
COMUNA	str	Categórica	84	0,00
DATUM	str	Metadato espacial	1	0,00
HUSO	str	Metadato espacial	1	0,00
NORTE	int64	Espacial	25.948	0,00
ESTE	int64	Espacial	24.677	0,00
FUENTE_DIG	str	Metadato	19	0,00
FUEN_FECHA	str	Metadato temporal	264	0,00
INVE_FECHA	int64	Metadato temporal	5	0,00
NOM_CUEN	str	Categórica principal	55	0,00
COD_CUEN	int64	Código categórico	55	0,00
COD_SCUEN	int64	Código categórico	179	0,00
COD_SSCUEN	int64	Código categórico	484	0,00
MZON_GLAC	str	Categórica principal	4	0,00
CH_CASQ	str	Categórica complementaria	6	97,24
CUBIERTO	float64	Por evaluar (vacía)	0	100,00
LATITUD	str	Espacial	26.180	0,00
LONGITUD	str	Espacial	26.180	0,00
PERIMETRO	float64	Numérica complementaria	6.757	0,00
ORIENTA	str	Categórica complementaria	9	0,00
HMEDIA	float64	Numérica complementaria	25.996	0,00
HMAX	float64	Numérica complementaria	4.441	0,00
HMIN	float64	Numérica complementaria	4.492	0,00
PENDIENTE	float64	Numérica complementaria	16.897	0,00
ESP_MED	float64	Numérica complementaria	14.779	0,00
F_ESP_MED	str	Metadato metodológico	1	0,00
VOL_km3	float64	Numérica principal	3.441	0,00
EQ_AGUAKM3	float64	Numérica principal	3.262	0,00
WGI_1	int64	Código categórico	5	0,00
WGI_2	int64	Código categórico	10	0,00
WGI_3	int64	Código categórico	15	0,00

Variable	Tipo	Rol analítico	Únicos	% faltante
FRENTE_TER	str	Categórica complementaria	3	0,00
RESOL_IMG	float64	Metadato técnico	14	0,00
ERROR	float64	Técnica	7.378	0,00
OBSERVACIO	float64	Por evaluar (vacía)	0	100,00
CUT_REG	int64	Código categórico	16	0,00
CUT_PROV	int64	Código categórico	40	0,00
CUT_COM	int64	Código categórico	84	0,00

Anexo B. Bitácora de decisiones de la Fase 2

Generada automáticamente por la clase `Bitacora` del notebook F2 y exportada a `docs/bitacora_f2.md` (34 decisiones). Se reproduce sin edición.

#	Etapa	Decisión	Evidencia
1	obtención	Se carga el CSV oficial desde data/raw sin modificarlo	26,180 filas × 45 columnas; SHA-256 5691de5d7d7f… = referencia
2	exploración	Id no aporta información (valor único)	0.0 % faltante; 1 valor(es) único(s); valor = 0
3	exploración	DATUM no aporta información (valor único)	0.0 % faltante; 1 valor(es) único(s); valor = WGS 84
4	exploración	HUSO no aporta información (valor único)	0.0 % faltante; 1 valor(es) único(s); valor = 19 SUR
5	exploración	CH_CASQ no aporta información (faltantes > 60%)	97.24 % faltante; 6 valor(es) único(s)
6	exploración	CUBIERTO no aporta información (faltantes > 60%)	100.0 % faltante; 0 valor(es) único(s)
7	exploración	F_ESP_MED no aporta información (valor único)	0.0 % faltante; 1 valor(es) único(s); valor = CHEN & OHMURA 1990
8	exploración	OBSERVACIO no aporta información (faltantes > 60%)	100.0 % faltante; 0 valor(es) único(s)
9	exploración	COD_GLA es el identificador; OBJECTID no identifica filas	COD_GLA único en 26,180 filas; OBJECTID repetido en 102 filas; 0 filas duplicadas
10	exploración	Área y volumen son muy asimétricos, con atípicos legítimos	AREA_KM2: asimetría 43.1, media 0.803 vs. mediana 0.036 km², 14.37 % fuera del IQR; VOL_km3: asimetría 54.0
11	exploración	VOL_km3 = 0 es redondeo, no ausencia de hielo	362 glaciaretes de área ≤ 0,002 km²; la fórmula reproduce el volumen (razón mediana 0.9999; rocosos 0.6 = 60 % de hielo)
12	exploración	El espesor y el volumen se estimaron desde el área (Chen y Ohmura, 1990)	ESP_MED = 28,5·AREA^0,357 en los 5 tipos (a entre 28.464 y 28.502, b entre 0.3567 y 0.357, R² ≥ 0.9985); área y volumen no son variables independientes
13	exploración	EQ_AGUAKM3 es una proporción fija de VOL_km3 según el tipo	EQ/VOL mediana 0.85 (850 kg/m³) y 0.917 en rocosos; 668 ceros por redondeo
14	exploración	HMIN = 0 con frente en tierra o lago es un faltante encubierto	69 glaciares con HMIN = 0: 36 en fiordo (plausible) y 33 en tierra/lago (implausible)
15	exploración	Un glaciar viola HMIN ≤ HMEDIA ≤ HMAX	CL108116007@ (ÑUBLE): HMEDIA 2,228 m < HMIN 2,849 m
16	exploración	WGI_1 duplica la información de CLASIFICA	correspondencia uno a uno entre las 5 clases y los códigos WGI_1: True
17	exploración	Revisión de categorías: codificación, mayúsculas, espacios y variantes	NOMBRE: 'VOLCAN PLANCHON PETEROA' (espacios irregulares); FUENTE_DIG: 'LiDAR ANDINA' (mayúsculas inconsistentes); FUENTE_DIG: 'FOTOGRAMETR ├ìA' (codificación de caracteres); NOM_CUEN: 'COSTERAS ENTRE LAG. BLANCA(INC), SENO OTWAY, CANAL JERONIMO Y MAGALLANES' (espacios irregulares)
18	exploración	FUEN_FECHA mezcla formatos; LATITUD/LONGITUD son texto con coma decimal	DD/MM/AAAA: 26,167, AAAA: 12, MM/DD/AAAA: 1; ejemplo LATITUD '-18,1744803305003'
19	limpieza	Se descartan 9 columnas: Id, DATUM, HUSO, CUBIERTO, F_ESP_MED, OBSERVACIO, WGI_1, OBJECTID, CH_CASQ	100 % vacías (CUBIERTO, OBSERVACIO), valor único (Id, DATUM = WGS 84, HUSO = 19 SUR, F_ESP_MED = CHEN & OHMURA 1990), redundante (WGI_1 ≡ CLASIFICA), sin unicidad (OBJECTID), CH_CASQ > 60 % faltante (45 → 36 columnas originales)
20	limpieza	CH_CASQ se convierte en la bandera binaria EN_CAMPO_HIELO	el faltante significa 'no pertenece'; 723 glaciares pertenecen a un campo de hielo o casquete
21	limpieza	Se normaliza el texto (codificación, mayúsculas y espacios)	139 valores corregidos (NOMBRE: 5, FUENTE_DIG: 6, NOM_CUEN: 128): 'FOTOGRAMETR ├ìA' → 'FOTOGRAMETRÍA', 'LiDAR ANDINA' → 'LIDAR ANDINA' y espacios dobles en nombres
22	limpieza	Casting: LATITUD/LONGITUD a float, FUEN_FECHA a fecha + FUEN_ANIO, códigos a texto	26,180 coordenadas convertidas sin pérdida; 26,168 fechas completas y 26,180 años (1955–2022); 8 columnas de código a texto
23	limpieza	Se recalculan los ceros de VOL_km3 y EQ_AGUAKM3 con la fórmula del inventario	362 volúmenes y 668 equivalentes; volumen total +0.001333 km³ (despreciable); banderas VOL/EQ_RECALCULADO

#	Etapa	Decisión	Evidencia
24	imputación	HMIN = 0 en tierra/lago se marca como faltante e imputa con 'HMEDIA − desnivel mediano por comuna'	33 valores (0.13 %); cambio de desv. estándar -0.0029 %; violaciones de HMIN ≤ HMEDIA: media global 33, mediana global 31, mediana por comuna 14, HMEDIA − desnivel mediano por comuna 0; eliminar filas perdería 967.5 km² de hielo
25	imputación	HMEDIA incoherente se reemplaza por (HMIN + HMAX) / 2	1 glaciar; la mediana global (1,525 m) violaría HMIN ≤ HMEDIA; el punto medio da 2,893 m
26	transformación	Se derivan RANGO_ALT, LOG_AREA, LOG_VOL, CLASE_TAMANO, FRENTE_AGUA y FUENTE_GRUPO	log10 reduce la asimetría del área de 43.1 a 0.61 y del volumen de 54.0 a 0.69; cortes de tamaño [0.01, 0.1, 1, 10] km²
27	transformación	MZON_GLAC y CLASE_TAMANO se codifican como ordinales con orden declarado	orden geográfico NORTE → AUSTRAL; el alfabético pondría AUSTRAL < CENTRO < NORTE < SUR
28	transformación	ORIENTA se codifica con seno y coseno	variable circular (N = 0°, NW = 315° son vecinas); 3 laderas PLANO → (0, 0)
29	transformación	One-hot para CLASIFICA, FRENTE_TER, REGION y FUENTE_GRUPO	nominales sin orden; 32 columnas binarias; FUENTE_DIG: 19 → 8 categorías (< 1 % → OTRAS)
30	escalamiento	Se usa RobustScaler (mediana 0, RIC 1) sobre 6 variables continuas	LOG_AREA, LOG_VOL, HMEDIA, RANGO_ALT, PENDIENTE, ESP_MED; coherente con la imputación por mediana y con los atípicos legítimos; sobre el área sin log, MinMax deja el 99.0 % de los datos en el 1 % inferior del rango
31	validación	Se ejecutan 17 validaciones del dataset resultante	17/17 OK: filas, clave, nulos, tipos, one-hot, ordinales, RobustScaler, reglas físicas, banderas y huella de data/raw
32	validación	Se ejecutan 21 pruebas de las funciones	21/21 OK: 7 casos normales, 5 casos límite y 9 excepciones
33	documentación	Los metadatos del pipeline se aplanan con una función recursiva	4 niveles de anidamiento → 34 pares clave-valor en docs/metadatos_proyecto.csv; 8 pruebas OK (normales, límite y excepción)
34	persistencia	Se guardan y releen glaciares_limpio.csv y glaciares_modelo.csv en data/processed	limpio 26180×48 y modelo 26180×49; forma, columnas y tipos comprobados tras releer; data/raw intacto

Anexo C. Evaluación del dataset contra los criterios del curso

Generada por `evaluar_criterios` en F1 §7.2 y exportada a `docs/evaluacion_criterios_dataset.csv`, con los umbrales de `validar_dataset.py` más dos requisitos de la presentación de la Semana 1. OK: cumple; AVISO: no descalifica el conjunto y se declara como restricción (sección 2.5).

Estado	Tipo	Requisito	Detalle
OK	obligatorio	Al menos 2000 filas	26,180 filas
OK	obligatorio	Al menos 12 columnas	45 columnas
OK	obligatorio	Combina al menos 3 roles analíticos	alta cardinalidad, continua, discreta, fecha, nominal, ordinal
OK	obligatorio	Al menos una variable numérica	16 (continuas o discretas)
OK	obligatorio	Al menos una variable categórica	10 (nominales, binarias u ordinales)
OK	aviso	Presencia de valores faltantes (≥ 1 %)	máximo 100.0 %
AVISO	aviso	Ninguna variable sobre 60 % de faltantes	CH_CASQ, CUBIERTO, OBSERVACIO
OK	aviso	Incluye alguna variable de fecha	1 detectada(s)
OK	aviso	Incluye texto o alta cardinalidad	10 detectadas
OK	aviso	Archivo bajo 100 MB	9.46 MB
OK	aviso	Sin filas duplicadas exactas	0 duplicadas
AVISO	aviso	Licencia abierta y fuente verificable	fuente oficial verificable; licencia no declarada
OK	aviso	Datos de los últimos cinco años	publicado en 2022