# MCDI500

# PROGRAMACIÓN PARA LA CIENCIA DE DATOS

# AVANCE DEL PROYECTO FASES 1 Y 2

## Análisis reproducible del Inventario Público de Glaciares de Chile 2022

**Nombre integrante/s:** Francisco Correa Soto, Gustavo Aloy Angella y Roberto Gaubert Urbina (Grupo 3)

**Curso:** MCDI500 Programación para la Ciencia de Datos — Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello

**Fecha:** 15 de noviembre de 2026

**Docente:** Dr. Omar Salinas Silva

**Repositorio:** https://github.com/fcorreasoto/proyecto-grupo3-mcdi500

# Índice

1. Introducción y contextualización....3
1.1 Contexto del proyecto....3
1.2 Situación que origina el análisis y presentación del problema....3
1.3 Propósito general y alcance del informe....3
1.4 Justificación técnica....4
1.5 Conexión con las fases F1–F4....4
2. Definición de la problemática y objetivos del proyecto....5
2.1 Formulación de la problemática....5
2.2 Preguntas centrales del análisis....5
2.3 Objetivos....5
2.4 Alcance del proyecto....6
2.5 Restricciones....6
2.6 Supuestos relevantes....6
2.7 Articulación con las fases....7
3. Aplicación de herramientas científicas....8
3.1 Ecosistema utilizado....8
3.2 Integración en el flujo de trabajo....8
3.3 Reproducibilidad técnica....9
3.4 Control de versiones....10
3.5 Documentación del proceso....13
3.6 Repositorio GitHub....14
4. Diseño de soluciones algorítmicas....15
4.1 Codificación funcional....15
4.2 Preprocesamiento y transformación del dataset....15
4.3 Validación técnica y verificación del código....19
5. Notebook F1_Definicion.ipynb (F1)....21
6. Notebook ejecutable de la Fase 2....21
7. Vinculación del mapa conceptual con el avance del proyecto....23
7.1 Justificación de la relación entre planificación e implementación....24
8. Síntesis del avance y próximos pasos....25
Bibliografía....26
Anexo A. Perfil de las 45 variables originales....28
Anexo B. Bitácora de decisiones de la Fase 2....30
Anexo C. Evaluación del dataset contra los criterios del curso....32

# 1. Introducción y contextualización

## 1.1 Contexto del proyecto

Chile concentra una de las mayores superficies glaciares del hemisferio sur fuera de la Antártica. Los glaciares son reservas estratégicas de agua dulce: en las zonas norte y central sostienen el caudal de los ríos durante los meses secos y los años de sequía, y en la Patagonia forman los Campos de Hielo Norte y Sur. La evidencia reciente muestra que los glaciares andinos pierden masa de forma sostenida (Dussaillant et al., 2019) y que la pérdida de hielo a escala global se aceleró durante el siglo XXI (Hugonnet et al., 2021). En ese escenario, saber dónde están los glaciares y cuánta agua almacenan es una condición previa para cualquier decisión de gestión hídrica.

La Dirección General de Aguas (DGA) publica el **Inventario Público de Glaciares de Chile 2022**, un catastro oficial que en su versión CSV contiene **26.180 glaciares y 45 variables**: ubicación administrativa e hidrográfica, clasificación, superficie, altitudes, pendiente, espesor medio y volumen estimado (Dirección General de Aguas [DGA], 2022). Es la única fuente de datos del proyecto.

## 1.2 Situación que origina el análisis y presentación del problema

El inventario existe, pero no es directamente analizable. El reconocimiento de F1 y la exploración de F2 mostraron varios problemas:

- **Columnas sin información:** dos columnas vacías (`CUBIERTO` y `OBSERVACIO`) y una con 97,24 % de faltantes (`CH_CASQ`).
- **Formatos que impiden el cálculo:** coordenadas leídas como texto por la coma decimal y fechas en tres formatos.
- **Texto inconsistente:** categorías con la codificación de caracteres rota y espacios dobles.
- **Faltantes encubiertos:** valores que no figuran como nulos pero lo son, como 33 altitudes mínimas registradas en 0 m en glaciares que no llegan al mar y 362 volúmenes en 0 por redondeo.
- **Magnitudes muy asimétricas:** la superficie media es 0,80 km², la mediana 0,036 km² y el máximo 772,5 km².

Si el procedimiento para leer, limpiar y resumir el archivo no es transparente, nadie puede verificar las cifras que se obtengan. La DGA publica el inventario y sus totales, pero no un cálculo reproducible de **cuán concentrado está el hielo**, que es el foco de este proyecto. El problema es, por tanto, doble: **medir esa concentración y su variación entre tipos de glaciar**, y hacerlo con un **flujo reproducible** que cualquier persona pueda ejecutar desde el repositorio y obtener el mismo resultado.

## 1.3 Propósito general y alcance del informe

**Objetivo general.** Medir, mediante un flujo reproducible en Python, cuán concentrados están el volumen estimado y la superficie de los glaciares de Chile en pocos glaciares y regiones, y cómo varía esa concentración según la clasificación del glaciar.

**Alcance de este informe.** Este avance documenta las Fases 1 y 2: la definición del problema y la configuración del entorno reproducible (F1) y la obtención, exploración, limpieza, transformación y validación del inventario (F2). Los resúmenes territoriales (F3) y las visualizaciones y la comunicación de

resultados (F4) se presentan como trabajo proyectado.

## 1.4 Justificación técnica

Con 26.180 registros, 45 variables y decisiones que dependen de cifras (cuántos faltantes, qué método de imputación deforma menos la distribución, qué escalador corresponde a los datos), el trabajo no puede hacerse de forma manual ni en una planilla sin perder trazabilidad. Programar el proceso en Python permite:

- encapsular cada paso en funciones reutilizables y probadas;
- justificar cada decisión con evidencia calculada en el mismo documento, gracias a los notebooks de Jupyter (Kluyver et al., 2016);
- versionar el proceso completo con Git, para reconstruir qué cambió, cuándo y quién lo hizo (Chacon & Straub, 2014);
- entregar a las fases siguientes un conjunto validado.

El equipo sigue las prácticas de computación científica de Wilson et al. (2017) y Sandve et al. (2013), la recomendación de mantener notebooks ejecutables de principio a fin (Pimentel et al., 2021) y la ruta de doce pasos propuesta en el curso (Salinas, 2026), con los criterios de la guía de desarrollo de la evaluación (Universidad Andrés Bello, 2026).

## 1.5 Conexión con las fases F1–F4

**Tabla 1. Aporte de cada fase a la solución del problema.**

| Fase | Propósito | Producto | Estado |
|---|---|---|---|
| F1 · Definición | Delimitar problema, pregunta y objetivos; configurar y verificar el entorno; reconocer el inventario sin modificarlo | F1/F1_Definicion.ipynb, README, requirements.txt | Implementada |
| F2 · Preparación | Explorar, limpiar, imputar, transformar, escalar y validar el inventario | F2/F2_Procesamiento.ipynb, data/processed/, docs/bitacora_f2.md | Implementada |
| F3 · Análisis | Medir la concentración del volumen y la superficie por glaciar, región y clasificación | Notebook F3, tablas y curvas de concentración | Proyectada (semana 2) |
| F4 · Comunicación | Comunicar si la concentración cambia según la clasificación | Figuras, informe final y presentación | Proyectada (semana 3) |

# 2. Definición de la problemática y objetivos del proyecto

## 2.1 Formulación de la problemática

El fenómeno analizado es la **concentración de la masa glaciar de Chile**: qué fracción del volumen de hielo estimado (`VOL_km3`) y de la superficie (`AREA_KM2`) reúnen unos pocos glaciares y regiones, y si esa concentración difiere entre los 5 tipos de glaciar (`CLASIFICA`), las 16 regiones (`REGION`) y las 4 macrozonas (`MZON_GLAC`). El problema técnico consiste en transformar el inventario original en un conjunto confiable en el que esas magnitudes puedan agregarse sin sesgos introducidos por errores de formato, faltantes encubiertos o inconsistencias, y sin alterar el archivo fuente. **El volumen no es una medición independiente:** el inventario lo estimó desde el área (sección 2.6), y el análisis lo declara como supuesto.

## 2.2 Preguntas centrales del análisis

**Pregunta de investigación:** ¿qué tan concentrado está el volumen de hielo estimado en pocos glaciares y regiones, y cambia esa concentración según la clasificación del glaciar? Se desagrega en:

- ¿Qué fracción del volumen y de la superficie reúnen el 1 % y el 10 % de los glaciares de mayor tamaño? La exploración anticipa un valor extremo: el 1 % reúne el 93,8 % del volumen (F2 sección 2.2.1).
- ¿Qué regiones y macrozonas concentran el volumen? Magallanes y Aysén reúnen el 97,9 % (F2 sección 2.2.1).
- ¿Cambia esa concentración entre glaciaretes y glaciares de montaña, rocosos, de valle y efluentes?
- Pregunta técnica de F2: ¿qué problemas de calidad presenta el inventario y cómo tratarlos sin perder ni inventar información?

## 2.3 Objetivos

**Objetivo general.** Medir, mediante un flujo reproducible en Python, cuán concentrados están el volumen estimado y la superficie de los glaciares de Chile en pocos glaciares y regiones, y cómo varía esa concentración según la clasificación del glaciar.

**Tabla 2. Objetivos específicos, fase e indicador de cumplimiento.**

| Objetivo específico | Fase | Indicador verificable |
|---|---|---|
| OE1. Verificar la estructura, la calidad y el rol analítico de las 45 variables, y que el volumen se estimó desde el área. | F1–F2 | Diccionario de 45 variables (F1 sección 7); 18 hallazgos de F2 sección 2, incluida la fórmula de Chen y Ohmura verificada |
| OE2. Documentar y ejecutar la limpieza y transformación del inventario sin modificar el archivo original. | F2 | Datos en data/processed/, 17/17 validaciones, 23/23 pruebas y huella SHA-256 del archivo raw sin cambios |
| OE3. Calcular la concentración del volumen y de la superficie: participación del 1 % y del 10 % de glaciares mayores, por región y por clasificación. | F3 | Tablas y curvas de concentración reproducibles |
| OE4. Comunicar con tablas y visualizaciones reproducibles si la concentración cambia según la clasificación. | F4 | Figuras e informe final generados desde los notebooks |

## 2.4 Alcance del proyecto

**Se aborda:** la concentración del volumen y de la superficie por glaciar, región y macrozona; su comparación entre clasificaciones de glaciar; el equivalente en agua como magnitud complementaria; y la construcción de un pipeline reproducible que prepare el inventario para esos análisis.

**No se aborda:** la estimación de tendencias temporales de pérdida de hielo, los modelos predictivos, el cruce con datos climáticos externos, la validación en terreno de las mediciones de la DGA ni las relaciones entre área y volumen, porque una se calculó a partir de la otra.

## 2.5 Restricciones

A diferencia del alcance, que es una decisión del equipo, las restricciones son condiciones impuestas por los datos, el método y el plazo. F1 sección 7.2 evaluó el inventario contra los criterios del curso, con los mismos umbrales de `validar_dataset.py`: **cumple todos los requisitos obligatorios y deja dos avisos**, que se declaran aquí como restricciones (detalle en el Anexo C):

- **Variables sobre 60 % de faltantes.** `CUBIERTO` y `OBSERVACIO` (100 %) y `CH_CASQ` (97,24 %) no son recuperables como variables; F2 las descarta y conserva el contenido de `CH_CASQ` como bandera binaria.
- **Datos transversales.** El 90,8 % de los registros tiene año de inventario 2019 y el 8,7 % 2020; no hay mediciones repetidas del mismo glaciar, por lo que no es posible estimar tendencias.
- **El espesor y el volumen no son mediciones.** La columna `F_ESP_MED` declara el método de Chen y Ohmura (1990), y F2 sección 2.3 lo verificó en los datos: `ESP_MED = 28,5 · AREA^0,357` en los cinco tipos ($R^2 \geq 0{,}998$). Por lo tanto, `VOL ≈ 0,0285 · AREA^1,357`, con un factor de 0,6 en los glaciares rocosos (60 % de hielo).
- **Documentación y licencia de la fuente.** La fuente es oficial y verificable, y el conjunto se descarga desde https://dga.mop.gob.cl/inventario-publico-glaciares/. Sin embargo, esa página no declara una licencia (revisada el 11-11-2026) y la DGA no publica un diccionario de variables junto al CSV. El conjunto se usa como dato público de un organismo del Estado, con fines exclusivamente académicos y citando la fuente. El significado y las unidades de `ERROR`, `PERIMETRO`, `PENDIENTE` y los códigos `WGI_*` quedan por verificar.
- **Plazo y herramientas.** Una semana para las Fases 1 y 2, con las librerías del curso.

## 2.6 Supuestos relevantes

- El inventario oficial es la mejor estimación disponible de cada glaciar: no se corrigen valores medidos sin una regla física o una fórmula del propio inventario que lo respalde.
- Las unidades ($km^2$, $km^3$, m s. n. m.) son homogéneas entre regiones.
- Cada fila representa un glaciar distinto y `COD_GLA` es su identificador. Se comprobó: 26.180 códigos únicos, sin nulos. `OBJECTID` se repite en 102 filas.
- Una altitud mínima de 0 m solo es plausible en glaciares con frente en fiordo. En los demás casos se interpreta como un dato faltante.
- **Área y volumen no son variables independientes.** Como el volumen es una función del área,

ambos se reportan juntos pero no se analiza su relación: la concentración del volumen amplifica la del área (exponente 1,357) y no aporta información física independiente.

- El inventario se interpreta como una fotografía del estado reciente de los glaciares, no como una serie de tiempo.

## 2.7 Articulación con las fases

OE1 se cumple entre F1 (estructura, tipos y diccionario) y F2 (diagnóstico cuantitativo). OE2 se cumple completamente en F2. OE3 y OE4 se desarrollarán en F3 y F4 a partir de `data/processed/glaciares_limpio.csv`, el archivo que entrega la Fase 2.

# 3. Aplicación de herramientas científicas

## 3.1 Ecosistema utilizado

**Tabla 3. Herramientas del ecosistema científico y su función en el proyecto.**

| Herramienta | Versión | Función en el proyecto |
|---|---|---|
| Python | 3.14.6 (.venv) | Lenguaje del análisis; se ejecuta dentro del entorno virtual del proyecto |
| pandas | 3.1.1 | Lectura, perfilado, limpieza, imputación, codificación one-hot y persistencia (McKinney, 2022; pandas development team, 2026) |
| NumPy | 2.5.4 | Logaritmos, seno y coseno de la orientación, selección vectorizada y semilla (Harris et al., 2020) |
| scikit-learn | 1.9.1 | StandardScaler, MinMaxScaler y RobustScaler para comparar el escalamiento (scikit-learn developers, 2026) |
| Matplotlib | 3.11.2 | Gráficos de control de la imputación, la transformación y el escalamiento en F2 (Hunter, 2007) |
| JupyterLab / ipykernel | 4.6.6 / 7.4.0 | Notebooks que integran narrativa, código y evidencia (Kluyver et al., 2016) |
| hashlib, pathlib, subprocess | Python 3.14 | Huella SHA-256, rutas relativas y registro del commit (Python Software Foundation, 2026) |
| Git / GitHub | — | Historial de cambios, ramas y Pull Requests (Chacon & Straub, 2014) |

`requirements.txt` también fija seaborn 0.13.2, que se usará en las visualizaciones de F4, para que el entorno no cambie entre fases.

## 3.2 Integración en el flujo de trabajo

Las funciones que usan varias fases viven en el **módulo src/utilidades.py**. F1 lo importa y lo prueba, y F2 lo reutiliza, de modo que ninguna función está copiada entre notebooks. Las librerías se usan dentro de funciones con un propósito declarado, no en celdas sueltas. Cada etapa recibe un DataFrame y devuelve uno nuevo, sin modificar la entrada, lo que permite verificar en el propio notebook la correspondencia entre entrada, procesamiento y salida. Jupyter, Git y las librerías operan como un solo flujo, con tres señales en los notebooks:

- la celda de verificación del entorno, que compara versiones con `requirements.txt`;
- las rutas relativas a la raíz del repositorio;
- el historial de Git y los Pull Requests, que registran cada cambio de los notebooks; en F1 (sección 9.1) y en F2 (sección 9), una celda final registra la rama y el commit con que se generaron las salidas.

**Tabla 4. Funciones principales del flujo programático.**

| Función | NB | Entrada → salida |
|---|---|---|
| localizar_raiz(inicio) · huella_sha256(ruta) · verificar_huella(ruta) | src/ | Directorio → raíz del repositorio (FileNotFoundError); archivo → SHA-256; versión distinta → ProyectoError |
| cargar_inventario · leer_requirements · version_repositorio · identidad_git | src/ | CSV → DataFrame sin alterar; requirements → versiones; Git → rama, commit, email válido |
| Bitacora (clase) · ProyectoError (excepción propia) | src/ | Decisión + evidencia → registro sin duplicados → Markdown; error del proyecto distinguible del de las librerías |

| Función | NB | Entrada → salida |
|---|---|---|
| cargar_limpio(ruta) · espera_error · prueba · ejecutar_pruebas | src/ | CSV procesado → DataFrame con las ordinales en su orden declarado, los códigos como texto y las fechas (ProyectoError si una categoría no tiene orden); funciones de prueba compartidas por F1 y F2 |
| verificar_entorno(deps, requirements) | F1 | Paquetes → versión instalada vs. declarada (OK / DIFIERE / NO INSTALADO) |
| construir_diccionario · evaluar_criterios(ficha) | F1 | DataFrame → diccionario con rol analítico; ficha → requisitos OK / FALTA / AVISO |
| validar_fase1(raiz, config, dicc, df) | F1 | Repositorio → estructura, artefactos, definición, coherencia, módulo y docs/ verificados |
| columnas_sin_informacion(df, umbral) | F2 | DataFrame → columnas con > 60 % faltante o valor único |
| resumen_numerico(df, cols) · relacion_volumen(df) | F2 | Asimetría, ceros e IQR; razón VOL/(AREA·ESP) y EQ/VOL por tipo |
| participacion_mayores · participacion_por_grupo | F2 | % del volumen y del área que reúnen el 1 % y el 10 % de glaciares mayores; % del volumen por región |
| categorias_sospechosas(df, cols) | F2 | Codificación rota, mayúsculas, espacios y variantes de categorías |
| normalizar_columnas · convertir_tipos · parsear_fecha_mixta | F2 | Texto reparado; '-18,17' → −18,17; fecha en 3 formatos → fecha + año |
| reconstruir_volumen(df) | F2 | Ceros de VOL/EQ → fórmula del inventario + banderas |
| imputar(df, col, metodo, grupo, referencia) · comparar_imputaciones | F2 | Nulos → valor estimado + bandera; tabla comparativa de métodos |
| derivar_variables · codificar_ordinal · codificar_orientacion · codificar_one_hot | F2 | Derivadas, códigos con orden declarado, seno/coseno, columnas binarias |
| escalar(df, cols, metodo) · comparar_escaladores | F2 | Continuas → *_ESC; propiedades de cada escalador |
| ejecutar_validaciones(limpio, modelo, original) | F2 | Conjuntos de salida → tabla OK/FALLA de 17 validaciones |
| aplanar(estructura) · profundidad(estructura) (recursivas) | F2 | Metadatos anidados → pares clave-valor → docs/metadatos_proyecto.csv |

## 3.3 Reproducibilidad técnica

### Entorno virtual y dependencias

El proyecto usa un entorno virtual propio (`.venv`), excluido del control de versiones. Las dependencias se declaran con versión exacta en `requirements.txt`, generado con `pip freeze`. El proyecto requiere Python 3.12 o superior. Para reconstruir el entorno en otro equipo:

```
git clone https://github.com/fcorreasoto/proyecto-grupo3-mcdi500.git
cd proyecto-grupo3-mcdi500
python3 -m venv .venv
source .venv/bin/activate          # Windows: .venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

### Verificación de la instalación y ejecución sin errores

- **Kernel y versiones.** F1 sección 5 comprueba que el kernel corre dentro del entorno virtual y compara siete librerías con `requirements.txt`: las siete aparecen como OK. Si falta una librería que los notebooks importan (NumPy, pandas, scikit-learn o Matplotlib), el notebook se detiene con un `assert`; las demás se reportan como aviso. F2 sección 0 repite la verificación del kernel y avisa si alguna versión difiere de la declarada.
- **Ejecución de inicio a fin.** Ambos notebooks se ejecutaron completos con `jupyter nbconvert --execute` (equivalente a Restart & Run All) dentro del `.venv` (Python 3.14.6), sin errores y con

contadores de ejecución consecutivos: 1–16 en F1 y 1–28 en F2.

- **Rutas relativas.** `localizar_raiz` sube desde el directorio de ejecución hasta encontrar `data/raw/`; ningún notebook depende de una ruta personal.
- **Integridad y versión del dato.** F1 y F2 comparan la huella SHA-256 del CSV con la registrada en el README (`5691de5d…c283f1d`). F2 la vuelve a calcular tras validar y tras exportar.
- **Determinismo y semilla.** El pipeline no usa muestreo ni procesos aleatorios: reejecutar F2 regenera archivos procesados idénticos byte a byte, también entre versiones de Python (comprobado con 3.12.3 y 3.13), porque las columnas calculadas con logaritmos y escaladores se redondean a 12 decimales antes de exportar. Aun así, `SEMILLA = 42` queda declarada en `src/utilidades.py` y fijada en ambos notebooks para los pasos aleatorios de las fases siguientes.
- **Robustez ante el orden de ejecución y la versión.** Cada etapa de F2 produce su propio DataFrame a partir de la anterior, por lo que re-ejecutar cualquier celda suelta da el mismo resultado; se verificó re-ejecutando una a una todas las celdas de código de F1 y F2. Ambos notebooks también se ejecutaron sin errores en un clon limpio del repositorio y en un entorno con Python 3.12 y pandas 2.2, donde F2 produjo archivos idénticos.
- **Verificación en un equipo distinto.** Queda pendiente para antes de la entrega: un integrante clonará el repositorio desde GitHub en su propio equipo (Windows), reconstruirá el entorno desde `requirements.txt` y ejecutará ambos notebooks de principio a fin. El resultado se registrará en la sección «Verificación en un segundo equipo» del README.

## 3.4 Control de versiones

Git registra localmente la evolución del proyecto y GitHub aloja el repositorio remoto común (Chacon & Straub, 2014). La convención de mensajes, declarada en el mapa conceptual y en el README, usa un prefijo por tipo de cambio: `docs:`, `data:`, `feat:`, `fix:`, `test:`, `refactor:` y `chore:`.

El trabajo de este avance se organizó en ramas por tarea:

- `f1-ajustes` reúne la revisión de F1, el README y el borrador del informe, y se integró a `main` mediante el **Pull Request #1**.
- `f2-pipeline` reúne el pipeline de F2, los datos procesados y la actualización de la documentación, y se integró mediante el **Pull Request #2**.
- `fix-robustez-notebooks` corrige la re-ejecución de celdas sueltas y la compatibilidad con pandas 2, detectadas al probar los notebooks en otro entorno. Además, alinea F1 y F2 con el proyecto de ejemplo del curso (módulo `src/`, evaluación del dataset, recursividad, gráficos de control y reflexión técnica) y aplica el formato institucional a este informe. Se integró mediante los Pull Requests #3 y #4.
- `ajustes-informe-final` actualiza los integrantes y regenera el informe con el mapa conceptual v2, y se integró mediante el **Pull Request #5**.
- `quitar-signo-seccion` reemplaza el símbolo de párrafo por la palabra «sección» y restaura la constante `SEMILLA` en `src/utilidades.py`, que un commit anterior había eliminado; se integró

mediante el **Pull Request #6**.

Las correcciones menores posteriores (redacción de F1 y F2, tipos al releer, variables redundantes y trazabilidad) se hicieron directamente sobre main. Las ejecuciones de los notebooks se registran en commits propios, que citan el commit sobre el que se generaron las salidas.

**Tabla 5. Historial de commits del avance (71 commits).**

| Commit | Autor | Fecha | Mensaje |
|---|---|---|---|
| 0aa3b95 | Francisco Correa Soto | 05-11-2026 | Initial commit |
| ed4dffe | Francisco Correa Soto | 05-11-2026 | add Inventario de Glaciares data |
| 4dac4c9 | Francisco Correa Soto | 05-11-2026 | docs: crear estructura inicial del proyecto |
| 818758c | Francisco Correa Soto | 05-11-2026 | data: incorpora dataset base en raw y actualizacion del README |
| 025a317 | Roberto Gaubert Urbina | 10-11-2026 | docs:Arregle el repositoreo, cree 2 carpetas |
| 1774b5e | Gustavo Aloy Angella | 10-11-2026 | docs: agregue una nueva carpeta donde se encuentran los datos procesados |
| c9dcf71 | Gustavo Aloy Angella | 10-11-2026 | update: actualizamos los requerimientos del proyecto |
| b04b33b | Roberto Gaubert Urbina | 10-11-2026 | update: Se agrego notebook para F1 |
| fe4df0d | Roberto Gaubert Urbina | 10-11-2026 | update:gitignore actualizado |
| 268cc89 | Gustavo Aloy Angella | 10-11-2026 | update: agregue Notebook F2 |
| 2a9446c | Francisco Correa Soto | 10-11-2026 | docs: se agrego la formativa f1, mapa conceptual |
| bd6bab7 | Francisco Correa Soto | 11-11-2026 | chore: excluye material de clase y archivos de sistema en .gitignore |
| cc91431 | Francisco Correa Soto | 11-11-2026 | docs: reescribe README con estructura, entorno y ejecución reales |
| 89fac2a | Francisco Correa Soto | 11-11-2026 | docs: agrega borrador del informe técnico de la Sumativa 1 |
| e5aa555 | Francisco Correa Soto | 11-11-2026 | feat: completa F1 con verificación de entorno, huella del dataset y vínculo con el mapa |
| 1685df9 | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F1 ejecutadas sobre el commit e5aa555 |
| b410c60 | Francisco Correa Soto | 11-11-2026 | Merge pull request #1 from fcorreasoto/f1-ajustes |
| 83cb963 | Francisco Correa Soto | 11-11-2026 | refactor: renombra data/processd a data/processed y documenta sus archivos |
| 20d98c7 | Francisco Correa Soto | 11-11-2026 | feat: implementa pipeline completo de F2 según los pasos 6 a 11 del curso |
| 487525d | Francisco Correa Soto | 11-11-2026 | data: agrega datos procesados y bitácora de decisiones de F2 |
| 4e61283 | Francisco Correa Soto | 11-11-2026 | docs: actualiza README con salidas y decisiones de F2 |
| 3f066ea | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F2 ejecutadas sobre el commit 4e61283 |
| a8a2959 | Francisco Correa Soto | 11-11-2026 | docs: actualiza el informe con el pipeline de F2 y la vinculación del mapa |
| d22431a | Francisco Correa Soto | 11-11-2026 | Merge pull request #2 from fcorreasoto/f2-pipeline |
| 6a039a5 | Francisco Correa Soto | 11-11-2026 | fix: hace que las celdas de F2 se puedan re-ejecutar y que corra con pandas 2 |
| 5e37ab6 | Francisco Correa Soto | 11-11-2026 | fix: F1 solo se detiene si faltan librerías que los notebooks importan |
| 33d8363 | Francisco Correa Soto | 11-11-2026 | docs: agrega solución de problemas frecuentes al README |
| 7fbfe00 | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F1 ejecutadas sobre el commit 33d8363 |
| 0151e82 | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F2 ejecutadas sobre el commit 7fbfe00 |
| b632b1a | Francisco Correa Soto | 11-11-2026 | docs: actualiza el informe con la verificación de robustez y el historial reciente |
| e8bda81 | Francisco Correa Soto | 11-11-2026 | docs: aplica la plantilla institucional al informe |
| a34877c | Francisco Correa Soto | 11-11-2026 | chore: excluye .ipynb_checkpoints en .gitignore |
| 0e86804 | Francisco Correa Soto | 11-11-2026 | feat: agrega módulo compartido src/utilidades.py |
| 25df465 | Francisco Correa Soto | 11-11-2026 | chore: agrega validar_dataset.py, el validador de dataset del curso |

| Commit | Autor | Fecha | Mensaje |
|---|---|---|---|
| 9d5a973 | Francisco Correa Soto | 11-11-2026 | feat: alinea F1 con el ejemplo del curso |
| 83ba9b0 | Francisco Correa Soto | 11-11-2026 | feat: alinea F2 con el ejemplo del curso |
| de37d27 | Francisco Correa Soto | 11-11-2026 | docs: actualiza README con el módulo src/, los artefactos de docs/ y la semilla |
| 629eabc | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F1 ejecutadas sobre el commit de37d27 |
| ffc414e | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F2 ejecutadas sobre el commit 629eabc |
| fa06f51 | Francisco Correa Soto | 11-11-2026 | docs: actualiza el informe con el módulo src/, la recursividad, los gráficos de control y la evaluación del dataset |
| 8134481 | Francisco Correa Soto | 11-11-2026 | docs: actualiza el mapa conceptual según la retroalimentación de la Formativa 1 |
| 9b290f3 | Francisco Correa Soto | 11-11-2026 | feat: F2 verifica que el espesor y el volumen se estimaron desde el área |
| ea1642d | Francisco Correa Soto | 11-11-2026 | feat: alinea F1 con el mapa conceptual v2 |
| b83ca1b | Francisco Correa Soto | 11-11-2026 | docs: actualiza README con la pregunta acotada, el supuesto del volumen y la licencia |
| 0704059 | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F1 ejecutadas sobre el commit b83ca1b |
| d2895c7 | Francisco Correa Soto | 11-11-2026 | docs: registra salidas de F2 ejecutadas sobre el commit 0704059 |
| fcc0311 | Francisco Correa Soto | 11-11-2026 | docs: alinea el informe con el mapa conceptual v2 |
| 6f24321 | Francisco Correa Soto | 11-11-2026 | Merge pull request #3 from fcorreasoto/fix-robustez-notebooks |
| cd4f1de | Francisco Correa Soto | 11-11-2026 | fix: fix: elimina celda de identidad Git que fallaba en F1 |
| 268492f | Francisco Correa Soto | 11-11-2026 | Merge pull request #4 from fcorreasoto/fix-robustez-notebooks |
| a92efbe | Francisco Correa Soto | 11-11-2026 | docs: quita de F1 las menciones a la celda de trazabilidad eliminada |
| 04ff013 | Francisco Correa Soto | 11-11-2026 | docs: agrega al README la tabla de verificación en un segundo equipo |
| 262d820 | Francisco Correa Soto | 11-11-2026 | docs: ajusta el informe a F1 sin celda de trazabilidad y cita la guía de la evaluación |
| 7c6483d | Francisco Correa Soto | 11-11-2026 | docs: actualiza los integrantes del informe según el acta |
| 4efce1e | Francisco Correa Soto | 11-11-2026 | docs: actualiza los integrantes según el acta en README, notebooks y mapa conceptual |
| 06a731e | Francisco Correa Soto | 11-11-2026 | docs: regenera el informe con el mapa conceptual actualizado |
| 31d8f75 | Francisco Correa | 11-11-2026 | Merge pull request #5 from fcorreasoto/ajustes-informe-final |
| 9af6c34 | Francisco Correa | 11-11-2026 | fix: correcciones al markdown de F1 |
| 9dc7556 | Francisco Correa | 11-11-2026 | fix: correcciones al markdown de F2 |
| a8d45fc | Francisco Correa Soto | 11-11-2026 | docs: usa la palabra sección en lugar del símbolo de párrafo |
| 77a5d56 | Francisco Correa Soto | 11-11-2026 | docs: regenera el informe sin el símbolo de párrafo |
| 326b261 | Francisco Correa | 11-11-2026 | Merge pull request #6 from fcorreasoto/quitar-signo-seccion |
| 590d5ae | Francisco Correa | 11-11-2026 | fix: Problemas de redacción y vinculación |
| a22cd90 | Francisco Correa | 11-11-2026 | fix: corrige tipos al releer, variables redundantes y trazabilidad de F2 |
| d58ddc1 | Francisco Correa Soto | 11-11-2026 | docs: actualización del informe |
| b352b88 | Gustavo Aloy Angella | 11-11-2026 | Update and rename README to README.md |
| 23f6b46 | Gustavo Aloy Angella | 11-11-2026 | Update and rename README to README.md |
| 02671f4 | Gustavo Aloy Angella | 11-11-2026 | Update README.md - Verificación del proyecto |
| 7c65f7b | Francisco Correa Soto | 11-11-2026 | fix: ejecuta F1 y F2 completos y actualiza sus salidas |
| e441b68 | Francisco Correa Soto | 11-11-2026 | chore: reejecuta F1 para registrar el commit 7c65f7b en su trazabilidad |
| dc36faa | Francisco Correa Soto | 11-11-2026 | chore: reejecuta F2 para registrar el commit e441b68 en su trazabilidad |

El historial muestra el avance progresivo: estructura y datos (5 de noviembre); requerimientos, notebooks iniciales y mapa (10 de noviembre); y revisión de F1, pipeline de F2 y documentación (11 de noviembre). Cada commit se hizo desde la cuenta de su autor. Con autorización del docente, el desarrollo de este avance quedó a cargo de Francisco Correa Soto, lo que explica que la mayoría de los commits

correspondan a su cuenta. 56 de los 71 mensajes siguen la convención. Los que no la siguen (con prefijo `update:` o sin prefijo) son de la primera semana, antes de que la convención quedara declarada en el README, o son tres commits hechos desde la interfaz web de GitHub, que proponen un mensaje automático («Update README.md»). El resto sigue la convención, salvo los mensajes automáticos de merge de los Pull Requests.

El archivo `.gitignore` excluye el entorno virtual, las cachés de Python, las variables de entorno (`.env`), archivos de sistema y la carpeta `material/` con el material de clase, que no es de autoría del grupo. Los notebooks se versionan **con sus salidas**, porque son evidencia de ejecución.

## 3.5 Documentación del proceso

El proceso queda documentado en cuatro niveles coherentes entre sí:

- **Notebooks.** Cada bloque de código va precedido por una celda Markdown que explica qué se hace y por qué. Las funciones tienen docstrings y los comentarios explican las líneas cuya razón no es evidente.
- **Bitácora.** La clase `Bitacora` de F2 registra cada decisión en el momento en que se toma, con su cifra. Se exporta a `docs/bitacora_f2.md` (36 decisiones) y se reproduce en el Anexo B. Este informe usa exactamente las mismas cifras.
- **Artefactos de docs/ generados por los notebooks.** F1 exporta el diccionario de variables con su rol, la evaluación del dataset, la tabla de vinculación con el mapa y los metadatos de ejecución. F2 exporta la bitácora y los metadatos del pipeline. Al generarse desde las mismas estructuras del notebook, no pueden contradecirlo.
- **Repositorio.** El README describe el proyecto, la estructura, las dependencias, la ejecución, las decisiones y la solución de problemas frecuentes. `data/processed/README` describe cada archivo de salida.
- **Informe.** Recoge las decisiones (capítulo 4), los enfoques descartados (secciones 4.2 y 7.1) y la vinculación con el mapa (capítulo 7).

**Flujo de datos.** Entra `data/raw/Inventario_Publico_de_Glaciares_2022.csv` (26.180 × 45, 9,46 MB). F1 lo lee y lo describe sin modificarlo. F2 lo explora, lo limpia, lo transforma, lo valida y escribe:

- `data/processed/glaciares_limpio.csv` (26.180 × 48);
- `data/processed/glaciares_modelo.csv` (26.180 × 47);
- un perfil de calidad, la bitácora y los metadatos del pipeline.

## 3.6 Repositorio GitHub

```
proyecto-grupo3-mcdi500/
├── F1/F1_Definicion.ipynb          # Fase 1: definición, entorno y dataset
├── F2/F2_Procesamiento.ipynb       # Fase 2: pasos 6–11 del pipeline
├── src/utilidades.py              # Módulo compartido (importado por F1 y F2)
├── data/
│   ├── raw/                        # CSV original de la DGA (inmutable)
│   └── processed/                  # glaciares_limpio, glaciares_modelo, perfil
├── docs/
│   ├── validacion_dataset.md       # Salida de validar_dataset.py
│   ├── diccionario_variables.csv   # F1: 45 variables con su rol
│   ├── evaluacion_criterios_dataset.csv · vinculacion_mapa_conceptual.csv
│   ├── metadatos_fase1.json · metadatos_proyecto.csv
│   ├── bitacora_f2.md              # Bitácora exportada por F2
│   ├── f1/                         # Mapa conceptual (Formativa 1)
│   └── informe/                    # Este informe (.docx y .pdf)
├── validar_dataset.py              # Validador de dataset del curso
├── requirements.txt                # Dependencias con versión exacta
├── .gitignore
└── README.md                       # Descripción, instalación, ejecución
```

# 4. Diseño de soluciones algorítmicas

## 4.1 Codificación funcional

El código sigue cinco principios:

- **Una función por tarea**, con parámetros explícitos y docstring.
- **Ninguna función modifica su entrada:** cada una trabaja sobre `df.copy()` y devuelve un objeto nuevo, y cada etapa del notebook guarda su resultado en una variable propia.
- **Las entradas inválidas producen la excepción correcta** (`ValueError`, `KeyError`, `FileNotFoundError`) en lugar de un resultado silenciosamente erróneo.
- **Las estructuras de control recorren variables y métodos**, en lugar de repetir el mismo bloque.
- **Las constantes del dominio se declaran una sola vez:** órdenes, cortes, ángulos y factores.

Ejemplo: la función de imputación, que admite cuatro métodos y crea la bandera de trazabilidad:

```
def imputar(df, columna, metodo, grupo=None, referencia=None, minimo=0.0):
    if metodo not in METODOS_IMPUTACION:
        raise ValueError(f"Método desconocido: {metodo}")
    df = df.copy()                                    # nunca se modifica la entrada
    nulos = df[columna].isna()
    if metodo == "diferencia":                        # usa una variable observada
        desnivel = df[referencia] - df[columna]
        desnivel_grupo = desnivel.groupby(df[grupo]).transform("median")
        estimado = (df[referencia] - desnivel_grupo).clip(lower=minimo)
    ...                                               # media, mediana, mediana por grupo
    df.loc[nulos, columna] = estimado[nulos]
    df[f"{columna}_IMPUTADO"] = nulos.astype(int)   # bandera: qué filas se imputaron
    return df
```

**Módulos y excepciones.** Lo que usan varias fases está en `src/utilidades.py`, junto con una excepción propia, `ProyectoError`, que distingue «el dato o el repositorio no son los esperados» de los errores de pandas o scikit-learn. F1 prueba el módulo con 13 casos (4 normales, 5 límite y 4 excepciones) antes de que F2 lo use.

**Orientación a objetos.** Aparece donde agrupar estado y comportamiento tiene sentido: la clase `Bitacora` acumula las decisiones, valida que cada una tenga evidencia, no las duplica si una celda se re-ejecuta y las exporta.

**Recursividad.** F2 sección 7 usa dos funciones recursivas con un propósito real. `aplanar` convierte los metadatos anidados del pipeline (fuente, decisiones con sus parámetros y resultados, hasta 4 niveles) en pares clave-valor exportables, y `profundidad` mide su anidamiento. Un bucle no sirve, porque la profundidad es variable. El caso base es un valor simple o una lista; el caso recursivo, un subdiccionario. Ambas funciones tienen 8 pruebas, incluida una excepción `TypeError`.

## 4.2 Preprocesamiento y transformación del dataset

La regla aplicada fue **medir primero, decidir después y justificar con la medición** (Salinas, 2026). La Tabla 6 resume el diagnóstico de F2 sección 2.

**Tabla 6. Diagnóstico previo del inventario (F2 sección 2).**

| Aspecto | Resultado medido |
|---|---|
| Dimensiones y duplicados | 26.180 × 45; 0 filas duplicadas; COD_GLA único; OBJECTID repetido en 102 filas |
| Faltantes > 60 % | CUBIERTO y OBSERVACIO 100 %; CH_CASQ 97,24 % (solo 723 glaciares con código) |
| Valor único | Id (0), DATUM (WGS 84), HUSO (19 SUR), F_ESP_MED (CHEN & OHMURA 1990) |
| Redundancia | WGI_1 corresponde uno a uno con las 5 clases de CLASIFICA |
| Asimetría y atípicos | AREA_KM2: asimetría 43,1; media 0,803 vs. mediana 0,036 km²; 14,37 % fuera del IQR. VOL_km3: asimetría 54,0 |
| Participación de los mayores | El 1 % de los glaciares de mayor volumen reúne el 93,8 % del volumen; el 1 % de mayor área, el 71,5 % del área. Magallanes (49,8 %) y Aysén (48,1 %) suman el 97,9 % del volumen |
| Fórmula del volumen | VOL/(AREA·ESP/1000) = 1,00 y EQ/VOL = 0,85 en todos los tipos, salvo los rocosos: 0,60 (60 % de hielo) y 0,917 |
| Espesor y área | ESP_MED = a · AREA^b con a = 28,46–28,50 y b = 0,3567–0,3570 en los 5 tipos ($R^2 \geq 0,9985$): fórmula de Chen y Ohmura (1990) |
| Faltantes encubiertos | 362 VOL_km3 = 0 (glaciaretes de 0,001–0,002 km²: redondeo); 668 EQ_AGUAKM3 = 0; 69 HMIN = 0, de ellos 36 en fiordo (plausible) y 33 en tierra o lago |
| Coherencia física | 1 glaciar (CL108116007@, Ñuble) con HMEDIA 2.228 m < HMIN 2.849 m |
| Categorías | FUENTE_DIG: 'FOTOGRAMETR├ìA' (codificación) y 'LiDAR ANDINA' (mayúsculas); espacios dobles en NOM_CUEN y NOMBRE |
| Tipos | LATITUD/LONGITUD como texto con coma decimal; FUEN_FECHA: 26.167 DD/MM/AAAA, 12 solo año, 1 MM/DD/AAAA |

## Limpieza: decisiones y justificación

**Tabla 7. Decisiones de limpieza, alternativas y justificación.**

| Hallazgo | Decisión | Justificación |
|---|---|---|
| CUBIERTO, OBSERVACIO (100 % vacías) | Descartar | Supera el umbral del curso (> 60 %): no hay valores desde los cuales imputar |
| Id, DATUM, HUSO, F_ESP_MED (valor único) | Descartar; valores en la bitácora | No aportan variación; se conservan como metadato, sin perder información |
| WGI_1 ≡ CLASIFICA; OBJECTID no único | Descartar | WGI_1 es redundante; OBJECTID no identifica filas. COD_GLA es la clave y se excluye del análisis |
| CH_CASQ (97,24 % faltante) | Descartar como categoría; crear EN_CAMPO_HIELO (0/1) | El faltante significa «no pertenece a un campo de hielo»: el contenido útil es binario (723 glaciares) |
| Codificación, mayúsculas y espacios | Normalizar el texto | 139 valores corregidos (FUENTE_DIG 6, NOM_CUEN 128, NOMBRE 5); evita contar una misma categoría dos veces en F3 |
| Coordenadas, fechas y códigos con tipo incorrecto | Casting | 26.180 coordenadas a float sin pérdida; 26.168 fechas completas y FUEN_ANIO para las 26.180 (1955–2022); 8 columnas de código a texto, porque no son cantidades |
| 362 VOL_km3 = 0 y 668 EQ_AGUAKM3 = 0 | Recalcular con la fórmula del inventario + bandera | Es redondeo a 5 decimales (máximo recalculado: $5{,}9 \cdot 10^{-6}$ km³). La fórmula usa datos observados del mismo glaciar; el volumen total cambia en +0,0013 km³ |
| Atípicos de área y volumen | Conservar | Son glaciares reales (por ejemplo, los efluentes de los Campos de Hielo); eliminarlos sesgaría la respuesta |

## Imputación: comparación de métodos

Se marcaron como faltantes los 33 `HMIN = 0` con frente en tierra o lago (0,13 %) y el `HMEDIA` incoherente. Antes de imputar se compararon las alternativas con tres criterios: el cambio porcentual en la desviación estándar, que mide cuánto reduce la variabilidad cada método; las violaciones de la restricción física `HMIN ≤ HMEDIA`; y la superficie de hielo que se perdería al eliminar filas.

**Tabla 8. Comparación de métodos de imputación de HMIN (33 faltantes).**

| Método | Filas | Desv. estándar | Cambio (%) | Violaciones | Área perdida (km²) |
|---|---|---|---|---|---|
| Eliminar filas | 26.146 | 1.260,28 | 0,0000 | 0 | 967,51 |
| Media global | 26.179 | 1.259,48 | −0,0630 | 33 | 0 |
| Mediana global | 26.179 | 1.259,56 | −0,0568 | 31 | 0 |
| Mediana por comuna | 26.179 | 1.260,08 | −0,0155 | 14 | 0 |
| HMEDIA − desnivel mediano por comuna (elegido) | 26.179 | 1.260,24 | −0,0029 | 0 | 0 |

Eliminar filas no altera la dispersión, pero descarta glaciares que suman 967,5 km² de hielo. La media y la mediana globales asignan a glaciares patagónicos de baja altitud valores típicos de los Andes centrales: 33 y 31 de ellos quedan por encima de su propia altitud media, lo que es físicamente imposible. La mediana por comuna reduce el problema a 14 casos. El método por diferencia usa la `HMEDIA` observada de cada glaciar: es el único sin violaciones y el que menos modifica la desviación estándar (−0,003 %). La regla de elección se declaró en el código antes de aplicarla, y la bandera `HMIN_IMPUTADO` registra las 33 filas imputadas.

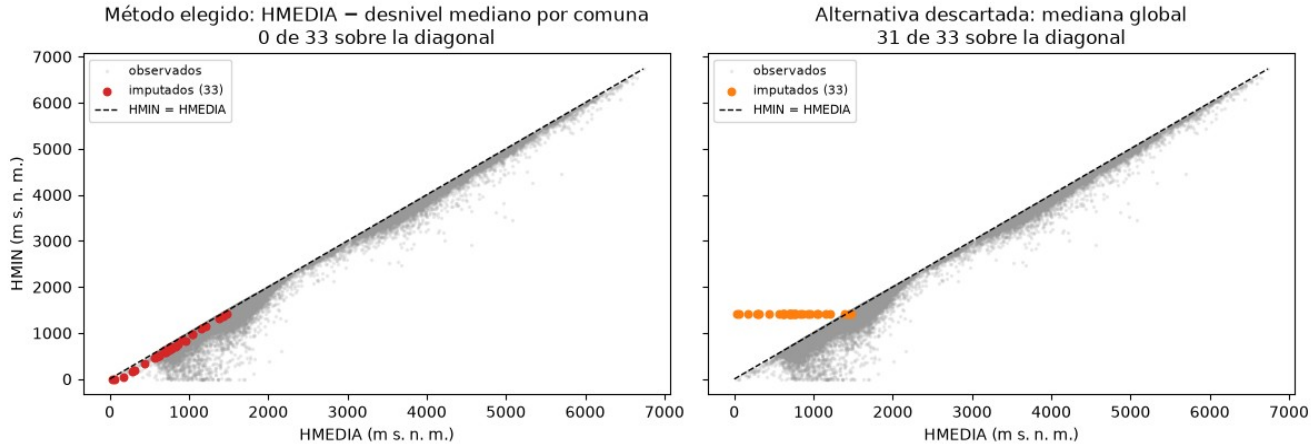



*Figura 1. Gráfico de control de la imputación de HMIN (F2 sección 3.5). Los 33 valores imputados deben quedar bajo la diagonal HMIN = HMEDIA. El método elegido no deja ninguno sobre ella; la mediana global deja 31.*

Para el `HMEDIA` del glaciar de Ñuble, la restricción física define el método: el punto medio entre `HMIN` y `HMAX` (2.893 m) respeta `HMIN ≤ HMEDIA ≤ HMAX` por construcción. La mediana global (1.525 m), en cambio, quedaría bajo su `HMIN` de 2.849 m.

### Transformación según el tipo de variable

**Tabla 9. Tratamiento por rol analítico.**

| Rol | Variables | Tratamiento y justificación |
|---|---|---|
| Numérica continua | AREA_KM2, VOL_km3 | log10 → LOG_AREA, LOG_VOL: la asimetría baja de 43,1 a 0,61 (área) y de 54,0 a 0,69 (volumen). Sin el recálculo de los ceros, el log daría −∞ |
| Derivadas | RANGO_ALT, CLASE_TAMANO, FRENTE_AGUA | Desnivel HMAX − HMIN; clases con cortes del dominio (0,01 · 0,1 · 1 · 10 km²); bandera de frente en lago o fiordo |
| Ordinal | MZON_GLAC, CLASE_TAMANO | Orden declarado NORTE → CENTRO → SUR → AUSTRAL. El alfabético pondría AUSTRAL < CENTRO < NORTE < SUR |
| Cíclica | ORIENTA | Seno y coseno del ángulo: N (0°) y NW (315°) quedan vecinas; las 3 laderas PLANO quedan en (0, 0) |

| Rol | Variables | Tratamiento y justificación |
|---|---|---|
| Nominal | CLASIFICA, FRENTE_TER, REGION | One-hot: 5 + 3 + 16 columnas binarias |
| Alta cardinalidad | FUENTE_DIG (19) | Categorías con menos de 1 % de los registros → OTRAS (160 glaciares); quedan 8 categorías → one-hot |
| Binaria | EN_CAMPO_HIELO, FRENTE_AGUA, banderas | Codificación 0/1 |
| Numérica discreta | INVE_FECHA | Se mantiene numérica: el orden y la distancia entre años tienen significado |
| Identificador | COD_GLA | Único y sin nulos; se conserva como clave y se excluye del análisis |

### Escalamiento: comparación de los tres escaladores

Aplicados al área sin logaritmo, los tres escaladores dejan el 99,0 % de los glaciares en el 1 % inferior del rango: **el problema es la asimetría, no el escalador**. Por eso primero se aplica log10 y después se escala. `LOG_VOL` y `ESP_MED` no entran a la matriz: son funciones del área (correlación de Spearman con `LOG_AREA` de 0,9965 y 0,9999), e incluirlas repetiría la misma información y contradiría el supuesto de que área y volumen no son independientes. Se escalan las cuatro continuas restantes (`LOG_AREA`, `HMEDIA`, `RANGO_ALT`, `PENDIENTE`):

**Tabla 10. Propiedades de cada escalador (ejemplo: LOG_AREA).**

| Escalador | Garantiza | Mediana · RIC de LOG_AREA | Riesgo con estos datos |
|---|---|---|---|
| StandardScaler | Media 0, desviación 1 | −0,120 · 1,377 | La media se desplaza por los valores extremos |
| MinMaxScaler | Rango [0, 1] | 0,264 · 0,194 | Depende de dos valores extremos (mínimo y máximo) |
| RobustScaler (elegido) | Mediana 0, RIC 1 | 0,000 · 1,000 | Las cifras no quedan «redondas» |

F2 incluye además dos gráficos de control: el histograma del área antes y después del logaritmo, y los boxplots de las mismas variables con cada escalador. RobustScaler es el único que deja la mediana en 0 y el RIC en 1 sin que los extremos deformen al resto. Se elige **RobustScaler** porque la asimetría no desaparece en todas las variables: `LOG_AREA` queda casi simétrica tras el log10 (0,61), pero `RANGO_ALT` (4,05) y `HMEDIA` (1,45) se escalan sin transformar y conservan colas largas, que desplazan la media y el máximo en que se basan StandardScaler y MinMaxScaler. La mediana y el RIC no se ven afectados, y la elección es coherente con conservar los atípicos legítimos y con imputar mediante criterios basados en medianas.

### Resultado e impacto

El pipeline entrega dos conjuntos con las **26.180 filas**; ningún glaciar se elimina:

- **glaciares_limpio.csv (26.180 × 48):** 36 variables originales limpias en sus unidades físicas, la bandera de campo de hielo, el año de la fuente, cuatro banderas de imputación o recálculo y seis variables derivadas. Es la entrada de F3 y F4, y se lee con utl.cargar_limpio, que restaura el orden declarado de las ordinales y los códigos como texto, porque un CSV no conserva los tipos.
- **glaciares_modelo.csv (26.180 × 47):** matriz 100 % numérica con 2 ordinales, 2 cíclicas, 6 banderas, 4 continuas escaladas y 32 columnas one-hot, más la clave `COD_GLA`.

Las estadísticas de superficie no cambian. Las de volumen cambian en 0,0013 km³ por el recálculo de los ceros, y las de `HMIN` en −0,003 % de desviación estándar. `LOG_VOL` y `ESP_MED` se conservan en `glaciares_limpio`, y las columnas calculadas con logaritmos y escaladores se redondean a 12 decimales

antes de exportar.

## 4.3 Validación técnica y verificación del código

La validación tiene dos partes, ambas ejecutadas en el notebook con sus salidas conservadas como evidencia (F2 sección 6):

- **Dataset resultante:** 17 comprobaciones, cada una de una **propiedad específica**. `ejecutar_validaciones` las corre todas y reporta OK o FALLA sin detenerse en la primera; luego un `assert` exige que todas pasen.
- **Funciones del pipeline:** 23 pruebas sobre un mini inventario sintético de cuatro glaciares que reproduce los problemas reales del dataset.
- **Módulo y recursividad:** las 13 pruebas de `src/utilidades.py` en F1 y las 8 de las funciones recursivas en F2. En total, el proyecto ejecuta 44 pruebas de funciones en casos normales, límite y excepciones.

**Tabla 11. Validaciones del dataset resultante: 17/17 OK.**

| Validación | Resultado |
|---|---|
| Se conservan las 26.180 filas en ambos conjuntos | OK |
| COD_GLA único, sin nulos y alineado entre conjuntos | OK |
| Sin filas duplicadas | OK |
| Sin nulos en las columnas de análisis (limpio) ni en la matriz del modelo | OK (2) |
| Matriz del modelo 100 % numérica, salvo la clave | OK |
| Cada grupo one-hot (tipo, frente, región, fuente) suma 1 por fila | OK (4) |
| Ordinales dentro del rango declarado | OK |
| RobustScaler: mediana 0 y RIC 1 en las 4 variables | OK |
| Área, volumen y equivalente en agua positivos | OK |
| Coherencia altitudinal HMIN ≤ HMEDIA ≤ HMAX en todos los glaciares | OK |
| Coordenadas dentro del territorio de Chile (−56° a −17°; −76° a −66°) | OK |
| Banderas coinciden con lo registrado (33 HMIN, 1 HMEDIA, 362 VOL) | OK |
| data/raw no fue modificado (SHA-256) | OK |

**Tabla 12. Pruebas de las funciones: 23/23 OK.**

| Tipo | Pruebas |
|---|---|
| Casos normales (8) | Conversión de coma decimal; reparación de codificación; fechas en 3 formatos; reconstrucción del volumen con bandera; imputación por diferencia respeta HMIN ≤ HMEDIA; ordinal respeta el orden declarado; la función no modifica su entrada; cargar_limpio restaura el orden declarado y los códigos como texto |
| Casos límite (5) | Imputar una columna sin nulos no cambia nada; one-hot con una sola categoría; RobustScaler sobre una columna constante (RIC = 0); orientación PLANO → (0, 0); funciones sobre un conjunto vacío |
| Excepciones (10) | Método de imputación desconocido; mediana por grupo sin grupo; escalar con nulos; escalador desconocido; categoría ordinal no declarada; logaritmo de volumen 0; columna inexistente; decisión sin evidencia en la bitácora; ordinal sin orden declarado al releer el CSV; ruta sin data/raw → ValueError, KeyError, ProyectoError o FileNotFoundError, según corresponda |

Los archivos exportados se vuelven a leer y se comprueba que conservan la forma, las columnas y los tipos; el conjunto limpio se relee con utl.cargar_limpio y se comprueba que MZON_GLAC y

CLASE_TAMANO conservan el orden declarado y que los códigos vuelven como texto. En F1, `verificar_f1` comprueba las dimensiones y la unicidad de `COD_GLA`, y `validar_fase1` comprueba la estructura del repositorio, los artefactos del entorno, la definición del problema, la coherencia del diccionario, el módulo importable y los artefactos de `docs/`.

# 5. Notebook F1_Definicion.ipynb (F1)

`F1/F1_Definicion.ipynb` contiene exclusivamente el alcance de la Fase 1: **no limpia, no imputa y no transforma**. Su última verificación lo deja explícito: «F1 finalizada: no se modificó ni exportó el inventario».

**Tabla 13. Estructura del notebook F1.**

| Sección | Contenido | Evidencia |
|---|---|---|
| 1–3 | Diccionario PROYECTO: problemática, pregunta, objetivos, alcance, restricciones y supuestos | Fuente única para el notebook, el README y el informe |
| 4 | Repositorio, módulo compartido y verificación del dataset (pasos 2 y 3) | src/utilidades.py importado; semilla 42; huella SHA-256 = referencia |
| 4.1 | Pruebas del módulo | 13/13 OK: 4 normales, 5 límite, 4 excepciones |
| 5 | Verificación del entorno reproducible (paso 1) | Tabla de herramientas; kernel en .venv; 7 librerías vs. requirements.txt: 7 OK |
| 6 | Reconocimiento inicial: dimensiones, tipos inferidos y roles analíticos | 26.180 × 45; 16 variables prioritarias presentes |
| 7 | Diccionario de las 45 variables (paso 4) y señales de calidad | Diccionario con assert de completitud; ceros y variantes de categorías; decisiones pendientes para F2 |
| 7.2 | Ficha del conjunto y evaluación contra los criterios del curso | Rol analítico por variable; obligatorios OK y 2 avisos |
| 8 | Correspondencia con las fases y vinculación con el mapa conceptual | Tabla con los 6 tipos de elemento verificada con assert y exportada |
| 9 | Persistencia y validación de la fase | 4 artefactos en docs/; validar_fase1 [OK]; sección 9.1: rama y commit de la ejecución |
| 10 | Reflexión técnica | Hallazgos, dificultades y decisiones abiertas |

# 6. Notebook ejecutable de la Fase 2

`F2/F2_Procesamiento.ipynb` sigue los pasos 6 a 11 del curso. Importa el módulo `src/utilidades.py` y fija la semilla. Cada etapa abre con una celda narrativa que explica su lógica y cierra con resultados intermedios verificables, registrados en la bitácora.

**Tabla 14. Estructura del notebook F2.**

| Sección | Etapa | Resultado intermedio verificable |
|---|---|---|
| 0–1 | Entorno, bitácora y obtención | Versiones y kernel; huella SHA-256 = referencia; `original` inmutable |
| 2 | Exploración y medición (paso 6) | Perfil, columnas sin información, asimetría, participación de los mayores, ceros, IQR, fórmula del volumen, categorías y fechas; 18 hallazgos |
| 3 | Limpieza e imputación (paso 7) | 45 → 37 columnas; 139 textos corregidos; casting; 362 + 668 recálculos; 5 métodos comparados para HMIN; gráfico de control |
| 4 | Transformación por tipo (paso 8) | Derivadas, ordinales, seno/coseno y 32 columnas one-hot; histograma antes y después del log |
| 5 | Escalamiento (paso 9) | LOG_VOL y ESP_MED excluidas por redundancia; comparación de los tres escaladores con boxplots; RobustScaler sobre 4 continuas |
| 6 | Validación y pruebas (paso 10) | 17/17 validaciones y 23/23 pruebas OK |

| Sección | Etapa | Resultado intermedio verificable |
|---|---|---|
| 7 | Recursividad | aplanar y profundidad: 4 niveles → 34 pares clave-valor; 8 pruebas OK |
| 8 | Persistencia y bitácora (paso 11) | 2 CSV releídos (el limpio con cargar_limpio) y verificados; bitácora de 36 decisiones; metadatos en docs/ |
| 9–10 | Trazabilidad y reflexión técnica | Rama y commit de la ejecución; hallazgos, dificultades y decisiones abiertas |

# 7. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual de la Formativa 1 se actualizó a una **versión 2** según la retroalimentación docente. La pregunta se acotó a la concentración del volumen; se agregó el supuesto verificado de que el volumen se estimó desde el área; se revisó la licencia y se declaró su ausencia como restricción; cada herramienta quedó conectada con la etapa en que interviene; y la letra quedó en 11,5 pt reales. El mapa organiza el proyecto en cinco bloques: A, contexto y pregunta; B, ciclo de vida del dato con las herramientas de cada etapa; C, herramientas transversales; D, repositorio y protocolo de colaboración; y E, documentación científica reproducible. La Tabla 15, generada por F1 sección 8 y exportada a `docs/vinculacion_mapa_conceptual.csv`, contrasta cada elemento con su implementación y cubre los seis tipos de elemento: herramientas, procesos, flujo reproducible, decisiones técnicas, organización del repositorio y estructura del notebook.

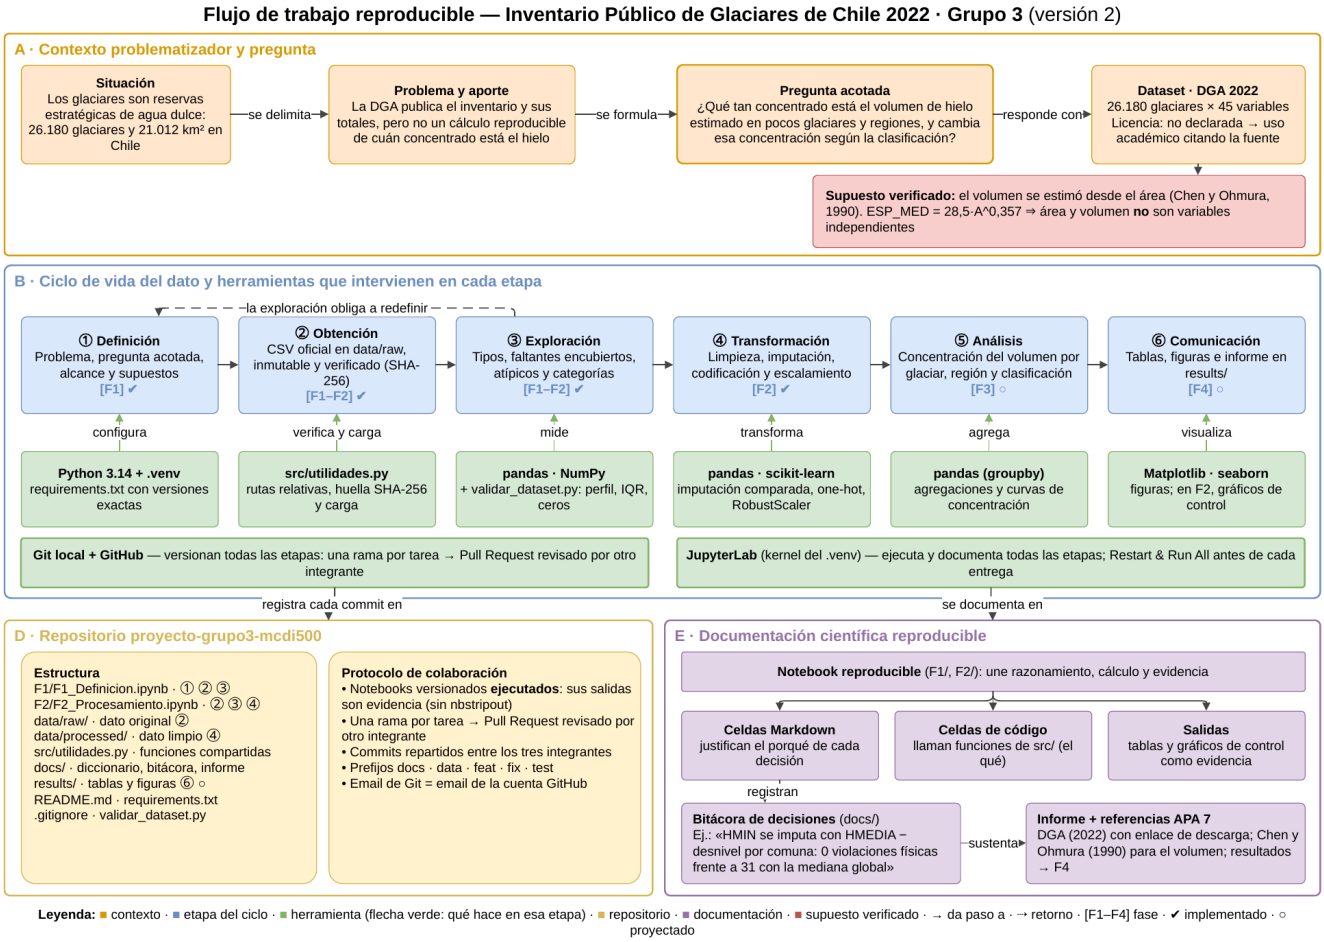



*Figura 2. Mapa conceptual v2 del flujo de trabajo reproducible (Formativa 1, ajustado según la retroalimentación docente). El original en A3 está en docs/f1/mcdi500_s1_grupo3.pdf.*

**Tabla 15. Correspondencia entre el mapa conceptual y el avance.**

| Elemento del mapa | Tipo | Estado | Evidencia |
|---|---|---|---|
| A · Situación, problema y aporte frente a la DGA | Proceso | Implementado | Secciones 1–3: PROYECTO['problematica']; README |
| A · Pregunta acotada: concentración del volumen y su variación por clasificación | Proceso | Implementado | Sección 2: PROYECTO['pregunta'] |

| Elemento del mapa | Tipo | Estado | Evidencia |
|---|---|---|---|
| A · Dataset DGA 2022 con licencia revisada (no declarada por la DGA) | Flujo reproducible | Implementado | Sección 7.2: FICHA y evaluación del dataset (aviso de licencia) |
| A · Supuesto verificado: el volumen se estimó desde el área | Decisión técnica | Implementado | F2 sección 2.3: ESP_MED = 28,5·A^0,357; sección 1 supuestos |
| B① Definición | Proceso | Implementado | Secciones 1–3 |
| B② Obtención: CSV en data/raw verificado con SHA-256 | Flujo reproducible | Implementado | Sección 4: verificar_huella |
| B③ Exploración: faltantes encubiertos, atípicos y categorías | Proceso | Implementado | Secciones 6–7 (descriptiva); F2 sección 2 |
| B④ Transformación → data/processed | Proceso | Implementado en F2 | F2 secciones 3–8; data/processed/ |
| B⑤ Análisis de concentración · B⑥ Comunicación | Proceso | Proyectado (F3–F4) | — |
| C · Python + .venv + requirements.txt → ① configura | Herramienta | Implementado | Sección 5: kernel y versiones verificadas |
| C · src/utilidades.py → ② verifica y carga | Herramienta | Implementado | Sección 4: módulo importado y probado (13 casos) |
| C · pandas · NumPy + validar_dataset.py → ③ mide | Herramienta | Implementado | Secciones 6–7; F2 sección 2; docs/validacion_dataset.md |
| C · pandas · scikit-learn → ④ transforma | Herramienta | Implementado en F2 | F2 secciones 3–5 |
| C · pandas (groupby) → ⑤ agrega | Herramienta | Proyectado (F3) | — |
| C · Matplotlib · seaborn → ⑥ visualiza | Herramienta | Parcial: gráficos de control en F2; figuras en F4 | F2 secciones 3.5, 4 y 5 |
| C · Git + GitHub y JupyterLab (transversales) | Herramienta | Implementado | Historial de Git; Pull Requests integrados a main; sección 9.1 |
| D · Estructura: F1/, F2/, data/, src/, docs/ en la raíz | Organización del repositorio | Implementado | Sección 9: validar_fase1 |
| D · results/ (tablas y figuras) | Organización del repositorio | Proyectado (F4) | — |
| D · Protocolo: notebooks ejecutados, rama + PR, commits por integrante | Decisión técnica | Implementado con ajuste: desarrollo a cargo de un integrante, con autorización docente | Historial de Git y README |
| E · Notebook: Markdown + código + salidas | Estructura del notebook | Implementado | Narrativa antes de cada bloque en F1 y F2 |
| E · Bitácora de decisiones con cifras | Documentación | Implementado | docs/bitacora_f2.md |
| E · Informe + referencias APA 7 (DGA con enlace) | Documentación | Implementado | docs/informe/; sección 7.2 |

## 7.1 Justificación de la relación entre planificación e implementación

Lo implementado corresponde a las etapas que el mapa asignó a F1 y F2 (①–④) y a las herramientas que intervienen en ellas. Las decisiones proyectadas se materializaron, entre ellas eliminar `CUBIERTO`, convertir las coordenadas, el módulo `src/`, la convención de commits y el trabajo en ramas con Pull Request. Respecto de la primera versión del mapa hay cuatro cambios, y cada uno responde a evidencia o a la retroalimentación:

- **notebooks/ → F1/ y F2/.** El entregable exige carpetas por fase.
- **nbstripout → no se usa en la entrega.** La rúbrica evalúa las salidas como evidencia de

ejecución.

- **El volumen se reconstruye en lugar de imputarse.** El mapa no anticipaba los ceros de volumen; la exploración mostró que son redondeo y que el inventario usa una fórmula reproducible.
- **La pregunta se acotó a la concentración del volumen**, y su interpretación incorpora el supuesto verificado de que el volumen se estimó desde el área (Chen y Ohmura, 1990).

Lo proyectado sigue siendo pertinente. El análisis de concentración (⑤) y la comunicación (⑥) son el objeto de F3 y F4, y parten de `glaciares_limpio.csv`. `src/` crecerá cuando F3 reutilice las funciones de imputación, codificación y escalamiento de F2, y `results/` se creará cuando existan tablas y figuras que comunicar.

## 8. Síntesis del avance y próximos pasos

El avance entrega:

- un entorno reproducible con versiones verificadas;
- un repositorio organizado por fase y trabajado en ramas, con un módulo compartido (`src/utilidades.py`) que evita duplicar funciones;
- un pipeline que convierte el inventario original en dos conjuntos validados (17/17 validaciones y 44 pruebas de funciones), con gráficos de control y metadatos exportados mediante recursividad, sin eliminar ningún glaciar y sin modificar el archivo fuente.

Los hallazgos más relevantes del proceso fueron:

- los **faltantes encubiertos**: volúmenes y altitudes en 0 que no figuraban como nulos;
- la **fórmula diferenciada del volumen** en los glaciares rocosos;
- la **asimetría extrema** de las magnitudes, que condicionó de forma coherente la imputación y el escalamiento.

**Próximos pasos.** En F3 se medirá la concentración del volumen y de la superficie (participación de los glaciares mayores y curvas de concentración por región, macrozona y clasificación), declarando que el volumen deriva del área. Las funciones de F2 que se reutilicen se trasladarán a `src/`. En F4 se comunicará si la concentración cambia según la clasificación.

# Bibliografía


Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book/es/v2

Chen, J., & Ohmura, A. (1990). Estimation of Alpine glacier water resources and their change since the 1870s. *IAHS Publication, 193*, 127–135.

Dirección General de Aguas. (2022). *Inventario público de glaciares de Chile 2022* [Conjunto de datos]. Ministerio de Obras Públicas. https://dga.mop.gob.cl/inventario-publico-glaciares/

Dussaillant, I., Berthier, E., Brun, F., Masiokas, M., Hugonnet, R., Favier, V., Rabatel, A., Pitte, P., & Ruiz, L. (2019). Two decades of glacier mass loss along the Andes. *Nature Geoscience, 12*(10), 802–808. https://doi.org/10.1038/s41561-019-0432-5

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hugonnet, R., McNabb, R., Berthier, E., Menounos, B., Nuth, C., Girod, L., Farinotti, D., Huss, M., Dussaillant, I., Brun, F., & Kääb, A. (2021). Accelerated global glacier mass loss in the early twenty-first century. *Nature, 592*(7856), 726–731. https://doi.org/10.1038/s41586-021-03436-z

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B., Bussonnier, M., Frederic, J., Kelley, K., Hamrick, J., Grout, J., Corlay, S., Ivanov, P., Avila, D., Abdalla, S., Willing, C., & Jupyter Development Team. (2016). Jupyter Notebooks: A publishing format for reproducible computational workflows. En F. Loizides & B. Schmidt (Eds.), *Positioning and power in academic publishing: Players, agents and agendas* (pp. 87–90). IOS Press. https://doi.org/10.3233/978-1-61499-649-1-87

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3.ª ed.). O'Reilly Media. https://wesmckinney.com/book/

pandas development team. (2026). *pandas: User guide* (Versión 3.1) [Documentación de software]. https://pandas.pydata.org/docs/user_guide/index.html

Pimentel, J. F., Murta, L., Braganholo, V., & Freire, J. (2021). Understanding and improving the quality and reproducibility of Jupyter notebooks. *Empirical Software Engineering, 26*(4), Artículo 65. https://doi.org/10.1007/s10664-021-09961-9

Python Software Foundation. (2026). *hashlib — Secure hashes and message digests* [Documentación de software]. https://docs.python.org/3/library/hashlib.html

Salinas, O. (2026). *Programación para la ciencia de datos: Semana 1* [Diapositivas de clase, MCDI500]. Universidad Andrés Bello.

Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLOS Computational Biology, 9*(10), Artículo e1003285. https://doi.org/10.1371/journal.pcbi.1003285

scikit-learn developers. (2026). *Preprocessing data* (Versión 1.9) [Documentación de software]. https://scikit-learn.org/stable/modules/preprocessing.html

Universidad Andrés Bello. (2026). *Guía de desarrollo: Evaluación Sumativa 1 (Fases 1 y 2)* [Documento de apoyo, MCDI500].

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology, 13*(6), Artículo e1005510. https://doi.org/10.1371/journal.pcbi.1005510

# Anexo A. Perfil de las 45 variables originales

Tipo leído por pandas 3.1.1, rol analítico asignado en el diccionario de F1 (sección 7), valores únicos y porcentaje de faltantes sobre 26.180 registros.

| Variable | Tipo | Rol analítico | Únicos | % faltante |
|---|---|---|---|---|
| OBJECTID | int64 | Identificador técnico | 26.078 | 0,00 |
| Id | int64 | Identificador auxiliar (constante) | 1 | 0,00 |
| COD_GLA | str | Identificador principal | 26.180 | 0,00 |
| NOMBRE | str | Descriptiva | 431 | 0,00 |
| CLASIFICA | str | Categórica principal | 5 | 0,00 |
| AREA_KM2 | float64 | Numérica principal | 2.323 | 0,00 |
| REGION | str | Categórica principal | 16 | 0,00 |
| PROVINCIA | str | Categórica | 40 | 0,00 |
| COMUNA | str | Categórica | 84 | 0,00 |
| DATUM | str | Metadato espacial | 1 | 0,00 |
| HUSO | str | Metadato espacial | 1 | 0,00 |
| NORTE | int64 | Espacial | 25.948 | 0,00 |
| ESTE | int64 | Espacial | 24.677 | 0,00 |
| FUENTE_DIG | str | Metadato | 19 | 0,00 |
| FUEN_FECHA | str | Metadato temporal | 264 | 0,00 |
| INVE_FECHA | int64 | Metadato temporal | 5 | 0,00 |
| NOM_CUEN | str | Categórica principal | 55 | 0,00 |
| COD_CUEN | int64 | Código categórico | 55 | 0,00 |
| COD_SCUEN | int64 | Código categórico | 179 | 0,00 |
| COD_SSCUEN | int64 | Código categórico | 484 | 0,00 |
| MZON_GLAC | str | Categórica principal | 4 | 0,00 |
| CH_CASQ | str | Categórica complementaria | 6 | 97,24 |
| CUBIERTO | float64 | Por evaluar (vacía) | 0 | 100,00 |
| LATITUD | str | Espacial | 26.180 | 0,00 |
| LONGITUD | str | Espacial | 26.180 | 0,00 |
| PERIMETRO | float64 | Numérica complementaria | 6.757 | 0,00 |
| ORIENTA | str | Categórica complementaria | 9 | 0,00 |
| HMEDIA | float64 | Numérica complementaria | 25.996 | 0,00 |
| HMAX | float64 | Numérica complementaria | 4.441 | 0,00 |
| HMIN | float64 | Numérica complementaria | 4.492 | 0,00 |
| PENDIENTE | float64 | Numérica complementaria | 16.897 | 0,00 |
| ESP_MED | float64 | Numérica complementaria | 14.779 | 0,00 |
| F_ESP_MED | str | Metadato metodológico | 1 | 0,00 |
| VOL_km3 | float64 | Numérica principal | 3.441 | 0,00 |
| EQ_AGUAKM3 | float64 | Numérica principal | 3.262 | 0,00 |
| WGI_1 | int64 | Código categórico | 5 | 0,00 |
| WGI_2 | int64 | Código categórico | 10 | 0,00 |
| WGI_3 | int64 | Código categórico | 15 | 0,00 |

| Variable | Tipo | Rol analítico | Únicos | % faltante |
|---|---|---|---|---|
| FRENTE_TER | str | Categórica complementaria | 3 | 0,00 |
| RESOL_IMG | float64 | Metadato técnico | 14 | 0,00 |
| ERROR | float64 | Técnica | 7.378 | 0,00 |
| OBSERVACIO | float64 | Por evaluar (vacía) | 0 | 100,00 |
| CUT_REG | int64 | Código categórico | 16 | 0,00 |
| CUT_PROV | int64 | Código categórico | 40 | 0,00 |
| CUT_COM | int64 | Código categórico | 84 | 0,00 |

# Anexo B. Bitácora de decisiones de la Fase 2

Generada automáticamente por la clase `Bitacora` del notebook F2 y exportada a `docs/bitacora_f2.md` (36 decisiones). Se reproduce sin edición.

| # | Etapa | Decisión | Evidencia |
|---|---|---|---|
| 1 | obtención | Se carga el CSV oficial desde data/raw sin modificarlo | 26,180 filas × 45 columnas; SHA-256 5691de5d7d7f… = referencia |
| 2 | exploración | Id no aporta información (valor único) | 0.0 % faltante; 1 valor(es) único(s); valor = 0 |
| 3 | exploración | DATUM no aporta información (valor único) | 0.0 % faltante; 1 valor(es) único(s); valor = WGS 84 |
| 4 | exploración | HUSO no aporta información (valor único) | 0.0 % faltante; 1 valor(es) único(s); valor = 19 SUR |
| 5 | exploración | CH_CASQ no aporta información (faltantes > 60%) | 97.24 % faltante; 6 valor(es) único(s) |
| 6 | exploración | CUBIERTO no aporta información (faltantes > 60%) | 100.0 % faltante; 0 valor(es) único(s) |
| 7 | exploración | F_ESP_MED no aporta información (valor único) | 0.0 % faltante; 1 valor(es) único(s); valor = CHEN & OHMURA 1990 |
| 8 | exploración | OBSERVACIO no aporta información (faltantes > 60%) | 100.0 % faltante; 0 valor(es) único(s) |
| 9 | exploración | COD_GLA es el identificador; OBJECTID no identifica filas | COD_GLA único en 26,180 filas; OBJECTID repetido en 102 filas; 0 filas duplicadas |
| 10 | exploración | Área y volumen son muy asimétricos, con atípicos legítimos | AREA_KM2: asimetría 43.1, media 0.803 vs. mediana 0.036 km², 14.37 % fuera del IQR; VOL_km3: asimetría 54.0 |
| 11 | exploración | Los glaciares y regiones mayores reúnen casi todo el hielo | el 1 % mayor reúne el 93.8 % del volumen y el 71.5 % del área; las dos regiones con más volumen (MAGALLANES Y ANTARTICA CHILENA y AYSEN DEL GENERAL CARLOS IBAÑEZ DEL CAMPO) suman el 97.9 % |
| 12 | exploración | VOL_km3 = 0 es redondeo, no ausencia de hielo | 362 glaciaretes de área ≤ 0,002 km²; la fórmula reproduce el volumen (razón mediana 0.9999; rocosos 0.6 = 60 % de hielo) |
| 13 | exploración | El espesor y el volumen se estimaron desde el área (Chen y Ohmura, 1990) | ESP_MED = 28,5·AREA^0,357 en los 5 tipos (a entre 28.464 y 28.502, b entre 0.3567 y 0.357, R² ≥ 0.9985); área y volumen no son variables independientes |
| 14 | exploración | EQ_AGUAKM3 es una proporción fija de VOL_km3 según el tipo | EQ/VOL mediana 0.85 (850 kg/m³) y 0.917 en rocosos; 668 ceros por redondeo |
| 15 | exploración | HMIN = 0 con frente en tierra o lago es un faltante encubierto | 69 glaciares con HMIN = 0: 36 en fiordo (plausible) y 33 en tierra/lago (implausible) |
| 16 | exploración | Un glaciar viola HMIN ≤ HMEDIA ≤ HMAX | CL108116007@ (ÑUBLE): HMEDIA 2,228 m < HMIN 2,849 m |
| 17 | exploración | WGI_1 duplica la información de CLASIFICA | correspondencia uno a uno entre las 5 clases y los códigos WGI_1: True |
| 18 | exploración | Revisión de categorías: codificación, mayúsculas, espacios y variantes | NOMBRE: 'VOLCAN PLANCHON  PETEROA' (espacios irregulares); FUENTE_DIG: 'LiDAR ANDINA' (mayúsculas inconsistentes); FUENTE_DIG: 'FOTOGRAMETR ├ìA' (codificación de caracteres); NOM_CUEN: 'COSTERAS ENTRE LAG.  BLANCA(INC), SENO OTWAY, CANAL JERONIMO Y MAGALLANES' (espacios irregulares) |
| 19 | exploración | FUEN_FECHA mezcla formatos; LATITUD/LONGITUD son texto con coma decimal | DD/MM/AAAA: 26,167, AAAA: 12, MM/DD/AAAA: 1; ejemplo LATITUD '-18,1744803305003' |
| 20 | limpieza | Se descartan 9 columnas: Id, DATUM, HUSO, CUBIERTO, F_ESP_MED, OBSERVACIO, WGI_1, OBJECTID, CH_CASQ | 100 % vacías (CUBIERTO, OBSERVACIO), valor único (Id, DATUM = WGS 84, HUSO = 19 SUR, F_ESP_MED = CHEN & OHMURA 1990), redundante (WGI_1 ≡ CLASIFICA), sin unicidad (OBJECTID), CH_CASQ > 60 % faltante (45 → 36 columnas originales) |
| 21 | limpieza | CH_CASQ se convierte en la bandera binaria EN_CAMPO_HIELO | el faltante significa 'no pertenece'; 723 glaciares pertenecen a un campo de hielo o casquete |
| 22 | limpieza | Se normaliza el texto (codificación, mayúsculas y espacios) | 139 valores corregidos (NOMBRE: 5, FUENTE_DIG: 6, NOM_CUEN: 128): 'FOTOGRAMETR ├ìA' → 'FOTOGRAMETRÍA', 'LiDAR ANDINA' → 'LIDAR ANDINA' y espacios dobles en nombres |

| # | Etapa | Decisión | Evidencia |
|---|---|---|---|
| 23 | limpieza | Casting: LATITUD/LONGITUD a float, FUEN_FECHA a fecha + FUEN_ANIO, códigos a texto | 26,180 coordenadas convertidas sin pérdida; 26,168 fechas completas y 26,180 años (1955–2022); 8 columnas de código a texto |
| 24 | limpieza | Se recalculan los ceros de VOL_km3 y EQ_AGUAKM3 con la fórmula del inventario | 362 volúmenes y 668 equivalentes; volumen total +0.001333 km³ (despreciable); banderas VOL/EQ_RECALCULADO |
| 25 | imputación | HMIN = 0 en tierra/lago se marca como faltante e imputa con 'HMEDIA − desnivel mediano por comuna' | 33 valores (0.13 %); cambio de desv. estándar -0.0029 %; violaciones de HMIN ≤ HMEDIA: media global 33, mediana global 31, mediana por comuna 14, HMEDIA − desnivel mediano por comuna 0; eliminar filas perdería 967.5 km² de hielo |
| 26 | imputación | HMEDIA incoherente se reemplaza por (HMIN + HMAX) / 2 | 1 glaciar; la mediana global (1,525 m) violaría HMIN ≤ HMEDIA; el punto medio da 2,893 m |
| 27 | transformación | Se derivan RANGO_ALT, LOG_AREA, LOG_VOL, CLASE_TAMANO, FRENTE_AGUA y FUENTE_GRUPO | log10 reduce la asimetría del área de 43.1 a 0.61 y del volumen de 54.0 a 0.69; cortes de tamaño [0.01, 0.1, 1, 10] km² |
| 28 | transformación | MZON_GLAC y CLASE_TAMANO se codifican como ordinales con orden declarado | orden geográfico NORTE → AUSTRAL; el alfabético pondría AUSTRAL < CENTRO < NORTE < SUR |
| 29 | transformación | ORIENTA se codifica con seno y coseno | variable circular (N = 0°, NW = 315° son vecinas); 3 laderas PLANO → (0, 0) |
| 30 | transformación | One-hot para CLASIFICA, FRENTE_TER, REGION y FUENTE_GRUPO | nominales sin orden; 32 columnas binarias; FUENTE_DIG: 19 → 8 categorías (< 1 % → OTRAS) |
| 31 | escalamiento | Se excluyen de la matriz LOG_VOL y ESP_MED, redundantes con el área | correlación de Spearman con LOG_AREA: LOG_VOL 0.9965, ESP_MED 0.9999; ambas se calculan desde el área (sección 2.3); se conservan en glaciares_limpio |
| 32 | escalamiento | Se usa RobustScaler (mediana 0, RIC 1) sobre 4 variables continuas | asimetría: LOG_AREA 0.61, HMEDIA 1.45, RANGO_ALT 4.05, PENDIENTE 0.17; las colas de RANGO_ALT y HMEDIA desplazan media y máximo; sobre el área sin log, MinMax deja el 99.0 % de los datos en el 1 % inferior del rango |
| 33 | validación | Se ejecutan 17 validaciones del dataset resultante | 17/17 OK: filas, clave, nulos, tipos, one-hot, ordinales, RobustScaler, reglas físicas, banderas y huella de data/raw |
| 34 | validación | Se ejecutan 23 pruebas de las funciones | 23/23 OK: 8 casos normales, 5 casos límite y 10 excepciones |
| 35 | documentación | Los metadatos del pipeline se aplanan con una función recursiva | 4 niveles de anidamiento → 34 pares clave-valor en docs/metadatos_proyecto.csv; 8 pruebas OK (normales, límite y excepción) |
| 36 | persistencia | Se guardan y releen glaciares_limpio.csv y glaciares_modelo.csv en data/processed | limpio 26180×48 y modelo 26180×47; forma, columnas y tipos comprobados tras releer; utl.cargar_limpio restaura el orden de MZON_GLAC y CLASE_TAMANO y los códigos como texto; data/raw intacto |

# Anexo C. Evaluación del dataset contra los criterios del curso

Generada por `evaluar_criterios` en F1 sección 7.2 y exportada a `docs/evaluacion_criterios_dataset.csv`, con los umbrales de `validar_dataset.py` más dos requisitos de la presentación de la Semana 1. OK: cumple; AVISO: no descalifica el conjunto y se declara como restricción (sección 2.5).

| Estado | Tipo | Requisito | Detalle |
|---|---|---|---|
| OK | obligatorio | Al menos 2000 filas | 26,180 filas |
| OK | obligatorio | Al menos 12 columnas | 45 columnas |
| OK | obligatorio | Combina al menos 3 roles analíticos | alta cardinalidad, continua, discreta, fecha, nominal, ordinal |
| OK | obligatorio | Al menos una variable numérica | 16 (continuas o discretas) |
| OK | obligatorio | Al menos una variable categórica | 10 (nominales, binarias u ordinales) |
| OK | aviso | Presencia de valores faltantes (≥ 1 %) | máximo 100.0 % |
| AVISO | aviso | Ninguna variable sobre 60 % de faltantes | CH_CASQ, CUBIERTO, OBSERVACIO |
| OK | aviso | Incluye alguna variable de fecha | 1 detectada(s) |
| OK | aviso | Incluye texto o alta cardinalidad | 10 detectadas |
| OK | aviso | Archivo bajo 100 MB | 9.46 MB |
| OK | aviso | Sin filas duplicadas exactas | 0 duplicadas |
| AVISO | aviso | Licencia abierta y fuente verificable | fuente oficial verificable; licencia no declarada |
| OK | aviso | Datos de los últimos cinco años | publicado en 2022 |