Universidad Andrés Bello
Magíster en Ciencia de Datos e Inteligencia Artificial
MCDI500 · Programación para la Ciencia de Datos

Evaluación Sumativa 1 · Avance del proyecto, Fases 1 y 2

Análisis reproducible del Inventario Público de Glaciares de Chile 2022

Implementación inicial del entorno reproducible, exploración y procesamiento inicial de los datos

Grupo 3
Aníbal Reyes
Francisco Correa Soto
Gustavo Aloy
Roberto Gaubert

Docente: Dr. Omar Salinas Silva
Fecha: 15 de noviembre de 2026
Repositorio: github.com/fcorreasoto/proyecto-grupo3-mcdi500

Índice

1. Introducción y contextualización....3
1.1 Contexto del proyecto....3
1.2 Situación que origina el análisis y presentación del problema....3
1.3 Propósito general y alcance del informe....3
1.4 Justificación técnica....4
1.5 Conexión con las fases F1–F4....4
2. Definición de la problemática y objetivos del proyecto....5
2.1 Formulación de la problemática....5
2.2 Preguntas centrales del análisis....5
2.3 Objetivos....5
2.4 Alcance del proyecto....6
2.5 Restricciones....6
2.6 Supuestos relevantes....6
2.7 Articulación con las fases....6
3. Aplicación de herramientas científicas....7
3.1 Ecosistema utilizado....7
3.2 Integración en el flujo de trabajo....7
3.3 Reproducibilidad técnica....8
3.4 Control de versiones....8
3.5 Documentación del proceso....9
3.6 Repositorio GitHub....10
4. Diseño de soluciones algorítmicas....11
4.1 Codificación funcional....11
4.2 Preprocesamiento y transformación del dataset....11
4.3 Validación técnica y verificación del código....13
5. Notebook F1_Definicion.ipynb (F1)....15
6. Notebook ejecutable de la Fase 2....15
7. Vinculación del mapa conceptual con el avance del proyecto....17
7.1 Justificación de la relación entre planificación e implementación....18
8. Síntesis del avance y próximos pasos....19
Bibliografía....20
Anexo A. Perfil de las 45 variables del inventario....22

1. Introducción y contextualización

1.1 Contexto del proyecto

Chile concentra una de las mayores superficies glaciares del hemisferio sur fuera de la Antártica. Los glaciares son reservas estratégicas de agua dulce: en las zonas norte y central sostienen el caudal de los ríos durante los meses secos y los años de sequía, y en la Patagonia forman los Campos de Hielo Norte y Sur. La evidencia reciente muestra que los glaciares andinos pierden masa de forma sostenida (Dussaillant et al., 2019) y que la pérdida de hielo a escala global se aceleró durante el siglo XXI (Hugonnet et al., 2021). En ese escenario, saber dónde están los glaciares y cuánta agua almacenan es una condición previa para cualquier decisión de gestión hídrica.

La Dirección General de Aguas (DGA) publica el **Inventario Público de Glaciares de Chile 2022**, un catastro oficial que en su versión CSV contiene **26.180 glaciares y 45 variables**: ubicación administrativa e hidrográfica, clasificación, superficie, altitudes, pendiente, espesor medio y volumen estimado (Dirección General de Aguas [DGA], 2022). Es la única fuente de datos del proyecto.

1.2 Situación que origina el análisis y presentación del problema

El inventario existe, pero no es directamente analizable. El reconocimiento inicial realizado en el notebook F1 mostró que dos columnas están completamente vacías (`CUBIERTO` y `OBSERVACIO`), que `CH_CASQ` tiene un 97,24 % de valores faltantes, que las coordenadas `LATITUD` y `LONGITUD` se leen como texto porque usan coma decimal y que las fechas de la fuente (`FUEN_FECHA`) mezclan formatos. A ello se suma una distribución muy asimétrica de las magnitudes físicas: la superficie media es 0,80 km², mientras que la mediana es 0,036 km² y el máximo alcanza 772,5 km².

Si el procedimiento para leer, limpiar y resumir el archivo no es transparente, nadie puede verificar las cifras que se obtengan. El problema que aborda el proyecto es, por tanto, doble: **caracterizar cómo se distribuyen los glaciares de Chile según región, clasificación, superficie y volumen estimado**, y hacerlo con un **flujo reproducible** que cualquier persona pueda ejecutar desde el repositorio y obtener el mismo resultado.

1.3 Propósito general y alcance del informe

Objetivo general. Caracterizar la distribución territorial y las propiedades físicas de los glaciares registrados en el Inventario Público de Glaciares 2022 mediante un flujo de análisis reproducible en Python.

Alcance de este informe. Este avance documenta las Fases 1 y 2: la definición del problema y la configuración del entorno reproducible (F1) y la obtención, exploración, limpieza, transformación y validación del inventario (F2). Los resúmenes territoriales (F3) y las visualizaciones y la comunicación de resultados (F4) se presentan como trabajo proyectado.

1.4 Justificación técnica

Con 26.180 registros, 45 variables y decisiones que dependen de cifras (cuántos faltantes, qué rangos, qué conversiones fallan), el trabajo no puede hacerse de forma manual ni en una planilla sin perder trazabilidad. Programar el proceso en Python permite (a) encapsular cada paso en funciones reutilizables y verificables; (b) justificar cada decisión con evidencia calculada en el mismo documento, gracias a los notebooks de Jupyter (Kluyver et al., 2016); (c) versionar el proceso completo con Git para reconstruir qué cambió, cuándo y quién lo hizo (Chacon & Straub, 2014); y (d) preparar los datos para los análisis y visualizaciones de las fases siguientes. El equipo sigue las prácticas de computación científica de Wilson et al. (2017) y Sandve et al. (2013), y la recomendación de mantener notebooks ejecutables de principio a fin (Pimentel et al., 2021).

1.5 Conexión con las fases F1–F4

Tabla 1. Aporte de cada fase a la solución del problema.

Fase	Propósito	Producto	Estado
F1 · Definición	Delimitar problema, pregunta y objetivos; configurar el entorno; reconocer el inventario sin modificarlo	F1/F1_Definicion.ipynb, README, requirements.txt	Implementada
F2 · Preparación	Obtener, explorar, limpiar, transformar y validar el inventario	F2/F2_Procesamiento.ipynb y data/processed/	Implementada
F3 · Análisis	Resumir número de glaciares, superficie y volumen por región, macrozona y clasificación	Notebook F3 y tablas de resumen	Proyectada (semana 2)
F4 · Comunicación	Visualizar e interpretar los resultados	Figuras, informe final y presentación	Proyectada (semana 3)

2. Definición de la problemática y objetivos del proyecto

2.1 Formulación de la problemática

El fenómeno analizado es la **distribución espacial y por tipo de la masa glaciar de Chile**, observada a través de cuatro variables del inventario: `REGION` (16 regiones), `CLASIFICA` (5 tipos de glaciar), `AREA_KM2` (superficie) y `VOL_km3` (volumen de hielo estimado), complementadas con `EQ_AGUAKM3` (equivalente en agua) y `MZON_GLAC` (macrozona). El problema técnico consiste en transformar el inventario original en un conjunto confiable en el que esas magnitudes puedan agregarse y compararse sin sesgos introducidos por errores de formato, faltantes o inconsistencias, y sin alterar el archivo fuente.

2.2 Preguntas centrales del análisis

Pregunta de investigación: ¿cómo se distribuyen los glaciares registrados en el Inventario Público de Glaciares 2022 según región, clasificación, superficie y volumen estimado? Se desagrega en:

- ¿Qué regiones y macrozonas concentran el número, la superficie y el volumen de los glaciares?
- ¿Cómo se reparten esas magnitudes entre glaciaretes y glaciares de montaña, rocosos, de valle y efluentes?
- ¿Qué tan concentrada está la superficie en unos pocos glaciares grandes?
- Pregunta técnica de F2: ¿qué problemas de calidad presenta el inventario y cómo tratarlos sin perder ni inventar información?

2.3 Objetivos

Objetivo general. Caracterizar la distribución territorial y las propiedades físicas de los glaciares registrados en el inventario mediante un flujo de análisis reproducible en Python.

Tabla 2. Objetivos específicos, fase e indicador de cumplimiento.

Objetivo específico	Fase	Indicador verificable
OE1. Verificar la estructura, la calidad y el rol analítico de las 45 variables del inventario.	F1–F2	Diccionario de 45 variables y perfil de faltantes, únicos y duplicados (F1 §7, F2 §2)
OE2. Documentar y ejecutar la limpieza y transformación del inventario sin modificar el archivo original.	F2	Dataset en data/processed/ y huella SHA-256 del archivo raw idéntica antes y después (F2 §6–7)
OE3. Resumir número de glaciares, superficie total y volumen estimado por región y por clasificación.	F3	Tablas de agregación reproducibles
OE4. Generar tablas y visualizaciones reproducibles desde el repositorio que respondan la pregunta.	F4	Figuras e informe final generados desde los notebooks

2.4 Alcance del proyecto

Se aborda: la caracterización espacial por región, macrozona y cuenca; la comparación por clasificación del glaciar; las magnitudes de superficie, volumen y equivalente en agua; y la construcción de un pipeline reproducible que prepare el inventario para esos análisis.

No se aborda: la estimación de tendencias temporales de pérdida de hielo, los modelos predictivos, el cruce con datos climáticos externos ni la validación en terreno de las mediciones de la DGA.

2.5 Restricciones

A diferencia del alcance, que es una decisión del equipo, las restricciones son condiciones impuestas por los datos, el método y el plazo:

- **Datos transversales.** El 90,8 % de los registros tiene año de inventario 2019 y el 8,7 % 2020; no hay mediciones repetidas del mismo glaciar, por lo que no es posible estimar tendencias.
- **Magnitudes estimadas.** El volumen y el espesor medio provienen de un método empírico (Chen & Ohmura, 1990); no son mediciones directas.
- **Documentación de la fuente.** La DGA no publica junto al CSV un diccionario de variables ni una licencia explícita. El significado y las unidades de `ERROR`, `PERIMETRO`, `PENDIENTE`, `CH_CASQ` y los códigos `WGI_*` quedan por verificar, y el uso es exclusivamente académico, citando la fuente.
- **Plazo y herramientas.** Una semana para las Fases 1 y 2, con las librerías del curso (Python, NumPy, Pandas, Jupyter y Git).

2.6 Supuestos relevantes

- El inventario oficial es la mejor estimación disponible de cada glaciar: no se corrigen valores medidos sin evidencia externa.
- Las unidades (km², km³, m s. n. m.) son homogéneas entre regiones.
- Cada fila representa un glaciar distinto y `COD_GLA` es su identificador. Se comprobó en F1 y F2: 26.180 códigos únicos, sin nulos. `OBJECTID`, en cambio, tiene solo 26.078 valores únicos.
- El inventario se interpreta como una fotografía del estado reciente de los glaciares, no como una serie de tiempo.

2.7 Articulación con las fases

OE1 se cumple entre F1 (estructura, tipos y diccionario) y F2 (perfil de calidad y diagnóstico). OE2 se cumple completamente en F2. OE3 y OE4 se desarrollarán en F3 y F4 a partir de `data/processed/inventario_glaciares_2022_procesado.csv`, el archivo que entrega la Fase 2.

3. Aplicación de herramientas científicas

3.1 Ecosistema utilizado

Tabla 3. Herramientas del ecosistema científico y su función en el proyecto.

Herramienta	Versión	Función en el proyecto
Python	3.14.6 (.venv)	Lenguaje del análisis; se ejecuta dentro del entorno virtual del proyecto
pandas	3.1.1	Lectura del CSV, perfil de columnas, conversión de tipos, validación y exportación (McKinney, 2022; pandas development team, 2026)
NumPy	2.5.4	Base numérica de pandas; tipos de datos y operaciones vectorizadas (Harris et al., 2020)
JupyterLab / ipykernel	4.6.6 / 7.4.0	Notebooks que integran narrativa, código y evidencia (Kluyver et al., 2016)
hashlib, pathlib (biblioteca estándar)	Python 3.14	Huella SHA-256 del archivo original y rutas relativas portables (Python Software Foundation, 2026)
Git / GitHub	—	Historial local de cambios y repositorio remoto compartido (Chacon & Straub, 2014)

El archivo `requirements.txt` también fija Matplotlib 3.11.2, seaborn 0.13.2 y scikit-learn 1.9.1. Aún no se usan en F1 ni en F2: quedan instalados para las visualizaciones de F4 y para un eventual escalamiento en F3, de modo que el entorno no tenga que cambiar entre fases.

3.2 Integración en el flujo de trabajo

Las librerías se usan dentro de funciones con un propósito declarado y no en celdas sueltas. El flujo completo es el siguiente: **verificación del entorno → localización de rutas relativas → carga del CSV → perfil y diagnóstico → transformación sobre una copia → validación con `assert` → exportación y relectura**. Cada etapa recibe un DataFrame y devuelve un resultado nuevo, de modo que la correspondencia entre entrada, procesamiento y salida puede comprobarse en el propio notebook.

Tabla 4. Funciones del flujo programático.

Función	Notebook	Entrada → salida
verificar_entorno(dependencias)	F1 §4	Lista de paquetes → versión de Python, sistema y versión instalada de cada paquete
localizar_raiz(inicio)	F1 §5	Directorio de ejecución → raíz del repositorio (FileNotFoundError si no existe data/raw/)
cargar_inventario(ruta)	F1 §6, F2 §1	Ruta del CSV → DataFrame original, sin modificar
describir_estructura(df) / construir_diccionario(df, defs)	F1 §6–7	DataFrame → tabla de tipos; diccionario de 45 variables con faltantes y únicos
diagnostico_documental(df, dicc)	F1 §7.1	DataFrame → señales de calidad para planificar F2
huella_sha256(ruta)	F2 §1	Archivo → hash SHA-256 para demostrar que raw no cambia
perfil_columnas(df) / diagnostico_iqr(df, cols)	F2 §2	DataFrame → perfil de calidad; conteo de valores fuera del rango intercuartílico
convertir_decimal_coma(serie)	F2 §4	Texto con coma decimal → float (valores inválidos → NaN)

Función	Notebook	Entrada → salida
transformar_inventario(df)	F2 §4	Inventario (45 col.) → copia con 3 columnas auxiliares (48 col.)
reporte_impacto(antes, despues)	F2 §5	Dos DataFrames → tabla de controles antes/después
validar_inventario(antes, despues)	F2 §6	Dos DataFrames → True o AssertionError con el motivo

3.3 Reproducibilidad técnica

Entorno virtual y dependencias

El proyecto usa un entorno virtual propio (`.venv`), excluido del control de versiones. Las dependencias se declaran con versión exacta en `requirements.txt`, generado con `pip freeze`. Para reconstruir el entorno en otro equipo:

```
git clone https://github.com/fcorreasoto/proyecto-grupo3-mcdi500.git
cd proyecto-grupo3-mcdi500
python3 -m venv .venv
source .venv/bin/activate          # Windows: .venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
```

Verificación de la instalación y ejecución sin errores

- **Registro del entorno.** La función `verificar_entorno` de F1 imprime la versión de Python, el sistema operativo y la versión instalada de numpy, pandas, jupyterlab e ipykernel. La celda inicial de F2 registra las versiones de Python, NumPy y pandas con las que se generaron sus resultados.
- **Ejecución de inicio a fin.** Ambos notebooks se ejecutaron completos con `jupyter nbconvert --to notebook --execute` (equivalente a Restart & Run All) dentro del `.venv` (Python 3.14.6, pandas 3.1.1, NumPy 2.5.4), sin errores. F1 también se ejecutó con Python 3.12.3 y las mismas versiones de pandas y NumPy.
- **Rutas relativas.** F1 localiza la raíz del repositorio subiendo desde el directorio de ejecución hasta encontrar `data/raw/`; F2 acepta ejecutarse desde `F2/` o desde la raíz. Ningún notebook depende de una ruta personal.
- **Integridad del dato original.** F2 calcula la huella SHA-256 del CSV al inicio (`5691de5d…c283f1d`) y la recalcula tras validar y tras exportar: si el archivo de `data/raw/` cambiara, el notebook fallaría.
- **Determinismo.** El pipeline no usa muestreo ni procesos aleatorios, por lo que no requiere semilla: dos ejecuciones producen el mismo archivo.
- **Verificación en un segundo equipo.** Un integrante distinto de quien configuró el entorno clona el repositorio, reconstruye el `.venv` desde `requirements.txt` y ejecuta ambos notebooks. El resultado se registra en el README.

3.4 Control de versiones

Git registra localmente la evolución del proyecto (qué cambió, cuándo, quién y por qué) y GitHub aloja el repositorio remoto común (Chacon & Straub, 2014). La convención de mensajes declarada en el mapa conceptual usa un prefijo por tipo de cambio:

Tabla 5. Convención de mensajes de commit.

Prefijo	Uso	Ejemplo del historial
docs:	Documentación y estructura	docs: crear estructura inicial del proyecto
data:	Incorporación o cambio de datos	data: incorpora dataset base en raw y actualizacion del README
feat:	Nueva funcionalidad (notebooks, funciones)	feat: agrega pipeline de transformación en F2
fix:	Corrección de errores	fix: corrige ruta de salida a data/processed

Tabla 6. Historial de commits del avance (rama main).

Commit	Autor	Fecha	Mensaje
0aa3b95	Francisco Correa	05-11-2026	Initial commit
ed4dffe	Francisco Correa	05-11-2026	add Inventario de Glaciares data
4dac4c9	Francisco Correa	05-11-2026	docs: crear estructura inicial del proyecto
818758c	Francisco Correa	05-11-2026	data: incorpora dataset base en raw y actualizacion del README
025a317	Roberto Gaubert	10-11-2026	docs:Arregle el repositoreo, cree 2 carpetas
1774b5e	Gustavo Aloy	10-11-2026	docs: agregue una nueva carpeta donde se encuentran los datos procesados
c9dcf71	Gustavo Aloy	10-11-2026	update: actualizamos los requerimientos del proyecto
b04b33b	Roberto Gaubert	10-11-2026	update: Se agrego notebook para F1
fe4df0d	Roberto Gaubert	10-11-2026	update:gitignore actualizado
268cc89	Gustavo Aloy	10-11-2026	update: agregue Notebook F2
2a9446c	Francisco Correa	10-11-2026	docs: se agrego la formativa f1, mapa conceptual

El historial muestra el avance progresivo: primero la estructura y los datos (5 de noviembre), y luego los requerimientos, los notebooks F1 y F2 y la documentación del mapa (10 de noviembre). Cada commit se hizo desde la cuenta de su autor. Durante esta primera semana se trabajó directamente sobre `main`. Los mensajes con prefijo `update:` no siguen la convención declarada y se reemplazan por `feat:` o `docs:` en adelante. Desde la Fase 3 cada tarea se desarrolla en una rama propia que se integra a `main` mediante Pull Request revisado por otro integrante.

El archivo `.gitignore` excluye el entorno virtual (`.venv/`, `venv/`, `env/`), las cachés de Python, las variables de entorno (`.env`), archivos de sistema (`Thumbs.db`, `.DS_Store`) y la carpeta `material/` con el material de clase, que no es de autoría del grupo.

3.5 Documentación del proceso

El proceso queda documentado en tres niveles coherentes entre sí:

- **Notebooks.** Cada bloque de código va precedido por una celda Markdown que explica qué se hace y por qué. Las funciones incluyen docstrings y los notebooks cierran con una bitácora de decisiones y pendientes (F1 §9 y anexo final; F2 §8).
- **Repositorio.** El README describe el proyecto, la estructura, las dependencias y el orden de ejecución. `docs/validacion_dataset.md` conserva el perfil de las 45 variables y el cumplimiento de los requisitos del curso.

- **Informe.** Recoge las decisiones con sus cifras (sección 4.2) y los enfoques descartados (sección 4.2 y capítulo 7).

Flujo de datos documentado. Entra `data/raw/Inventario_Publico_de_Glaciares_2022.csv` (26.180 × 45, 9,46 MB). F1 lo lee y lo describe sin modificarlo. F2 lo diagnostica, crea una copia con tres columnas auxiliares, la valida y escribe `data/processed/inventario_glaciares_2022_procesado.csv` (26.180 × 48) y `data/processed/perfil_f2.csv` (perfil de calidad de las 48 columnas).

3.6 Repositorio GitHub

El repositorio organiza el trabajo por fase y separa el dato original del procesado:

```
proyecto-grupo3-mcdi500/
├── F1/F1_Definicion.ipynb          # Fase 1: definición y entorno
├── F2/F2_Procesamiento.ipynb       # Fase 2: obtención → validación
├── data/
│   ├── raw/                        # CSV original de la DGA (inmutable)
│   └── processed/                  # Salidas de F2
├── docs/
│   ├── validacion_dataset.md       # Perfil de variables y requisitos
│   └── f1/                         # Mapa conceptual (Formativa 1) e informe
├── requirements.txt                # Dependencias con versión exacta
├── .gitignore
└── README.md                       # Descripción, instalación y ejecución
```

4. Diseño de soluciones algorítmicas

4.1 Codificación funcional

El código sigue cuatro principios: (1) **una función por tarea**, con parámetros explícitos; (2) **ninguna función modifica su entrada**: se trabaja sobre `df.copy(deep=True)` y se devuelve un objeto nuevo, lo que preserva el DataFrame original para comparar antes y después; (3) **los errores se hacen visibles**: una conversión que falla produce `NaN` contable, no un valor inventado; y (4) **las estructuras de control recorren columnas**, en lugar de repetir el mismo bloque por variable. Ejemplo de la transformación de F2:

```
def convertir_decimal_coma(serie):
    # '-18,17' (texto) -> -18.17 (float); lo no interpretable queda como NaN
    return pd.to_numeric(serie.astype("string").str.strip()
                         .str.replace(",", ".", regex=False), errors="coerce")

def transformar_inventario(df):
    resultado = df.copy(deep=True)            # nunca se modifica el original
    resultado["LATITUD_NUM"] = convertir_decimal_coma(resultado["LATITUD"])
    resultado["LONGITUD_NUM"] = convertir_decimal_coma(resultado["LONGITUD"])
    resultado["FUEN_FECHA_DT"] = pd.to_datetime(resultado["FUEN_FECHA"],
                                    format="%d/%m/%Y", errors="coerce")
    return resultado
```

La función de diagnóstico usa un bucle sobre las columnas para calcular cuartiles y valores fuera de rango, de modo que agregar una variable al análisis solo requiere añadirla a la lista:

```
def diagnostico_iqr(df, columnas):
    filas = []
    for columna in columnas:
        x = pd.to_numeric(df[columna], errors="coerce").dropna()
        q1, q3 = x.quantile([.25, .75])
        iqr = q3 - q1
        fuera = int(((x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)).sum())
        filas.append({"variable": columna, "q1": q1, "q3": q3, "fuera_iqr": fuera})
    return pd.DataFrame(filas)
```

4.2 Preprocesamiento y transformación del dataset

La regla aplicada fue **medir primero y decidir después**. La Tabla 7 resume el diagnóstico de F2 (§2) sobre el archivo original.

Tabla 7. Diagnóstico previo del inventario (F2 §2).

Aspecto	Resultado medido
Dimensiones	26.180 filas × 45 columnas; 9,46 MB
Duplicados	0 filas duplicadas exactas; 0 COD_GLA duplicados; 0 COD_GLA nulos
Faltantes	CUBIERTO y OBSERVACIO 100 % (26.180); CH_CASQ 97,24 % (25.457); resto de columnas 0 %
Variables constantes	Id (1 valor), DATUM (WGS 84), HUSO y F_ESP_MED (1 valor cada una)
Tipos incompatibles	LATITUD y LONGITUD leídas como texto por la coma decimal (ej. '-18,1744803305003'); FUEN_FECHA como texto

Aspecto	Resultado medido
Fechas no interpretables con DD/MM/AAAA	13: 12 contienen solo el año (p. ej. '2019') y 1 está en formato MM/DD/AAAA ('03/27/2016')
Asimetría de superficie	AREA_KM2: media 0,803; mediana 0,036; máximo 772,511 km²; 3.761 valores fuera del rango IQR
Asimetría de volumen	VOL_km3: 4.380 valores fuera del rango IQR; EQ_AGUAKM3: 4.377
Ceros	VOL_km3 = 0 en 362 registros; EQ_AGUAKM3 = 0 en 668; HMIN = 0 en 69
Coherencia física	1 glaciar (CL108116007@, Ñuble) con HMEDIA = 2.228 m < HMIN = 2.849 m

Decisiones de limpieza y su justificación

Tabla 8. Decisiones de la Fase 2, alternativas evaluadas y justificación.

Hallazgo	Alternativas	Decisión	Justificación
CUBIERTO y OBSERVACIO 100 % vacías	Eliminar · imputar · conservar	Conservar en el archivo procesado; excluir de los análisis de F3	No existe ningún valor desde el cual imputar. Conservarlas mantiene el esquema original verificable columna a columna (F2 §6)
CH_CASQ 97,24 % faltante	Eliminar · completar · conservar	Conservar los faltantes sin imputar	Solo 723 glaciares tienen código. El faltante parece significar «no pertenece a un campo de hielo», pero la fuente no lo documenta: imputarlo sería inventar información
LATITUD y LONGITUD como texto	Mantener texto · sobrescribir · columna auxiliar	Crear LATITUD_NUM y LONGITUD_NUM (float)	Habilita cálculos espaciales sin perder el valor original; las 26.180 coordenadas se convirtieron sin fallas
FUEN_FECHA como texto con formatos mixtos	Mantener texto · convertir · columna auxiliar	Crear FUEN_FECHA_DT con formato DD/MM/AAAA	26.167 fechas válidas; las 13 no interpretables quedan como NaT y se reportan, en lugar de adivinar el día y el mes
Superficie y volumen asimétricos, con miles de valores fuera del IQR	Eliminar atípicos · winsorizar · conservar	Conservar todos los registros	Los glaciares grandes (por ejemplo, los efluentes de los Campos de Hielo) son observaciones reales que concentran la mayor parte del hielo; eliminarlos sesgaría la respuesta a la pregunta
Valores faltantes en variables de análisis	Eliminar filas · imputar media/mediana/grupo	No imputar	AREA_KM2, VOL_km3, EQ_AGUAKM3, REGION y CLASIFICA tienen 0 faltantes: no hay nada que imputar y sus estadísticas permanecen idénticas
Id constante	Eliminar · conservar	Conservar sin usarlo como identificador	No aporta variación; COD_GLA es el identificador verificado
HMEDIA < HMIN en 1 glaciar; 69 HMIN = 0	Corregir · marcar · reportar	Reportar sin corregir	Corregir requiere evidencia externa. Se documenta para revisarlo en F3, donde la altitud no es una variable central

Transformaciones según el rol de cada variable

- **Casting.** Las coordenadas pasan de texto a `float64` y la fecha de la fuente a `datetime64`. Se crean como columnas auxiliares para que el valor original permanezca disponible y comparable.
- **Normalización y escalamiento: no se aplican en esta fase.** Los objetivos de F3 son sumas y conteos de superficie y volumen por región y clasificación, que deben expresarse en km² y km³. Escalar las variables cambiaría su interpretación física sin beneficio para esos resúmenes. Si en F3 se compararan variables de distinta escala, se evaluará primero una transformación logarítmica (por la asimetría medida en la Tabla 7) y después un escalador robusto.

- **Codificación de categóricas: no se aplica one-hot.** `REGION`, `CLASIFICA` y `MZON_GLAC` se usan como variables de agrupación, no como entradas de un modelo; codificarlas generaría columnas redundantes. Los códigos territoriales (`CUT_*`, `COD_CUEN`) y de clasificación WGI se mantienen como códigos y no se tratan como cantidades.

Impacto medido de las decisiones

Tabla 9. Controles antes y después de la transformación (F2 §5).

Control	Antes	Después
Registros	26.180	26.180
Columnas	45	48
Latitudes numéricas	0 (texto)	26.180
Longitudes numéricas	0 (texto)	26.180
Fechas interpretables	0 (texto)	26.167
Nulos en AREA_KM2	0	0
Nulos en VOL_km3	0	0

El pipeline **no elimina ningún glaciar ni modifica ningún valor original**: las 45 columnas de origen son idénticas antes y después (`pd.testing.assert_frame_equal`), y las estadísticas de superficie y volumen no cambian, porque no se imputó ni se filtró. El único efecto es que 26.180 coordenadas y 26.167 fechas pasan a ser utilizables para el cálculo.

4.3 Validación técnica y verificación del código

La validación combina invariantes del dataset y pruebas de las funciones con casos normales, límite y entradas inválidas. Todas se implementan con `assert` y se ejecutan en el notebook, que conserva sus salidas como evidencia (F2 §6–7).

Tabla 10. Pruebas implementadas y resultado.

Tipo	Prueba	Resultado
Invariante	Se conservan las 26.180 filas	OK
Invariante	Las 45 columnas originales son idénticas en valores y tipos (assert_frame_equal)	OK
Invariante	COD_GLA sin nulos y único	OK
Rango	LATITUD_NUM ∈ [−90, 90] y LONGITUD_NUM ∈ [−180, 180], sin nulos	OK
Rango	AREA_KM2, VOL_km3 y EQ_AGUAKM3 sin faltantes y ≥ 0	OK
Caso normal	convertir_decimal_coma('-33,45') devuelve −33,45	OK
Entrada inválida	convertir_decimal_coma('dato inválido') devuelve NaN, sin error	OK
Caso límite	transformar_inventario sobre un DataFrame vacío devuelve un DataFrame vacío	OK
Caso límite	transformar_inventario sobre una sola fila devuelve 1 × 48	OK
Excepción	localizar_raiz lanza FileNotFoundError con un mensaje claro si no existe data/raw/ (F1)	Implementado
Integridad	La huella SHA-256 de data/raw/ es idéntica tras validar y tras exportar	OK
Persistencia	El CSV exportado se relee: mismas dimensiones (26.180 × 48) y mismo COD_GLA	OK

La salida registrada en el notebook es: «Pruebas superadas: preservación, identificadores, rangos, no negatividad, conversión, caso vacío y huella de origen». En F1, la función `verificar_f1`

comprueba que el archivo no está vacío, que contiene las columnas clave y que tiene 45 columnas; `construir_diccionario` verifica con `assert` que el diccionario documenta exactamente las 45 columnas del CSV.

5. Notebook F1_Definicion.ipynb (F1)

`F1/F1_Definicion.ipynb` contiene exclusivamente el alcance de la Fase 1: **no limpia, no imputa y no transforma**. Su última celda lo deja explícito: «F1 finalizada: no se modificó ni exportó el inventario».

Tabla 11. Estructura del notebook F1.

Sección	Contenido	Evidencia
1	Configuración documental: diccionario PROYECTO con problemática, pregunta, objetivos, alcance, restricciones y supuestos	Fuente única para el notebook y el informe
2–3	Problemática, pregunta y objetivos; alcance, restricciones y supuestos	Funciones mostrar_definicion y mostrar_marco
4	Verificación del entorno reproducible	Versiones de Python, sistema, numpy, pandas, jupyterlab e ipykernel
5	Organización del repositorio y localización de datos con rutas relativas	localizar_raiz; tamaño del CSV: 9,46 MB
6	Reconocimiento inicial: dimensiones, columnas, tipos inferidos y roles analíticos	26.180 × 45; tabla de 16 variables prioritarias presentes
7	Diccionario de las 45 variables y señales de calidad	Diccionario con faltantes y únicos; tabla de decisiones pendientes para F2
8	Correspondencia con las fases F1–F4	Tabla de fases y estado
9	Verificaciones de cierre	verificar_f1 con asserts superados

Hay modularidad en esta fase: nueve funciones con parámetros explícitos y un diccionario de configuración que centraliza la definición del proyecto, de modo que el notebook y el informe usan exactamente la misma formulación.

6. Notebook ejecutable de la Fase 2

`F2/F2_Procesamiento.ipynb` ordena sus celdas según el flujo **obtención → exploración → limpieza → transformación → validación → exportación**. Cada etapa abre con una celda narrativa que explica su lógica.

Tabla 12. Estructura del notebook F2.

Sección	Etapa	Resultado intermedio verificable
0	Entorno reproducible y rutas	Versiones de Python, NumPy y pandas; ruta relativa de la fuente
1	Obtención y preservación de la fuente	Dimensiones (26.180, 45); huella SHA-256; copia independiente
2	Exploración y diagnóstico previo	Perfil de 45 columnas; resumen de 8 variables físicas con conteo de ceros; atípicos IQR; 13 fechas no interpretables
3	Decisiones de limpieza justificadas	Tabla evidencia → alternativas → decisión
4	Transformaciones reproducibles	Dimensiones (26.180, 48); 3 columnas nuevas
5	Impacto cuantificado	Tabla antes/después; conversiones fallidas; anomalía altitudinal
6	Validación técnica y casos límite	Asserts superados con mensaje de confirmación

Sección	Etapa	Resultado intermedio verificable
7	Exportación y evidencia	inventario_glaciares_2022_procesado.csv y perfil_f2.csv, releídos y verificados
8	Bitácora de decisiones y continuidad	Implementado, pendientes y orientación para F3–F4

Salida para la Fase 3. `data/processed/inventario_glaciares_2022_procesado.csv` contiene las 45 columnas originales más `LATITUD_NUM`, `LONGITUD_NUM` (float) y `FUEN_FECHA_DT` (fecha ISO AAAA-MM-DD). `perfil_f2.csv` documenta el tipo, los no nulos, los faltantes y los valores únicos de las 48 columnas.

7. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual de la Formativa 1 organizó el proyecto en cinco bloques: A, contexto problematizador; B, ciclo de vida del dato en seis etapas; C, ecosistema de herramientas; D, estructura del repositorio y commits; y E, documentación científica reproducible. La Tabla 13 contrasta cada elemento con su implementación real.

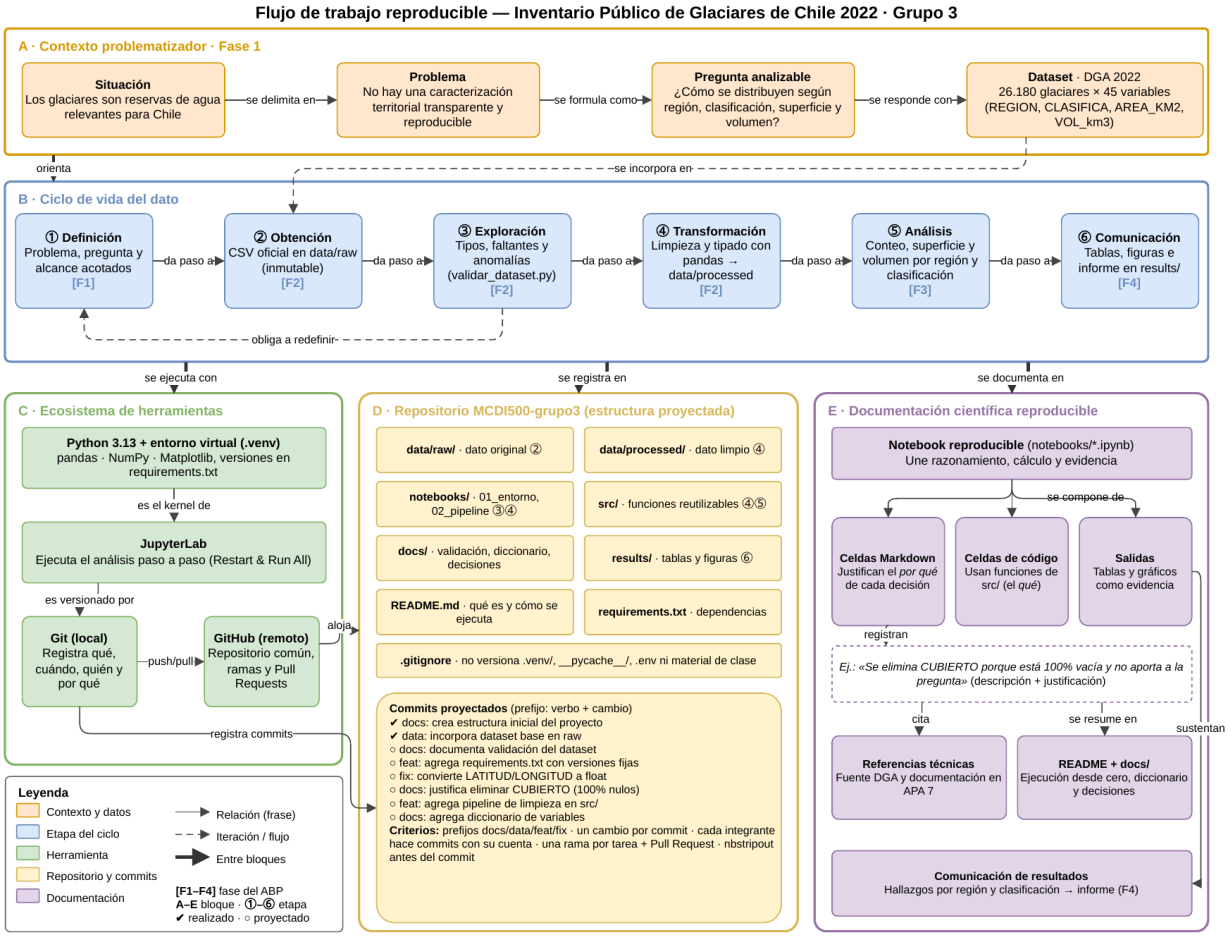


Figura 1. Mapa conceptual del flujo de trabajo reproducible (Evaluación Formativa 1, Grupo 3).

Tabla 13. Correspondencia entre el mapa conceptual y el avance.

Elemento del mapa	Tipo	Estado	Evidencia
A · Situación, problema, pregunta y dataset	Proceso	Implementado	F1 §1–3; informe cap. 1–2; README
B① Definición (problema, pregunta, alcance)	Proceso	Implementado	F1 §1–3
B② Obtención: CSV oficial en data/raw (inmutable)	Flujo reproducible	Implementado	data/raw/; F2 §1 con huella SHA-256
B③ Exploración: tipos, faltantes y anomalías	Proceso	Implementado	F1 §6–7; F2 §2; docs/validacion_dataset.md
B④ Transformación: limpieza y tipado → data/processed	Proceso	Implementado	F2 §3–7; data/processed/

Elemento del mapa	Tipo	Estado	Evidencia
B⑤ Análisis por región y clasificación	Proceso	Proyectado (F3)	—
B⑥ Comunicación en results/	Proceso	Proyectado (F4)	—
C · Python + .venv + requirements.txt	Herramienta	Implementado	requirements.txt; F1 §4
C · pandas y NumPy	Herramienta	Implementado	Funciones de F1 y F2
C · Matplotlib	Herramienta	Instalado; uso proyectado (F4)	requirements.txt
C · JupyterLab (Restart & Run All)	Herramienta	Implementado	Notebooks ejecutados sin errores (sección 3.3)
C · Git local y GitHub remoto	Herramienta	Implementado	Tabla 6; repositorio remoto
C · Ramas y Pull Requests	Decisión técnica	Proyectado (F3)	Sección 3.4
D · data/raw, data/processed, docs/, README, requirements, .gitignore	Organización del repositorio	Implementado	Sección 3.6
D · notebooks/ (01_entorno, 02_pipeline)	Organización del repositorio	Ajustado → F1/ y F2/	Estructura exigida por el entregable
D · src/ (funciones reutilizables)	Organización del repositorio	Proyectado (F3)	Funciones aún dentro de los notebooks
D · results/ (tablas y figuras)	Organización del repositorio	Proyectado (F4)	—
D · Convención de commits (docs/data/feat/fix)	Decisión técnica	Parcial	Tabla 6: 5 de 11 commits la siguen
D · nbstripout antes del commit	Decisión técnica	Descartado para la entrega	Las salidas son evidencia evaluada
D · Eliminar CUBIERTO (100 % nulos)	Decisión técnica	Reemplazado: se conserva	Tabla 8
E · Celdas Markdown + código + salidas	Estructura del notebook	Implementado	F1 y F2: narrativa antes de cada bloque
E · README + docs/ (diccionario y decisiones)	Documentación	Implementado	README; diccionario en F1 §7; bitácora en F2 §8
E · Referencias en APA 7	Documentación	Implementado	Bibliografía de este informe

7.1 Justificación de la relación entre planificación e implementación

Lo implementado corresponde a las etapas que el mapa asignó a F1 y F2 (①–④). Los cambios respecto de lo planificado responden a evidencia o a requisitos del entregable:

- **notebooks/ → F1/ y F2/.** El entregable exige carpetas por fase.
- **Eliminar CUBIERTO → conservarla.** Al implementar la validación se optó por que el esquema de 45 columnas permaneciera idéntico y verificable con `assert_frame_equal`. La columna simplemente se excluye de los análisis.
- **nbstripout → no se usa en la entrega.** La rúbrica evalúa las salidas como evidencia de ejecución; borrarlas en cada commit eliminaría esa evidencia.

Lo proyectado sigue siendo pertinente. El análisis (⑤) y la comunicación (⑥) son el objeto de F3 y F4 y partirán del archivo procesado. `src/` adquiere sentido cuando las mismas funciones se reutilicen entre notebooks de distintas fases, y el flujo de ramas con Pull Request se adopta cuando el trabajo en paralelo sobre notebooks distintos lo hace necesario.

8. Síntesis del avance y próximos pasos

El avance entrega un entorno reproducible con dependencias fijadas, un repositorio organizado por fase y un pipeline que convierte el inventario original en un conjunto validado: 26.180 glaciares sin pérdida de registros, coordenadas y fechas utilizables y el archivo fuente intacto, comprobado mediante su huella SHA-256. Los principales hallazgos de calidad, entre ellos las columnas vacías, la coma decimal, los formatos de fecha mixtos y la asimetría extrema de las magnitudes, quedaron medidos y documentados, junto con la decisión adoptada para cada uno.

Próximos pasos. En F3 se implementarán las agregaciones por región, macrozona y clasificación, con estadísticos robustos dada la asimetría medida. Además, las funciones comunes se trasladarán a `src/` y se adoptará el flujo de ramas con Pull Request. En F4 se elaborarán las visualizaciones y la comunicación de los hallazgos.

Bibliografía

Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book/es/v2

Chen, J., & Ohmura, A. (1990). Estimation of Alpine glacier water resources and their change since the 1870s. *IAHS Publication, 193*, 127–135.

Dirección General de Aguas. (2022). *Inventario público de glaciares de Chile 2022* [Conjunto de datos]. Ministerio de Obras Públicas. https://dga.mop.gob.cl

Dussaillant, I., Berthier, E., Brun, F., Masiokas, M., Hugonnet, R., Favier, V., Rabatel, A., Pitte, P., & Ruiz, L. (2019). Two decades of glacier mass loss along the Andes. *Nature Geoscience, 12*(10), 802–808. https://doi.org/10.1038/s41561-019-0432-5

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hugonnet, R., McNabb, R., Berthier, E., Menounos, B., Nuth, C., Girod, L., Farinotti, D., Huss, M., Dussaillant, I., Brun, F., & Kääb, A. (2021). Accelerated global glacier mass loss in the early twenty-first century. *Nature, 592*(7856), 726–731. https://doi.org/10.1038/s41586-021-03436-z

Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B., Bussonnier, M., Frederic, J., Kelley, K., Hamrick, J., Grout, J., Corlay, S., Ivanov, P., Avila, D., Abdalla, S., Willing, C., & Jupyter Development Team. (2016). Jupyter Notebooks: A publishing format for reproducible computational workflows. En F. Loizides & B. Schmidt (Eds.), *Positioning and power in academic publishing: Players, agents and agendas* (pp. 87–90). IOS Press. https://doi.org/10.3233/978-1-61499-649-1-87

McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3.ª ed.). O'Reilly Media. https://wesmckinney.com/book/

pandas development team. (2026). *pandas: User guide* (Versión 3.1) [Documentación de software]. https://pandas.pydata.org/docs/user_guide/index.html

Pimentel, J. F., Murta, L., Braganholo, V., & Freire, J. (2021). Understanding and improving the quality and reproducibility of Jupyter notebooks. *Empirical Software Engineering, 26*(4), Artículo 65. https://doi.org/10.1007/s10664-021-09961-9

Python Software Foundation. (2026). *hashlib — Secure hashes and message digests* [Documentación de software]. https://docs.python.org/3/library/hashlib.html

Salinas, O. (2026a). *Programación para la ciencia de datos: Semana 1* [Diapositivas de clase, MCDI500]. Universidad Andrés Bello.

Salinas, O. (2026b). *Guía de desarrollo: Evaluación Sumativa 1 (Fases 1 y 2)* [Documento de apoyo, MCDI500]. Universidad Andrés Bello.

Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLOS Computational Biology, 9*(10), Artículo e1003285. https://doi.org/10.1371/journal.pcbi.1003285

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology, 13*(6), Artículo e1005510. https://doi.org/10.1371/journal.pcbi.1005510

Anexo A. Perfil de las 45 variables del inventario

Tipo leído por pandas 3.1.1, rol analítico asignado en el diccionario de F1 (§7), valores únicos y porcentaje de faltantes sobre 26.180 registros. Se reproduce desde F1 y desde `docs/validacion_dataset.md`.

Variable	Tipo	Rol analítico	Únicos	% faltante
OBJECTID	int64	Identificador técnico	26.078	0,00
Id	int64	Identificador auxiliar (constante)	1	0,00
COD_GLA	str	Identificador principal	26.180	0,00
NOMBRE	str	Descriptiva	431	0,00
CLASIFICA	str	Categórica principal	5	0,00
AREA_KM2	float64	Numérica principal	2.323	0,00
REGION	str	Categórica principal	16	0,00
PROVINCIA	str	Categórica	40	0,00
COMUNA	str	Categórica	84	0,00
DATUM	str	Metadato espacial	1	0,00
HUSO	str	Metadato espacial	1	0,00
NORTE	int64	Espacial	25.948	0,00
ESTE	int64	Espacial	24.677	0,00
FUENTE_DIG	str	Metadato	19	0,00
FUEN_FECHA	str	Metadato temporal	264	0,00
INVE_FECHA	int64	Metadato temporal	5	0,00
NOM_CUEN	str	Categórica principal	55	0,00
COD_CUEN	int64	Código categórico	55	0,00
COD_SCUEN	int64	Código categórico	179	0,00
COD_SSCUEN	int64	Código categórico	484	0,00
MZON_GLAC	str	Categórica principal	4	0,00
CH_CASQ	str	Categórica complementaria	6	97,24
CUBIERTO	float64	Por evaluar (vacía)	0	100,00
LATITUD	str	Espacial	26.180	0,00
LONGITUD	str	Espacial	26.180	0,00
PERIMETRO	float64	Numérica complementaria	6.757	0,00
ORIENTA	str	Categórica complementaria	9	0,00
HMEDIA	float64	Numérica complementaria	25.996	0,00
HMAX	float64	Numérica complementaria	4.441	0,00
HMIN	float64	Numérica complementaria	4.492	0,00
PENDIENTE	float64	Numérica complementaria	16.897	0,00
ESP_MED	float64	Numérica complementaria	14.779	0,00
F_ESP_MED	str	Metadato metodológico	1	0,00
VOL_km3	float64	Numérica principal	3.441	0,00
EQ_AGUAKM3	float64	Numérica principal	3.262	0,00
WGI_1	int64	Código categórico	5	0,00

Variable	Tipo	Rol analítico	Únicos	% faltante
WGI_2	int64	Código categórico	10	0,00
WGI_3	int64	Código categórico	15	0,00
FRENTE_TER	str	Categórica complementaria	3	0,00
RESOL_IMG	float64	Metadato técnico	14	0,00
ERROR	float64	Técnica	7.378	0,00
OBSERVACIO	float64	Por evaluar (vacía)	0	100,00
CUT_REG	int64	Código categórico	16	0,00
CUT_PROV	int64	Código categórico	40	0,00
CUT_COM	int64	Código categórico	84	0,00